

Vergleich eines dedizierten Reflexionsbots und eines
generischen KI-Systems zur Unterstützung von
Lernprozessen im Software-Prozessmanagement

BACHELORARBEIT

im Studiengang Bachelor Software Engineering
der Hochschule Heilbronn

Name: Sebastian Schuster
Matrikelnummer: 215992
Erstprüfer: Claudia Sperrfechter
Zweitprüfer: Prof. Dr. rer. nat. Nicole Ondrusch
Zeitraum: 20. April 2026 bis 20. August 2026
Datum: 20. August 2026

Kurzfassung

Generative KI-Systeme werden von Studierenden inzwischen routinemäßig auch bei komplexen Aufgaben eingesetzt, was die Gefahr birgt, dass Lösungen ungeprüft übernommen werden. Diese Arbeit untersucht, ob ein speziell für Reflexion gestaltetes KI-System (Reflexionsbot) dazu führt, dass Studierende Prozessentscheidungen im Software-Prozessmanagement eigenständiger und reflektierter bearbeiten als mit einem generischen KI-System.

Dazu wurde ein Reflexionsbot umgesetzt, der mittels sokratischem Fragen und adaptiver Antworttiefe statt direkter Lösungen begleitet. In einem Mini-Experiment in der Lehrveranstaltung „Grundlagen des Software Engineering 1“ im Bachelorstudiengang Software Engineering der Hochschule Heilbronn bearbeitete eine Gruppe zwei realitätsnahe Prozessszenarien mit dem Reflexionsbot, eine Vergleichsgruppe mit einem generischen KI-System. Die 31 Bearbeitungen und die zugehörigen Chatverläufe wurden mittels strukturierender qualitativer Inhaltsanalyse nach Hatton und Smith kodiert, ergänzt um die Autorenschaft des Textes als eigene Kategorie, und mit einem Prä-Post-Survey (n=22 bzw. n=20) trianguliert.

Der Anteil der Bearbeitungen ohne eindeutig studentische Autorenschaft ist in der Reflexionsbot-Gruppe geringer (8 von 16 gegenüber 12 von 15). Dieser Abstand ist jedoch teilweise durch die Aufgabenvorgabe für die Vergleichsgruppe bedingt und fällt bei den gesichert KI-generierten Fällen deutlich kleiner aus (7 von 16 gegenüber 8 von 15). Die direkten Lernmaße stützen keinen Vorteil des Reflexionsbots. Im Wissenstest verhindert ein Deckeneffekt jede Aussage, und die gezeigte Reflexionstiefe liegt deskriptiv sogar niedriger als in der Vergleichsgruppe (mittlere Stufe 0.75 gegenüber 1.33), bei drei gegenüber acht auswertbaren Fällen allerdings ohne Aussagekraft für die Richtung. Günstiger fällt lediglich die Selbsteinschätzung zum Begründen und Abwägen aus. Didaktisches Design beeinflusst damit das Nutzungsverhalten, ein Lernvorteil ergibt sich daraus aber nicht automatisch. Entscheidend ist die Bereitschaft der Studierenden, sich auf den Dialog einzulassen.

Schlagwörter: Generative KI, Reflexionsbot, Sokratisches Fragen, Software Engineering Education, Mixed-Methods, Qualitative Inhaltsanalyse

Abstract

Students now routinely use generative AI systems even for complex tasks, which carries the risk that solutions are adopted without scrutiny. This thesis investigates whether an AI system specifically designed for reflection (a “Reflexionsbot”) leads students to work through process decisions in software process management more independently and more reflectively than a generic AI system does.

To this end, a Reflexionsbot was implemented that guides students through Socratic questioning and adaptive response depth instead of direct answers. In a mini-experiment conducted within the course “Grundlagen des Software Engineering 1” in the Software Engineering bachelor’s programme at Heilbronn University, one group worked through two realistic process scenarios using the Reflexionsbot, while a comparison group used a generic AI system. The resulting 31 submissions and the corresponding chat logs were coded using structuring qualitative content analysis based on Hatton and Smith’s model of reflective levels, extended by text authorship as a separate category, and triangulated with a pre/post survey (n=22 and n=20, respectively).

The share of submissions without clearly student authorship is lower in the Reflexionsbot group (8 of 16 versus 12 of 15). This gap is partly induced by the task requirement imposed on the comparison group and is considerably smaller when only clearly AI-generated cases are considered (7 of 16 versus 8 of 15). The direct learning measures do not support an advantage of the Reflexionsbot. A ceiling effect in the knowledge test precludes any conclusion, and the demonstrated depth of reflection is descriptively even lower than in the comparison group (mean level 0.75 versus 1.33), although with three versus eight codable cases this difference carries no directional weight. Only students’ self-assessment of reasoning and weighing is more favourable. Didactic design therefore influences usage behaviour, but a learning advantage does not follow automatically. What matters is students’ willingness to engage with the dialogue.

Keywords: Generative AI, Reflection Bot, Socratic Questioning, Software Engineering Education, Mixed Methods, Qualitative Content Analysis

Eidesstattliche Erklärung

Hiermit versichere ich, dass ich die vorliegende Arbeit selbständig verfasst, keine anderen als die angegebenen Quellen und Hilfsmittel benutzt und alle wörtlich oder sinngemäß übernommene Textstellen als solche kenntlich gemacht habe.

Des Weiteren versichere ich, dass diese Arbeit in gleicher oder ähnlicher Form noch keiner anderen Prüfungsbehörde vorgelegen hat und bisher nicht veröffentlicht wurde.

Bei der Erstellung dieser Arbeit habe ich KI-basierte Werkzeuge eingesetzt. Die verwendeten Werkzeuge sowie Zweck und Umfang ihres Einsatzes sind im Anhang (Abschnitt A.8) vollständig dokumentiert. Alle KI-generierten Inhalte habe ich kritisch geprüft, verifiziert und überarbeitet. Die Verantwortung für den Inhalt dieser Arbeit liegt vollständig bei mir.

Datum, Ort

Unterschrift

Inhaltsverzeichnis

Kurzfassung	ii
Abstract	iii
Eidesstattliche Erklärung	iv
Abkürzungsverzeichnis	viii
Abbildungsverzeichnis	ix
Tabellenverzeichnis	x
1 Einleitung, Motivation und Zielsetzung	1
1.1 Motivation	2
1.2 Problemstellung	3
1.3 Zielsetzung und Forschungsfragen	4
1.4 Abgrenzung des Untersuchungsrahmens	5
1.5 Beitrag der Arbeit	6
2 Theoretische Grundlagen	7
2.1 Relevante Technologien und Konzepte	7
2.1.1 Large Language Models (LLMs)	7
2.1.2 Chat-Completions-API und Systemnachricht	8
2.1.3 Prompt Engineering	9
2.1.4 Scaffolding und Sokratisches Fragen	10
2.1.5 Reflexion und Reflexionsstufenmodelle	11
2.1.6 Mixed-Methods-Forschungsdesign	12
2.2 Stand der Technik	13
2.2.1 Generative KI in der Hochschullehre	13
2.2.2 Chatbots und KI-Tutoren im Bildungsbereich	15
2.2.3 Reflexion und Scaffolding-Ansätze	15
2.2.4 Vergleich und Einordnung	16

3	Methodik	19
3.1	Forschungsdesign	19
3.2	Datenerhebung	20
3.3	Stichprobe	21
3.4	Fragebogen und Mini-Experiment	23
3.5	Datenanalyse	27
3.6	Gütekriterien	29
3.7	Forschungsethik und Datenschutz	30
4	Konzeptionierung	31
4.1	Anforderungen an das System	31
4.2	Konzept des Reflexionsbots	32
4.3	Konzeption der Szenarien	35
4.4	Technische Umsetzung	37
4.4.1	Frontend-Auswahl: Streamlit vs. Gradio	37
4.4.2	Implementierung	38
5	Ergebnisse	41
5.1	Deskriptiver Überblick	41
5.2	Illustration des Kategoriensystems an realen Entscheidungssituationen	44
5.3	Selbstauskunft und dokumentiertes Bearbeitungsverhalten	46
6	Diskussion	47
6.1	Beantwortung der Forschungsfragen	47
6.2	Einordnung in den Forschungsstand	50
6.3	Limitationen	52
6.4	Handlungsempfehlungen für den Einsatz in der Software-Engineering-Lehre .	55
6.5	Ausblick	56
7	Fazit	58
	Literatur	60
	Anhang	68
A.1	Kategoriensystem der qualitativen Inhaltsanalyse	68
A.2	Vollständige Kodierungstabelle	70
A.3	Häufigkeitsverteilung je Gruppe	73
A.4	Vollständige Szenariobeschreibungen	74
A.5	Eingesetzte Fragebögen	77
A.6	Deskriptive Statistik der Fragebogenitems	79

A.7 Systemnachricht des Reflexionsbots	84
A.8 Verwendete KI-Werkzeuge	86
A.9 Digitaler Anhang	87

Abkürzungsverzeichnis

API Application Programming Interface.

GPT Generative Pre-trained Transformer.

KI Künstliche Intelligenz.

LLM Large Language Model.

RLHF Reinforcement Learning from Human Feedback.

Token Einzelne Einheiten von Text, die von einem Sprachmodell verarbeitet werden.

Abbildungsverzeichnis

3.1	Konvergentes Parallel-Design des Mini-Experiments	20
3.2	Zusammensetzung der Stichprobe	22
3.3	Ablauf des Mini-Experiments mit Erhebungsinstrumenten	25
3.4	Zweistufiger Kodierprozess	28
3.5	Schema der Triangulation im Joint Display	29
4.1	Adaptive Tiefe der Bot-Antworten	34
4.2	Oberfläche des Reflexionsbots mit Beispielverlauf	36
4.3	Dreistufiger Aufgabenaufbau der Szenarien	37
4.4	Vereinfachte Architektur des Reflexionsbots	38
4.5	Aufbau der Nachrichtenliste und Streaming-Aufruf der Chat-Completions-API	40
5.1	Verteilung der Reflexionsstufen nach Gruppe (nur Fälle mit eindeutig studen- tischer Autorenschaft)	42
5.2	Vergleich zentraler Survey-Mittelwerte	44

Tabellenverzeichnis

2.1	Einschlägige Vergleichsstudien, gruppiert nach Art der Aufgabe	17
3.1	Zusammensetzung der Stichprobe (Prä-Survey, n=22)	22
3.2	Gegenüberstellung der beiden Versuchsbedingungen	24
3.3	Operationalisierung der quantitativ erhobenen Konstrukte	26
4.1	Funktionale und nicht-funktionale Anforderungen an den Reflexionsbot . . .	33
4.2	Vergleich von Streamlit und Gradio als Frontend-Framework	39
5.1	Autorenschaft der kodierten Bearbeitungen nach Gruppe	42
A.1	Kategoriensystem zur Kodierung der Reflexionsstufe	68
A.2	Kategoriensystem zur Kodierung der Autorenschaft	70
A.3	Vollständige Kodierung aller Fälle (Fall-ID, Gruppe, Person, Szenario, Reflexionsstufe, Autorenschaft, Anmerkung)	71
A.4	Häufigkeitsverteilung der Reflexionsstufen nach Gruppe (nur studentische Autorenschaft)	73
A.5	Post-Survey: Bewertung des jeweiligen Systems (n=20, 10 Reflection Bot, 10 Generic AI)	80
A.6	Prä-Survey: Vergleichbarkeit der Gruppen zu Studienbeginn (n=9 Reflection Bot, n=7 Generic AI, nur eindeutig Prä-Post-zuordenbare Personen)	80
A.7	Wissenstest zu Scrum und Prozessmodellen je Gruppe	81
A.8	Reflexionsverhalten: Selbstauskunft Prä und Post je Gruppe (n=9 Reflection Bot, n=7 Generic AI)	81
A.9	Selbsteingeschätztes Prozessverständnis: Veränderung Post minus Prä je Gruppe (Skala 1 bis 5)	82
A.10	Post-Survey: Kognitive Last (Skala 1 = very easy / very low bis 5 = very difficult / very high; n=10 Reflection Bot, n=10 Generic AI)	83
A.11	Verwendete KI-Werkzeuge. Alle Ausgaben wurden vom Autor geprüft und validiert.	86

1 Einleitung, Motivation und Zielsetzung

Die Digitalisierung hat in den vergangenen Jahrzehnten nahezu alle Lebensbereiche verändert, von der Arbeitswelt über die Kommunikation bis hin zu der Art, wie Wissen erworben und weitergegeben wird. Mit dem Aufkommen generativer Künstliche Intelligenz (KI) hat sich diese Entwicklung in den letzten Jahren noch einmal deutlich beschleunigt: Systeme, die auf natürlichsprachliche Eingaben reagieren und komplexe Texte, Programmcode oder Argumentationen erzeugen können, stehen heute praktisch jeder Person mit Internetzugang zur Verfügung, ohne dass technisches Vorwissen erforderlich wäre.

Auch die Hochschulbildung bleibt von dieser Entwicklung nicht unberührt, und kaum ein Bereich hat sich dabei so schnell verändert wie sie. Innerhalb weniger Jahre haben sich Systeme wie ChatGPT, Microsoft Copilot oder Gemini von einer Randerscheinung zu einem alltäglichen Begleiter für Millionen Studierender weltweit entwickelt [1], [2]. Auch an deutschen Hochschulen bestätigen aktuelle Studien eine bereits sehr hohe und weiter wachsende Nutzung generativer KI durch Studierende. Eine bundesweite Längsschnittbefragung von 4910 Studierenden an 395 Hochschulen weist einen Anstieg von 63,2 Prozent im Jahr 2023 auf 91,6 Prozent im Jahr 2025 aus [3], [4]. Damit rückt eine grundlegende Frage in den Vordergrund der hochschuldidaktischen Diskussion: Verändert generative KI, wie Studierende lernen, Probleme durchdringen und Entscheidungen treffen, und wenn ja, in welche Richtung [5]?

Hochschulen begegnen dieser Entwicklung bislang vor allem mit Regularien und Richtlinien zum verantwortungsvollen Umgang mit generativer KI [6], [7]. Wie ein KI-System selbst so gestaltet werden kann, dass es eigenständiges Denken fördert statt zu ersetzen, wird demgegenüber, insbesondere für offene Aufgaben ohne eindeutig richtige Lösung, noch seltener systematisch untersucht (vgl. Abschnitt 2.2). Diese gestalterische Frage lässt sich kaum abstrakt beantworten, sondern nur an konkreten Aufgabenstellungen untersuchen, die tatsächlich eine eigene Begründung und Abwägung verlangen und nicht mit einer einzigen richtigen Antwort auskommen.

Diese Arbeit setzt genau an dieser Frage an, und zwar im Software Engineering, einem Fachgebiet, in dem Studierende bereits im Studienalltag intensiv mit KI-gestützten Werkzeugen

arbeiten und in dem Prozessentscheidungen, wie im weiteren Verlauf dieses Kapitels ausgeführt wird, eine besonders geeignete Aufgabenklasse darstellen, um Reflexionstiefe überhaupt sichtbar zu machen.

Dieses Kapitel legt zunächst die Motivation für die vorliegende Arbeit dar (Abschnitt 1.1), leitet daraus die konkrete Problemstellung ab (Abschnitt 1.2) und formuliert abschließend die Zielsetzung sowie die daraus abgeleiteten Forschungsfragen (Abschnitt 1.3).

Die weitere Arbeit ist wie folgt aufgebaut: Kapitel 2 führt die technischen und didaktischen Grundlagen sowie den Stand der Technik ein und arbeitet die Forschungslücke heraus, an der diese Arbeit ansetzt. Kapitel 3 beschreibt das Untersuchungsdesign, die Datenerhebung und die Datenanalyse. Es steht bewusst vor der Konzeptionierung, weil es den Auswertungsrahmen festlegt, auf den sich die anschließenden Gestaltungsentscheidungen beziehen. Kapitel 4 dokumentiert die Konzeption und technische Umsetzung des Reflexionsbots. Kapitel 5 berichtet die Ergebnisse rein darstellend, bevor Kapitel 6 sie interpretiert, die Forschungsfragen beantwortet, die Befunde in den Forschungsstand einordnet und Limitationen sowie einen Ausblick darlegt. Kapitel 7 fasst die zentralen Erkenntnisse zusammen.

1.1 Motivation

Studierende nutzen generative KI-Systeme längst nicht mehr nur zur Informationssuche, sondern aktiv bei der Bearbeitung komplexer Aufgabenstellungen, auch im Rahmen von Lehrveranstaltungen [8], [9]. Diese Praxis wird kontrovers beurteilt. Generative KI kann Lernprozesse durch personalisierte Unterstützung bereichern [10], wird jedoch auch genutzt, um Aufgaben schnell zu erledigen, ohne sich inhaltlich mit den Lerninhalten auseinanderzusetzen [11], [12]. Eine Meta-Analyse zum kognitiven Einfluss generativer KI-Werkzeuge legt nahe, dass die Wirkung weniger davon abhängt, ob KI überhaupt eingesetzt wird, als davon, wie ein System gestaltet und in die Lehrveranstaltung eingebettet ist [13]. Hochschulen richten ihr Augenmerk deshalb zunehmend darauf, wie ein System gestaltet sein muss, damit es eigenständiges Denken fördert statt zu ersetzen [6].

Im Software Engineering stellt sich diese Frage mit besonderer Dringlichkeit, da Studierende hier bereits im Studienalltag intensiv mit KI-gestützten Werkzeugen arbeiten [14]. Erste Erfahrungsberichte zu KI-Tutoren in der Software-Engineering-Lehre lassen offen, ob solche Systeme zu einem tieferen Verständnis führen oder vor allem den Bearbeitungsaufwand reduzieren [15], [16]. Diesem Risiko soll unter anderem durch sokratisches Nachfragen anstelle direkter Lösungsvorschläge begegnet werden. Bislang wurde dieser Ansatz jedoch überwiegend für eng abgegrenzte Aufgaben, etwa einzelne Programmierfehler, untersucht [17].

Besonders deutlich wird dieses Spannungsfeld im Software-Prozessmanagement, wo sich Prozessentscheidungen selten mit einer einzigen richtigen Antwort lösen lassen, sondern eine Abwägung konkurrierender Ziele wie Geschwindigkeit, Dokumentationsaufwand und Compliance erfordern. Reflexion über die eigenen Entscheidungen gilt dabei, wie Befunde aus der Entscheidungsdidaktik in anderen Fachkontexten zeigen, als zentral für den Aufbau von Entscheidungskompetenz [18]. Ein generisches KI-System, das auf Wunsch eine vollständige, plausibel klingende Lösung liefert, kann diesen Reflexionsprozess umgehen, ohne dass dies für Studierende oder Lehrende sichtbar wird. Motiviert wird diese Arbeit deshalb von der Frage, ob ein KI-System, das gezielt für Reflexion statt für schnelle Antworten gestaltet ist, Studierende anders bei Prozessentscheidungen unterstützt als ein generisches System, mit dem sie ohnehin bereits im Studienalltag arbeiten.

1.2 Problemstellung

Für die didaktische Gestaltung generativer KI ist entscheidend, wie ein System auf Eingaben reagiert. Generische Systeme sind darauf ausgelegt, auf jede Eingabe eine möglichst hilfreiche, direkte Antwort zu liefern. Für einfache Wissensfragen ist das unproblematisch, für Aufgaben, die eine eigene Begründung und Abwägung verlangen, besteht jedoch die Gefahr, dass Studierende die gelieferte Antwort ungeprüft übernehmen, ohne die zugrunde liegenden Kompromisse selbst durchdacht zu haben [12].

Problematisch ist dabei weniger die Existenz einer Antwort an sich als vielmehr ihre Wirkung auf den Bearbeitungsprozess: Eine vollständige, kohärent formulierte Lösung wirkt überzeugend, unabhängig davon, ob sie durch eigenes Abwägen oder durch bloße Übernahme zustande gekommen ist. Für Lehrende ist im fertigen Leistungsprodukt kaum erkennbar, welcher der beiden Wege tatsächlich beschritten wurde. Diese Unsichtbarkeit macht es schwer, allein anhand der Ergebnisse zu beurteilen, ob ein KI-Einsatz die intendierten Lernprozesse tatsächlich unterstützt oder lediglich verdeckt, dass sie ausgeblieben sind.

Alternative Ansätze, die Antworten bewusst zurückhalten und stattdessen durch Rückfragen zur Auseinandersetzung anregen, existieren bereits, wurden jedoch bislang vor allem für eng abgegrenzte, klar strukturierte Aufgaben wie die Suche nach einem einzelnen Programmierfehler untersucht [17]. Ob ein solcher Ansatz auch in einem Themenfeld funktioniert, in dem es keine eindeutig richtige Lösung gibt, sondern mehrere vertretbare Optionen mit unterschiedlichen Konsequenzen abzuwägen sind, wie es für Prozessentscheidungen im Software-Prozessmanagement typisch ist, ist bislang kaum empirisch untersucht.

Es fehlt insbesondere an einem direkten, praktischen Vergleich zwischen einem generischen KI-System und einem dediziert für Reflexion gestalteten Gegenstück unter realen Bedingungen einer Lehrveranstaltung, der beide Systeme derselben Aufgabenstellung gegenüberstellt und die tatsächlich gezeigte Reflexionstiefe anhand der entstandenen Bearbeitungen und Chatverläufe nachvollzieht, statt sich allein auf die subjektive Einschätzung der Studierenden zu verlassen. Diese Arbeit setzt an dieser Lücke an.

1.3 Zielsetzung und Forschungsfragen

Erkenntnisleitendes Ziel dieser Arbeit ist es zu klären, ob und in welcher Hinsicht sich die didaktische Gestaltung eines KI-Systems darauf auswirkt, wie eigenständig und reflektiert Studierende anspruchsvolle Prozessentscheidungen im Software Engineering bearbeiten. Nicht die Frage, ob ein solches System technisch funktioniert, steht dabei im Vordergrund, sondern die Frage, ob ein gezielt auf Reflexion statt auf schnelle Antworten ausgelegtes System Studierende anders unterstützt als ein generisches KI-System, mit dem sie ohnehin bereits im Studienalltag arbeiten.

Daraus ergibt sich die zentrale Forschungsfrage dieser Arbeit:

Inwiefern unterscheidet sich ein didaktisch gestalteter Reflexionsbot von einem generischen KI-System darin, wie eigenständig und reflektiert Studierende Prozessentscheidungen im Software-Prozessmanagement bearbeiten?

Sie wird in drei Teilfragen (TF1 bis TF3) ausdifferenziert, die jeweils an ein konkret erhobenes Konstrukt gebunden sind:

- TF1** Wie unterscheidet sich zwischen beiden Systemen der Anteil an die KI ausgelagerter beziehungsweise ungeprüft übernommener Bearbeitungen? (*Operationalisierung: Autorenschaftskodierung der Bearbeitungen, vgl. Abschnitt 3.5.*)
- TF2** Welche Reflexionstiefe und welches selbsteingeschätzte Prozessverständnis zeigen beziehungsweise berichten Studierende beim Reflexionsbot im Vergleich zum generischen System? (*Operationalisierung: Reflexionsstufen nach Hatton und Smith sowie die Prä-Post-Items zu Beschreiben, Begründen und Abwägen, vgl. Abschnitte 2.1.5 und 3.4.*)
- TF3** Wie bewerten Studierende ihre eigene Kompetenzentwicklung sowie die Stärken und Grenzen beider Ansätze für ihr Lernen? (*Operationalisierung: Post-Survey-Items zu Kompetenzentwicklung, Erwartung und Nutzungspräferenz, vgl. Abschnitt 3.4.*)

Die Beantwortung dieser Fragen soll zeigen, ob und wie sich ein didaktisch gestalteter Reflexionsbot in den erhobenen Daten von einem generischen System unterscheidet, und welche Konsequenzen sich daraus für den gezielten KI-Einsatz in der Hochschullehre ergeben.

Als methodischer Weg zur Beantwortung dieser Fragen wurde ein Reflexionsbot konzipiert und umgesetzt, der Studierende durch sokratisches Fragen statt direkter Lösungen begleitet. Um eine Aufgabenstellung zu schaffen, an der sich Reflexionstiefe überhaupt sinnvoll unterscheiden lässt, wurden zwei realitätsnahe Fallszenarien aus dem Software-Prozessmanagement konzipiert, die jeweils mehrere Dilemma-Situationen mit widerstreitenden Zielen enthalten, etwa Patientensicherheit gegenüber Entwicklungsgeschwindigkeit oder Datenschutzanforderungen gegenüber Projektfortschritt. Details zur Gestaltung dieser Szenarien und des Reflexionsbots folgen in Kapitel 4.

Der Reflexionsbot wurde im Rahmen eines Mini-Experiments in der Lehrveranstaltung „Grundlagen des Software Engineering 1“ im ersten Fachsemester des Bachelorstudiengangs Software Engineering (B.Sc.) an der Hochschule Heilbronn eingesetzt und einer Vergleichsgruppe gegenübergestellt, die dieselben Szenarien mit einem generischen KI-System bearbeitete. Die Auswertung erfolgt als Mixed-Methods-Untersuchung: Quantitativ werden Prä- und Post-Survey-Daten zur wahrgenommenen Wirkung beider Systeme ausgewertet, qualitativ werden die tatsächlichen schriftlichen Bearbeitungen und Chatverläufe mittels strukturierender Inhaltsanalyse auf ihre Reflexionstiefe hin untersucht. Erst die Zusammenführung beider Perspektiven erlaubt es, wahrgenommene und tatsächlich gezeigte Reflexion zu unterscheiden, statt sich allein auf die Selbsteinschätzung der Studierenden zu verlassen.

1.4 Abgrenzung des Untersuchungsrahmens

Der Untersuchungsrahmen dieser Arbeit ist bewusst eng gefasst, um den Vergleich beider Systeme unter kontrollierten und im Rahmen einer Bachelorarbeit umsetzbaren Bedingungen durchführen zu können.

Gegenstand ist ein einzelner Anwendungsfall, nämlich Prozessentscheidungen im Software-Prozessmanagement, bearbeitet anhand von zwei eigens konstruierten Fallszenarien in einer Übungseinheit einer einzelnen Lehrveranstaltung. Diese Fokussierung erlaubt es, beide Gruppen mit identischen Aufgabenstellungen zu konfrontieren und die entstandenen Bearbeitungen vollständig auszuwerten, statt Vergleichbarkeit zugunsten einer breiteren Abdeckung aufzugeben.

Nicht Gegenstand der Arbeit sind daher die Übertragbarkeit auf andere Fachgebiete, Kohorten oder Hochschulen, ein längerfristiger Lernzuwachs über die Übungseinheit hinaus sowie

ein kontrollierter Vergleich verschiedener Sprachmodelle. Der Reflexionsbot wird mit einem einzigen Modell umgesetzt, während die Vergleichsgruppe ein frei gewähltes, in seiner Modellstufe nicht kontrolliertes Consumer-System nutzt (vgl. Abschnitt 3.4). Die Auswertung erfolgt angesichts der kleinen Stichprobe ausschließlich deskriptiv und explorativ. Auf inferenzstatistische Tests und Verallgemeinerungsansprüche wird bewusst verzichtet. Welche Konsequenzen sich daraus für die Reichweite der Ergebnisse ergeben, wird in Abschnitt 6.3 ausführlich dargelegt, mögliche Erweiterungen benennt der Ausblick in Abschnitt 6.5.

1.5 Beitrag der Arbeit

Aus dieser Zielsetzung ergeben sich vier Beiträge:

Ein dokumentierter, reproduzierbarer Reflexionsbot. Der entwickelte Bot ist nicht nur konzeptionell beschrieben, sondern mit eingesetztem Sprachmodell, Architektur und der Systemnachricht im vollständigen Wortlaut dokumentiert (Kapitel 4, Anhang A.7), sodass sich der didaktische Eingriff nachvollziehen und replizieren lässt.

Ein zweidimensionales Kategoriensystem. Die qualitative Auswertung erfasst neben der Reflexionsstufe nach Hatton und Smith die *Autorenschaft* der eingereichten Texte als eigene Dimension mit prüfbaren Indikatoren (Anhang A.1). Damit wird verhindert, dass die Analyse die Reflexionsfähigkeit des KI-Systems statt der Studierenden misst, ein Problem, das bei offenen Aufgaben mit KI-Zugang unmittelbar auftritt.

Empirische Evidenz für offene Prozessentscheidungen. Der Vergleich zwischen spezialisiertem und generischem System wird auf Aufgaben ohne eindeutig richtige Lösung übertragen, ein Kontext, für den ein solcher Vergleich bislang fehlt (Abschnitt 2.2).

Ein Beleg für den Wert der Triangulation. Der fallweise Abgleich von Selbstauskunft und dokumentiertem Bearbeitungsverhalten zeigt, dass beide auseinanderfallen können und eine Befragung allein die tatsächliche Auseinandersetzung nicht zuverlässig abbildet (Abschnitt 5.3).

2 Theoretische Grundlagen

Generative KI-Systeme sind in kurzer Zeit zu einem festen Bestandteil des Hochschulalltags geworden. Wie sie dabei das Lernen konkret beeinflussen, ob sie es fördern oder eher oberflächlich machen, ist eine der zentralen Fragen, die diese Arbeit antreiben. Im Folgenden werden relevante Forschungsarbeiten zu KI in der Lehre, zu dialogbasierten Tutorsystemen und zu Reflexions- und Scaffolding-Ansätzen vorgestellt.

2.1 Relevante Technologien und Konzepte

Der Fokus dieses Abschnitts liegt auf den technischen, konzeptionellen und didaktischen Grundlagen, die zum Verständnis des entwickelten Reflexionsbots notwendig sind. Dazu werden sowohl die zugrundeliegenden KI-Technologien als auch die didaktischen Prinzipien erläutert, die in der Gestaltung des Bots eine Rolle spielen.

2.1.1 Large Language Models (LLMs)

Large Language Models (LLMs) sind KI-Modelle, die auf der Verarbeitung und Generierung von natürlicher Sprache spezialisiert sind. Eingabetexte werden dazu zunächst in einzelne Token (Wörter oder Wortbestandteile) zerlegt und als numerische Vektoren (Embeddings) dargestellt, die semantische Beziehungen zwischen Token abbilden. Verarbeitet werden diese Vektoren durch die Transformer-Architektur [19], deren zentraler Bestandteil der Self-Attention-Mechanismus ist. Dieser gewichtet für jedes Token, wie stark die übrigen Token der Sequenz für dessen Interpretation relevant sind, und erfasst so auch weitreichende Abhängigkeiten im Kontext. Trainiert werden die Modelle auf großen Textmengen mit dem Ziel, das nächste Token in einer Sequenz möglichst präzise vorherzusagen. Aus dieser scheinbar einfachen Aufgabe entstehen durch massive Skalierung von Modellgröße und Trainingsdaten erstaunlich komplexe Fähigkeiten, darunter Übersetzen, Programmieren, Argumentieren und kreatives Schreiben [20], [21].

Bekannte Vertreter dieser Modellklasse sind GPT-3 und GPT-4 von OpenAI sowie LLaMA von Meta [22]. Für den Einsatz in dialogbasierten Systemen sind LLMs besonders geeignet,

da sie natürlichsprachliche Eingaben verarbeiten, kontextbezogen antworten und mehrstufige Gespräche stimmig fortführen können. Diese Eigenschaften sind eine funktionale Voraussetzung für den in dieser Arbeit entwickelten Reflexionsbot. Die technische Grundlage im engeren Sinne bildet dagegen das konkret eingesetzte Sprachmodell samt Systemarchitektur (vgl. Kapitel 4).

Dass ein Sprachmodell natürlichsprachliche Anweisungen befolgt und sich dialogorientiert verhält, ergibt sich allerdings nicht allein aus dem Vortraining auf großen Textmengen. Rein auf die Vorhersage des nächsten Token trainierte Modelle setzen Instruktionen häufig noch unzuverlässig um. Erst zwei nachgelagerte Trainingsschritte machen sie gezielt steuerbar: Beim instruktionsbasierten Finetuning wird ein Modell auf einer Vielzahl in natürlicher Sprache formulierter Aufgaben nachtrainiert, wodurch es Anweisungen auch für zuvor unge-sehene Aufgabenstellungen deutlich besser befolgt [23]. Beim anschließenden Reinforcement Learning from Human Feedback (RLHF) wird das Modellverhalten zusätzlich an menschlichen Präferenzurteilen ausgerichtet, sodass Antworten hilfreicher, konsistenter und stärker an den gegebenen Instruktionen orientiert ausfallen [24]. Diese beiden Schritte sind die Voraussetzung dafür, dass sich das Verhalten des eingesetzten Modells überhaupt über eine Systemnachricht (Abschnitt 4.2) in Richtung eines reflexionsfördernden Gesprächspartners lenken lässt.

Aufgrund dieser Fähigkeiten finden LLMs heute in einer Vielzahl von Bereichen Anwendung. Im Alltag werden sie vor allem über Chatbots und Assistenzsysteme genutzt, etwa zur Beantwortung von Fragen, zum Verfassen und Zusammenfassen von Texten oder zur Unterstützung bei der Softwareentwicklung durch Codegenerierung [22], [25]. In Unternehmen kommen LLMs unter anderem im Kundenservice, in der automatisierten Dokumentenanalyse und zunehmend als sogenannte agentenbasierte Systeme zum Einsatz, die mehrstufige Aufgaben eigenständig unter Einbindung externer Werkzeuge wie Websuche oder Datenbanken ausführen [26]. Für den hier verfolgten Einsatz als Reflexionsbot ist dabei weniger die Bandbreite der Anwendungsfelder relevant als die Frage, wie zuverlässig sich das Verhalten eines LLM über die Systemnachricht steuern lässt, ein Aspekt, der bei der Konzeption des Bots in Abschnitt 4.2 aufgegriffen wird.

2.1.2 Chat-Completions-API und Systemnachricht

Dialogbasierte Anwendungen greifen üblicherweise über eine Programmierschnittstelle (API) auf ein Large Language Model (LLM) zu. Ein verbreitetes Beispiel ist die Chat-Completions-API von OpenAI [27], über die Anfragen über das HTTP-Protokoll an das Modell gesendet werden. Eine Anfrage besteht aus einer geordneten Liste von Nachrichten, von denen jede einer der Rollen `system`, `user` oder `assistant` zugeordnet ist [27].

Die Rolle **system** enthält die sogenannte Systemnachricht, die das Verhalten des Modells grundlegend steuert und festlegt, wie es auf Eingaben reagieren soll. Die Rolle **user** enthält die jeweilige Nutzereingabe, während **assistant** frühere Modellantworten abbildet, sodass der Gesprächsverlauf kontextuell erhalten bleibt. Der Begriff der Systemnachricht ist für die vorliegende Arbeit zentral, da über sie die didaktische Ausrichtung des Bots festgelegt wird. Die konkrete Wahl der Schnittstelle und die Ausgestaltung der Systemnachricht werden in Kapitel 4 beschrieben (Wortlaut siehe Anhang A.7).

2.1.3 Prompt Engineering

Unter Prompt Engineering wird die systematische Gestaltung von Eingaben (Prompts) verstanden, mit dem Ziel, das Verhalten eines LLM gezielt zu steuern, ohne dessen Parameter zu verändern [28]. Da LLMs stark davon abhängen, wie eine Aufgabe formuliert, kontextualisiert und strukturiert wird, kann bereits die Wahl von Formulierung, Reihenfolge und Beispielen die Qualität und Richtung der Modellantwort erheblich beeinflussen [29].

Eine grundlegende Unterscheidung betrifft Zero-Shot- und Few-Shot-Prompting: Bei Zero-Shot-Prompting werden keine Beispiele mitgegeben und das Modell antwortet allein auf Basis der Instruktion, wobei sich diese Fähigkeit insbesondere durch instruktionsbasiertes Finetuning gezielt verbessern lässt [23]. Ein Few-Shot-Prompt enthält dagegen zusätzlich einige Beispiel-Interaktionen, an denen sich das Modell orientieren kann [20]. Für komplexere Aufgaben hat sich zudem das sogenannte Chain-of-Thought-Prompting etabliert, bei dem das Modell angeleitet wird, seine Antwort in nachvollziehbaren Zwischenschritten her-zuleiten, was bei mehrstufigen Denkaufgaben die Antwortqualität verbessern kann [30]. Der Nutzen fällt allerdings je nach Aufgabe und Modell unterschiedlich aus und gilt nicht uneingeschränkt.

Neben einzelnen Techniken haben sich strukturierte Prompt-Muster (*Prompt Patterns*) etabliert, die wiederkehrende Formulierungsstrategien wie Rollenzuweisungen, Kontextvorgaben oder Ausgabeformat-Vorgaben katalogisieren und so die systematische Konstruktion von Prompts erleichtern [31].

Für den in dieser Arbeit entwickelten Reflexionsbot ist insbesondere die Gestaltung der Systemnachricht (vgl. Abschnitt 4.2) von zentraler Bedeutung: Durch eine gezielte Rollen- und Verhaltensvorgabe wird das Modell angeleitet, keine direkten Lösungen zu liefern, sondern durch gezielte Rückfragen zur Reflexion anzuregen. Konkret kombiniert die Systemnachricht des Reflexionsbots (Anhang A.7) mehrere der genannten Techniken: eine Zero-Shot-Instruktion, die Rolle und Verhalten ohne zusätzliche Modellanpassung vorgibt, ein

Prompt-Pattern der Rollen- und Verhaltenszuweisung sowie einige Few-Shot-artige Beispielreaktionen, die die vier Stufen der adaptiven Tiefe (vgl. Abschnitt 4.2) illustrieren. Chain-of-Thought-Prompting im engeren Sinne wird dagegen nicht eingesetzt, da nicht die Herleitung einer Modelllösung, sondern die Rückfrage an die Studierenden im Vordergrund steht. Prompt Engineering bildet damit das methodische Werkzeug, mit dem die didaktische Zielsetzung des Bots technisch umgesetzt wird.

Die Steuerung über die Systemnachricht ist allerdings nicht beliebig zuverlässig, was für einen Reflexionsbot besonders ins Gewicht fällt, dessen didaktische Idee gerade darauf beruht, keine direkten Lösungen zu liefern. LLMs reagieren empfindlich auf kleine Änderungen in Formulierung, Reihenfolge oder Kontext, sodass bereits geringfügig veränderte Eingaben die Qualität und Richtung der Antwort spürbar verschieben können [29]. Da die Antwortgenerierung zudem probabilistisch erfolgt (vgl. Abschnitt 2.1), kann dieselbe Eingabe zu unterschiedlichen Antworten führen. Eine Systemnachricht legt das Verhalten daher nur tendenziell, nicht deterministisch fest. Gezielte Nutzereingaben können das Modell so dazu bringen, die im Systemprompt verankerte Rückfrage-Strategie zu unterlaufen und doch eine direkte Lösung auszugeben. Robuste, manipulationsresistente Prompt-Muster [31] können solche Umgehungen erschweren, aber nicht vollständig ausschließen. Wie Studierende diese Grenze im vorliegenden Mini-Experiment tatsächlich ausnutzten, zeigt die Kodierung der Chatverläufe in Anhang A.2; die daraus folgenden Konsequenzen für die Gestaltung werden in Abschnitt 6.4 gezogen.

Neben der Steuerbarkeit betrifft eine weitere Grenze die inhaltliche Zuverlässigkeit: LLMs können plausibel formulierte, aber sachlich falsche Aussagen erzeugen (Halluzinationen) [32]. Für einen Reflexionsbot, der in seinen Rückfragen auf konkrete regulatorische Randbedingungen der Szenarien (etwa MDR oder FERPA) Bezug nimmt, ist dies eine relevante Einschränkung, da sachlich falsche Rückfragen die Reflexion in eine falsche Richtung lenken könnten.

2.1.4 Scaffolding und Sokratisches Fragen

Scaffolding beschreibt eine didaktische Unterstützungsform, bei der Lernenden zunächst gezielte Hilfestellungen angeboten werden, die mit wachsender Kompetenz schrittweise zurückgenommen werden [33], [34]. Ziel ist es, Lernende nicht bei jeder Aufgabe vollständig anzuleiten, sondern ihnen genau so viel Unterstützung zu geben, wie sie zur eigenständigen Bewältigung benötigen, sodass Verantwortung sukzessive auf die Lernenden übergeht. Im Kontext von Entscheidungsprozessen zeigt sich zudem, dass die Kombination von Entscheidungsstrategien mit Reflexion, sowohl über das Vorgehen anderer als auch, im Sinne

selbstregulierten Lernens, über das eigene, die Entscheidungskompetenz von Lernenden verbessert. In der Variante mit selbstreguliertem Lernen waren die Effekte auch zwei Monate später noch nachweisbar [18].

Eine konkrete Umsetzungsform von Scaffolding im Dialog ist das sokratische Fragen. Anstatt Wissen oder Lösungen direkt zu vermitteln, stellt eine Lehrperson oder ein System gezielte Rückfragen, die Lernende dazu anregen, ihre eigenen Annahmen zu hinterfragen, Begründungen zu liefern und Konsequenzen ihrer Entscheidungen selbst zu durchdenken. Eine unterrichtsbezogene Analyse von Fragestrategien identifiziert sokratisches Fragen als eine von vier Herangehensweisen, mit denen Lehrende das Denken von Lernenden stützen, und beschreibt es als Aufforderung, das eigene Denken zu artikulieren, statt eine Antwort zu erhalten [35]. Auf KI-gestützte Systeme übertragen wurde dieses Prinzip unter anderem im Kontext der Programmierausbildung [17]. Übertragen auf KI-gestützte Dialogsysteme bedeutet dies, dass ein Modell nicht als Antwortmaschine, sondern als fragenstellendes Gegenüber fungiert, das Lernprozesse anstößt, ohne sie durch fertige Lösungen abzukürzen.

Für den in dieser Arbeit entwickelten Reflexionsbot bilden Scaffolding und sokratisches Fragen die didaktische Grundlage: Die im Systemprompt verankerte Regel, Unterstützung graduell an die Qualität der studentischen Argumentation anzupassen, überträgt das Scaffolding-Prinzip technisch in den Reflexionsbot, während die Vorgabe, keine Lösungen zu liefern, sondern Rückfragen zu stellen, dem Prinzip des sokratischen Fragens folgt.

2.1.5 Reflexion und Reflexionsstufenmodelle

Reflexion wird in dieser Arbeit im Anschluss an Hatton und Smith als bewusstes Nachdenken über das eigene Handeln mit dem Ziel seiner Verbesserung verstanden [36]. Sie unterscheidet sich damit von der bloßen Beschreibung oder Wiedergabe eines Sachverhalts, die für sich genommen noch keine Reflexion darstellt. Für die vorliegende Arbeit ist dabei entscheidend, dass sich Reflexion nicht nur selbst einschätzen, sondern auch anhand von Texten und Gesprächsverläufen von außen beurteilen lässt: Nicht jede Aussage, die inhaltlich richtig ist, zeugt bereits von reflektiertem Denken, und nicht jede subjektiv als reflektiert empfundene Bearbeitung zeigt sich auch im entstandenen Text als solche.

Um diese Beurteilung nachvollziehbar und wiederholbar zu machen, wird in dieser Arbeit das Stufenmodell von Hatton und Smith [36] verwendet, das ursprünglich zur Bewertung schriftlicher Reflexionen in der Lehramtsausbildung entwickelt wurde. Es unterscheidet vier aufeinander aufbauende Stufen: *deskriptives Schreiben* (Descriptive Writing), bei dem eine Entscheidung oder ein Sachverhalt lediglich wiedergegeben, aber nicht begründet wird; *deskriptive Reflexion* (Descriptive Reflection), bei der eine Entscheidung anhand eines einzelnen

Kriteriums begründet wird; *dialogische Reflexion* (Dialogic Reflection), bei der mehrere Perspektiven oder Optionen explizit gegeneinander abgewogen werden; und *kritische Reflexion* (Critical Reflection), bei der die Entscheidung zusätzlich in einen größeren regulatorischen, ethischen oder organisationalen Kontext eingeordnet wird. Der Vorteil dieses Modells liegt darin, dass es Reflexion nicht als Alles-oder-Nichts-Kategorie behandelt, sondern als graduelles Konstrukt, das sich unmittelbar am Text festmachen lässt, ohne auf die Selbstauskunft der schreibenden Person angewiesen zu sein.

Für den Reflexionsbot ist dieses Modell in zweifacher Hinsicht zentral: Zum einen bildet die adaptive Tiefe seiner Rückfragen (vgl. Abschnitt 4.2) die Grundannahme des Modells technisch nach, indem sie gezielt auf die jeweils nächsthöhere Stufe hinlenkt, statt pauschal nachzufragen. Zum anderen dient das Modell als deduktives Kategoriensystem für die spätere qualitative Inhaltsanalyse der entstandenen Bearbeitungen (Abschnitt 3.5), ergänzt um eine zusätzliche Stufe zur Erfassung fehlender Eigenreflexion (Vermeidung, Aufgabenverweigerung). Ob ein Text von der KI stammt, wird davon getrennt über die Dimension Autorenschaft erfasst (vgl. Anhang A.1).

2.1.6 Mixed-Methods-Forschungsdesign

Da weder rein quantitative noch rein qualitative Verfahren allein ausreichen, um sowohl die wahrgenommene als auch die tatsächlich gezeigte Wirkung eines Lernwerkzeugs zu erfassen, kombinieren Mixed-Methods-Designs beide Herangehensweisen gezielt miteinander [37], [38]. Quantitative Befragungsdaten liefern ein breites, über viele Personen vergleichbares Bild subjektiv wahrgenommener Effekte, sind jedoch anfällig für Verzerrungen durch soziale Erwünschtheit oder eine ungenaue Selbsteinschätzung [39]. Qualitative Verfahren wie die Inhaltsanalyse erlauben demgegenüber eine differenzierte, am tatsächlichen Material ansetzende Beurteilung, sind dafür aber aufwendiger und schwerer verallgemeinerbar. Beim sogenannten konvergenten Parallel-Design werden beide Datenarten unabhängig voneinander erhoben und erst nachträglich zusammengeführt, um Übereinstimmungen und Widersprüche zwischen wahrgenommener und tatsächlicher Wirkung sichtbar zu machen [37], [38]. Creswell und Plano Clark bezeichnen dieses Design in der dritten Auflage nur noch als *convergent design* und grenzen es ausdrücklich vom Triangulationsbegriff der qualitativen Forschung ab [38]. Die vorliegende Arbeit folgt in der deutschen Begriffsverwendung Kuckartz, versteht das Zusammenführen aber im Sinne beider Quellen als Vergleich der beiden Ergebnisstränge und nicht als wechselseitige Absicherung eines einzelnen Befundes.

Für die vorliegende Arbeit ist dieser Abgleich von besonderer Bedeutung, weil sich wahrgenommene und tatsächlich gezeigte Reflexion grundsätzlich unterscheiden können: Eine Selbsteinschätzung im Fragebogen bildet nicht zwangsläufig ab, wie tief eine Bearbeitung

tatsächlich ausfällt. Ein rein quantitatives Vorgehen könnte einen solchen Unterschied nicht aufdecken. Das Mixed-Methods-Design schafft daher erst die methodische Voraussetzung, wahrgenommene und dokumentierte Reflexion gegeneinander zu prüfen. Die konkrete Umsetzung dieses Designs für das vorliegende Mini-Experiment wird in Abschnitt 3.1 beschrieben.

2.2 Stand der Technik

Der Einsatz von KI in der Hochschullehre ist kein Randthema mehr. Im Folgenden werden zentrale Arbeiten und bestehende Ansätze vorgestellt, die für diese Arbeit relevant sind, von generischen KI-Systemen bis hin zu spezialisierten Reflexions- und Scaffolding-Werkzeugen.

2.2.1 Generative KI in der Hochschullehre

Generative KI-Systeme wie ChatGPT haben in kurzer Zeit einen breiten Einzug in die Hochschullehre gehalten [1]. Sie bieten Potenziale für individualisiertes Lernen, direkte Rückmeldungen und eine Anpassung an den jeweiligen Lernstand [10]. Gleichzeitig stellen sie die akademische Integrität vor ernsthafte Fragen, da Studierende Antworten einfach übernehmen könnten, ohne eigenes Nachdenken [8], [12].

In der Literatur wird argumentiert, dass ein unkontrollierter Einsatz von GenAI oberflächliches Lernen begünstigt, wenn keine didaktische Rahmung vorhanden ist [5], [6], [7]. Eine Befragung von Studierenden in Deutschland zeigt ein zwiespältiges Bild: Die Mehrheit nutzt KI-Werkzeuge im Studium, steht ihnen zugleich aber kritisch gegenüber, insbesondere wegen ihrer Fehleranfälligkeit und des Risikos, von ihnen abhängig zu werden. Unterstützung durch die eigene Hochschule erleben die Befragten dabei nur selten; Schulungsangebote oder eine Integration in die Lehre werden seltener berichtet als bloße Nutzungsrichtlinien [4]. Eine qualitative Analyse von Anwendungsfällen an deutschsprachigen Hochschulen weist in dieselbe Richtung, dass der Einsatz bislang überwiegend von Einzelinitiativen getragen wird und die Bedingungen für eine gelingende didaktische Einbettung erst ansatzweise geklärt sind [40]. Daraus ergibt sich der Bedarf an KI-Systemen, die nicht einfach Lösungen liefern, sondern Lernprozesse aktiv begleiten [11]. Metaanalysen bestätigen insgesamt einen moderat positiven Effekt generativer KI auf Lernergebnisse [41]. Eine Metaanalyse zu Chatbots im Lernkontext, die 28 Berichte mit 31 Effektstärken auswertet, ermittelt einen mittleren Effekt von $g = 0,48$, findet zugleich aber, dass die höchsten Effektstärken dort auftreten, wo die Vergleichsgruppe gar keine Unterstützung erhielt, wo die Intervention nur eine einzige Sitzung umfasste und wo die Chatbots aufgabenfokussiert arbeiteten [42]. Dieses Moderatormuster

verweist eher auf Designartefakte der Untersuchungsanlage als auf tiefere Lernwirkungen und mahnt zur Vorsicht bei der Interpretation kurzer Einzelinterventionen, wie sie auch der vorliegenden Arbeit zugrunde liegt. Die noch junge Forschungslage ist insgesamt konzeptionell uneinheitlich [43].

2.2.2 Chatbots und KI-Tutoren im Bildungsbereich

Dialogbasierte KI-Systeme werden zunehmend als tutorielle Begleitung genutzt [2]. Eine Übersicht zu Chatbots in der Programmierlehre zeigt, dass solche Systeme kurze Erklärungen, prozessnahe Hilfen und schrittweise Anleitungen bereitstellen können [25]. Ein aktueller systematischer Überblick ordnet Chatbots, generative Werkzeuge und Tutorsysteme in der Programmierausbildung ein [44]. Gerade im Bereich Software Engineering gibt es erste Erfahrungsberichte, die KI-Tutoren als ergänzende Lernunterstützung erprobt haben [14], [15], [16], [45].

Diese Ansätze verbindet, dass KI nicht als reine Antwortmaschine verstanden wird, sondern als lernunterstützendes Dialogsystem. Der Unterschied liegt im Grad der Spezialisierung: Generische Systeme sind zwar breit einsetzbar, liefern aber oft direkte Antworten statt gezielte Lernimpulse. Spezialisierte Systeme greifen stärker in die Gesprächsstruktur ein und lenken auf Begründung, Abwägung und Perspektivwechsel. Erste Analysen des tatsächlichen Interaktionsverlaufs deuten zudem darauf hin, dass weniger das System allein als die Struktur der Studierenden-Chatbot-Interaktion mit dem Lerngewinn zusammenhängt [46].

2.2.3 Reflexion und Scaffolding-Ansätze

Aufbauend auf dem Scaffolding-Prinzip und dem sokratischen Fragen (vgl. Abschnitt 2.1.4) zeigen Prompt-Sammlungen wie „Reflect Me“, wie textgenerative KI didaktisch als Reflexionsanstoß gerahmt werden kann [47]. Dabei handelt es sich um ein Praxis-Workbook mit vorformulierten Reflexionsprompts, nicht um ein empirisch evaluiertes System. Eine Wirksamkeitsprüfung steht dort ebenso aus wie eine Antwort auf die Frage, wann solche Impulse tatsächlich zu tieferer Reflexion führen und welche Fragetypen dabei wirksam sind. Genau an dieser Stelle setzt die vorliegende Arbeit an, indem sie ein kontextspezifisches Reflexionswerkzeug nicht nur entwirft, sondern im Lehrbetrieb gegen eine Vergleichsbedingung erprobt.

Mehrere aktuelle Studien vergleichen inzwischen gezielt gestaltete, zurückhaltende Lernsysteme mit generischen, direkt antwortenden KI-Systemen. In einem dreiarmligen randomisierten Experiment in der Programmierausbildung wurde ein scaffoldender Tutor, der vollständige Lösungen bewusst zurückhält, gegen ein unbeschränktes ChatGPT und eine Kontrollgruppe ohne KI verglichen. Beide KI-Bedingungen steigerten zwar die unmittelbare Aufgabenleistung, die Ergebnisse deuten aber auf eine Entkopplung von kurzfristiger Leistung und tatsächlichem Lernen hin [48]. Ein weiterer Beitrag derselben Arbeitsgruppe stellt einen kontextbewussten KI-Tutor einem generischen KI-Chatbot gegenüber [49]. Für die Hochschullehre liegt mit der Studie von Xi et al. der bislang engste Vergleich zur vorliegenden

Arbeit vor. Über sechs Wochen bearbeiteten 94 zufällig zugeteilte Studierende ein gemeinsames Forschungsdesign, wobei die eine Gruppe einen sokratisch fragenden, die andere einen bewusst direkt antwortenden Dialogagenten nutzte. Die sokratische Bedingung schnitt sowohl in der fachlichen Leistung als auch im reflexiven Denken besser ab, insbesondere in den Dimensionen *reflection* und *critical reflection* [50]. Ergänzend erhebt eine Befragung von 230 Studierenden mit anschließenden Interviews, wie sokratisches KI-Tutoring im Vergleich zu menschlichen Tutoren *wahrgenommen* wird; eine Aufgabenbearbeitung wurde dort nicht untersucht [51]. Im schulischen Bereich vergleicht ein randomisiertes kontrolliertes Experiment mit 90 Lernenden der zehnten Klasse eine KI-gestützte Argumentationsübung mit derselben Übung ohne KI sowie mit einer Kontrollgruppe. Die KI-Gruppe verbesserte sich stärker in wissenschaftlicher Argumentation und kritischem Denken, während sich für die metakognitive Selbstregulation kein Effekt zeigte; die Arbeit liegt bislang nur als Preprint vor [52].

Zugleich benennt die Literatur Grenzen solcher Ansätze: Scaffolding-Tutoren zeigen eine Lücke zwischen Benchmark-Leistung und realem Einsatzverhalten [53], müheloser KI-Einsatz kann eine „Illusion des Lernens“ erzeugen, obwohl gerade die produktive Anstrengung den Lernwert ausmacht [54], und die ungeprüfte Übernahme von Chatbot-Antworten lässt sich als eigenständiges Analyseproblem der Overreliance fassen [55]. Auch für anspruchsvollere, offenere Aufgaben wie mathematische Beweise zeigt sich, dass generative KI allein nicht ausreicht, sondern eine gezielte didaktische Unterstützung erfordert [56].

2.2.4 Vergleich und Einordnung

Die drei vorangegangenen Abschnitte lassen sich zu drei Forschungssträngen bündeln. Arbeiten zu generativer KI in der Lehre begründen den Bedarf an didaktisch kontrollierter Nutzung, Arbeiten zu Chatbots und KI-Tutoren zeigen, dass dialogische Systeme Lernende überhaupt begleiten können, und Arbeiten zu Reflexion und Scaffolding liefern das didaktische Prinzip, nach dem ein solches System nicht lösen, sondern anregen soll. Für die Verortung der vorliegenden Arbeit ist jedoch weniger diese thematische Gliederung entscheidend als die Frage, in welchen Untersuchungskontexten der Vergleich zwischen zurückhaltenden und direkt antwortenden Systemen bislang durchgeführt wurde. Tabelle 2.1 stellt die einschlägigen Arbeiten gegenüber.

Tabelle 2.1: Einschlägige Vergleichsstudien, gruppiert nach Art der Aufgabe

Quelle	Domäne	Design und Vergleichsbedingung	Zentrales Ergebnis
<i>Aufgaben mit eindeutig richtiger Lösung</i>			
[17]	Programmierung (Debugging)	Sokratischer Fragebaum, Systemevaluation	Sokratisches Nachfragen stützt eigenständige Fehlersuche
[48]	Programmierausbildung	Randomisiert, drei Arme: scaffoldender Tutor, freies ChatGPT, ohne KI	Beide KI-Arme steigern die unmittelbare Leistung; Hinweise auf Entkopplung von Leistung und Lernen
[49]	Programmierausbildung	Kontextbewusster KI-Tutor gegenüber generischem Chatbot	Vergleich spezialisierter und generischer Systeme
<i>Offene Aufgaben ohne eindeutig richtige Lösung</i>			
[50]	Hochschullehre (Forschungsmethodik)	Randomisiert, n=94, sechs Wochen: sokratischer gegenüber eigens gebautem, direkt antwortendem Agenten	Sokratische Gruppe besser bei Leistung und reflexivem Denken
[52]	Schulunterricht (Naturwissenschaften)	Randomisiert, n=90, drei Arme: Argumentation mit KI, ohne KI, Kontrolle	KI-Gruppe besser bei Argumentation und kritischem Denken; Selbstregulation ohne Effekt
[47]	domänenoffen	Prompt-Workbook ohne Wirksamkeitsprüfung	Zeigt die didaktische Rahmung, ohne sie zu evaluieren
<i>Ohne eigene Aufgabenbearbeitung</i>			
[51]	Hochschullehre (fächerübergreifend)	Befragung, n=230, plus 23 Interviews	Studentische Wahrnehmung von ChatGPT gegenüber menschlichen Tutoren
<i>Vorliegende Arbeit</i>			
–	Software-Prozessmanagement	Mini-Experiment: Reflexionsbot gegenüber frei gewähltem Consumer-System	Offene Prozessentscheidungen, zusätzlich Erhebung der Autorenschaft

Die Gruppierung danach, ob die untersuchten Aufgaben eine objektiv richtige Lösung besitzen, beruht auf der in der jeweiligen Arbeit berichteten Aufgabenstellung und ist eine Einordnung des Verfassers.

Aus der Übersicht ergibt sich ein differenzierteres Bild, als die bloße Neuheit des Themas nahelegt. Ein Teil der Arbeiten prüft zurückhaltende gegen direkt antwortende Systeme in Domänen mit eindeutig richtiger Lösung, vor allem in der Programmierausbildung. Das ist naheliegend, weil eine eindeutige Lösung ein einfaches Erfolgsmaß erlaubt. Zwei Arbeiten untersuchen jedoch bereits offene Aufgaben. Kao et al. [52] setzen sokratische KI in der naturwissenschaftlichen Argumentation ein und finden Vorteile gegenüber Unterricht ohne KI. Xi et al. [50] vergleichen über sechs Wochen einen sokratischen mit einem direkt antwortenden Dialogagenten bei der Erstellung eines Forschungsdesigns und berichten Vorteile der sokratischen Bedingung sowohl in der Leistung als auch im reflexiven Denken. Die Annahme, ein solcher Vergleich sei bei offenen Aufgaben bislang gar nicht angestellt worden, wäre demnach unzutreffend.

Drei Unterschiede zur vorliegenden Arbeit bleiben gleichwohl bestehen. Erstens ist die Vergleichsbedingung eine andere. Xi et al. stellen ihrem System einen *eigens für die Studie gebauten* nicht-sokratischen Agenten gegenüber und weisen ausdrücklich darauf hin, dass dieser nicht für nicht-sokratische Systeme im Allgemeinen steht. Die vorliegende Arbeit vergleicht dagegen mit den frei gewählten Consumer-Systemen, die Studierende ohnehin verwenden, und misst damit den Abstand zur tatsächlichen Alltagspraxis statt zu einer Laborbedingung. Zweitens erfasst keine der genannten Arbeiten, *ob die eingereichten Texte überhaupt von den Studierenden stammen*. Genau diese Dimension der Autorenschaft erweist sich in der vorliegenden Untersuchung als der Befund mit der größten praktischen Tragweite (vgl. Kapitel 5). Drittens unterscheidet sich der Umfang der Intervention erheblich: sechs Wochen mit wöchentlichen Sitzungen bei Xi et al. gegenüber einer einzelnen Übungseinheit hier, was bei der späteren Einordnung der Befunde zu berücksichtigen ist (vgl. Abschnitt 6.2).

Für das Software-Prozessmanagement liegt zudem bislang keine vergleichende Untersuchung vor. Ebenso bleibt offen, unter welchen Bedingungen KI-gestützte Dialoge wirklich zu tieferer Reflexion führen und welche Fragetypen dabei am meisten helfen. Genau hier setzt diese Arbeit an. Der entwickelte Reflexionsbot ist technisch schlank, aber didaktisch gezielt: Er liefert keine Lösungen, sondern stellt Rückfragen und lenkt Studierende dazu, ihre Prozessentscheidungen selbst zu begründen.

3 Methodik

Um die in Abschnitt 1.3 formulierte Forschungsfrage empirisch zu beantworten, bedarf es einer methodischen Vorgehensweise, die sowohl die wahrgenommene als auch die tatsächlich gezeigte Reflexion der Studierenden erfasst. Empirische Untersuchungen in der Software-Engineering-Forschung stützen sich dafür typischerweise auf eine Kombination aus Experimenten, Fallstudien und Befragungen [57]. Die vorliegende Arbeit folgt diesem Grundgedanken, indem sie ein Mini-Experiment im Rahmen einer regulären Lehrveranstaltung mit einer Befragung sowie einer qualitativen Auswertung der entstandenen Bearbeitungen verbindet.

Dieses Kapitel gliedert sich entsprechend in sieben Abschnitte: Zunächst wird das übergeordnete Forschungsdesign erläutert (Abschnitt 3.1), gefolgt von der Datenerhebung (Abschnitt 3.2) und der Stichprobe (Abschnitt 3.3). Anschließend werden der Aufbau des Mini-Experiments sowie der eingesetzten Fragebögen im Detail dargestellt (Abschnitt 3.4) und das Verfahren der Datenanalyse beschrieben (Abschnitt 3.5), bevor abschließend die Gütekriterien (Abschnitt 3.6) sowie forschungsethische und datenschutzrechtliche Aspekte (Abschnitt 3.7) eingeordnet werden.

3.1 Forschungsdesign

Die vorliegende Arbeit verfolgt einen explorativen Mixed-Methods-Ansatz [37], um den in Abschnitt 1.3 formulierten Vergleich zwischen dem Reflexionsbot und einem generischen KI-System empirisch zu untersuchen. Qualitative und quantitative Daten werden dabei nicht nacheinander, sondern parallel erhoben und erst in der Auswertung zusammengeführt (konvergentes Parallel-Design, bei Creswell und Plano Clark *convergent design*) [37], [38]: Die quantitativen Fragebogendaten liefern ein breites, aber oberflächliches Bild der wahrgenommenen Wirkung beider Systeme, während die qualitative Inhaltsanalyse der tatsächlichen Bearbeitungen zeigt, wie tief die Studierenden sich inhaltlich mit den Prozessentscheidungen auseinandergesetzt haben. Erst die Kombination beider Perspektiven erlaubt es, wahrgenommene und tatsächliche Reflexionstiefe zu unterscheiden. Abbildung 3.1 veranschaulicht diesen Ablauf.




Abbildung 3.1: Konvergentes Parallel-Design des Mini-Experiments

3.2 Datenerhebung

Die Datenerhebung erfolgte in drei aufeinanderfolgenden Phasen, die alle im Rahmen derselben Übungseinheit der Lehrveranstaltung „Grundlagen des Software Engineering 1“ stattfanden.

In der ersten Phase füllten alle Studierenden vor Beginn der eigentlichen Aufgabenbearbeitung einen Prä-Survey aus. Dieser wurde als freiwilliges, pseudonymisiertes Online-Formular (persönlicher, selbst gewählter Code statt Klarname) bereitgestellt und erfasste unter anderem die Vorerfahrung mit KI-Systemen sowie das selbsteingeschätzte Reflexionsverhalten (vgl. Abschnitt 3.4).

In der zweiten Phase bearbeiteten die Studierenden die beiden Prozessszenarien mit dem ihrer Gruppe zugewiesenen KI-System. Dabei entstanden zwei Arten von Rohdaten: zum einen die schriftlichen Bearbeitungsdokumente, in denen die Studierenden ihre Entscheidungen und Begründungen zu den Dilemma-Situationen festhielten, zum anderen die Chatverläufe (Interaktionsprotokolle) mit dem jeweiligen KI-System. Beide Datenquellen bildeten gemeinsam die Grundlage für die spätere qualitative Inhaltsanalyse (vgl. Abschnitt 3.5).

In der dritten Phase füllten die Studierenden im direkten Anschluss an die Bearbeitung einen Post-Survey aus, der spiegelbildlich zum Prä-Survey aufgebaut war und die Erfahrung mit dem jeweils genutzten System sowie die wahrgenommene Unterstützung eigenständigen Denkens erfasste.

Ein persönlicher, selbst gewählter Code erlaubte es, die Angaben aus Prä- und Post-Survey einer Person zuzuordnen, ohne dass Klarnamen erhoben wurden (Pseudonymisierung). Da dieser Code teilweise auch als Pseudonym für den Upload der Bearbeitungsdokumente verwendet wurde, konnten die quantitativen Survey-Daten grundsätzlich auch mit den qualitativ kodierten Fällen derselben Person verknüpft werden (vgl. Abschnitt 3.5).

3.3 Stichprobe

Die Stichprobe besteht aus Studierenden des Studiengangs Software Engineering (Bachelor of Science) an der Hochschule Heilbronn in Sontheim, die im Rahmen der regulären Übung zur Lehrveranstaltung „Grundlagen des Software Engineering 1“ an dem Mini-Experiment teilnahmen. Diese Veranstaltung ist im ersten Fachsemester des Studiengangs verortet, was die im Folgenden beschriebene Zusammensetzung der Stichprobe (überwiegend Erstsemester mit noch geringer einschlägiger Vorerfahrung) erklärt. Die Teilnahme war freiwillig, die Zuteilung zur Reflexionsbot- oder zur Generic-AI-Gruppe erfolgte durch die Übungsleitung vor Beginn der Bearbeitung.

Vor der Bearbeitung wurden alle Studierenden im Prä-Survey über Zweck und Ablauf des Mini-Experiments informiert und um ihre freiwillige Einwilligung zur Teilnahme sowie um die Bestätigung der Volljährigkeit gebeten. Eine Person verneinte die Einwilligungsfrage ausdrücklich, füllte im Anschluss jedoch dennoch sowohl Prä- als auch Post-Survey vollständig aus. Da für diese Person keine wirksame Einwilligung vorliegt, wurden ihre Angaben vollständig von der quantitativen Auswertung ausgeschlossen. Dieselbe Person konnte ohnehin auch für die qualitative Inhaltsanalyse nicht berücksichtigt werden, da keine eigene Ausgangsantwort zu den Prozessszenarien auffindbar war.

Für die quantitative Auswertung liegen nach diesem Ausschluss $n=20$ vollständig ausgefüllte Post-Survey-Datensätze vor (10 Reflexionsbot, 10 Generic AI) sowie $n=22$ Prä-Survey-Datensätze. Da nicht jeder Personal Code eindeutig einer Person zuzuordnen war, weil er teilweise doppelt vergeben wurde, konnten für den Prä-Post-Abgleich $n=16$ Personen eindeutig verknüpft werden (vgl. Abschnitt 3.5).

Tabelle 3.1 fasst die Zusammensetzung der Stichprobe zusammen, Abbildung 3.2 stellt die drei kategorialen Merkmale zusätzlich grafisch dar. Die Stichprobe besteht überwiegend aus Studierenden des ersten Fachsemesters, ergänzt um einzelne Studierende höherer Semester sowie eine Austauschstudentin bzw. einen Austauschstudenten. Der überwiegende Teil der Teilnehmenden ist männlich, und der Großteil hatte vor dem Mini-Experiment noch

keine oder nur geringe berufliche Erfahrung im IT-Bereich. Erfahrung mit generativen KI-Chatbots war dagegen nahezu durchgängig vorhanden. In allen drei erfassten Merkmalen ist die Stichprobe damit deutlich einseitig zusammengesetzt.

Tabelle 3.1: Zusammensetzung der Stichprobe (Prä-Survey, n=22)

Merkmal	Ausprägung	Anzahl
Fachsemester	erstes Fachsemester	15
	höheres Fachsemester	6
	Austauschstudierende	1
Geschlecht	männlich	19
	weiblich	2
	keine Angabe	1
Vorerfahrung mit generativen KI-Chatbots	bereits genutzt	20
	nicht genutzt	2
Alter	19 bis 29 Jahre (M=22.0)	
Berufserfahrung im IT-Bereich	Median 0 Monate	




Abbildung 3.2: Zusammensetzung der Stichprobe nach Fachsemester, Geschlecht und Vorerfahrung mit generativen KI-Chatbots (n=22). Die mittleren Segmente stehen für höhere Fachsemester (6), weibliche Teilnehmende (2) und fehlende KI-Vorerfahrung (2). Die hellen Segmente stehen für Austauschstudierende (1) und eine fehlende Angabe zum Geschlecht (1).

Für die qualitative Inhaltsanalyse liegen aus den hochgeladenen Bearbeitungsdokumenten und Chatverläufen 31 auswertbare Analyseeinheiten vor, die sich auf beide Gruppen verteilen (15 Team AI, 16 Reflexionsbot). Ausgeschlossen wurden zwei erkennbare Testeinreichungen (Ordner mit dem Zusatz „(Test)“ im Namen) sowie derselbe bereits genannte Fall ohne

eigene Ausgangsantwort und ohne wirksame Einwilligung. Da bei einem erheblichen Teil der Einreichungen die Autorenschaft nicht eindeutig den Studierenden zuzuordnen ist (vgl. Abschnitt 3.5), reduziert sich die für die Häufigkeitsauswertung nutzbare Stichprobe auf 11 Fälle mit eindeutig studentischer Autorenschaft.

3.4 Fragebogen und Mini-Experiment

Das Mini-Experiment wurde im Rahmen der regulären Übung zur Lehrveranstaltung „Grundlagen des Software Engineering 1“ durchgeführt. Die Studierenden wurden in zwei Gruppen eingeteilt: die *Reflexionsbot*-Gruppe (in den Rohdaten und in den Anhangstabellen *Reflection Bot*), die die Aufgaben mit dem in dieser Arbeit entwickelten Reflexionsbot bearbeitete, und die *Generic-AI*-Gruppe (in Tabellen und in der Kodierung auch *Team AI*), die einen generischen KI-Chatbot nutzte, der Anfragen direkt und ohne systematische Rückfragen beantwortet. Als generisches System durften die Studierenden der Vergleichsgruppe frei zwischen den öffentlich zugänglichen Consumer-Versionen von ChatGPT (OpenAI), Gemini (Google) und Claude (Anthropic) wählen, wobei der Zugriff über die jeweiligen Weboberflächen auf den eigenen Endgeräten der Studierenden (Laptop, Tablet oder Smartphone) erfolgte. Anders als beim Reflexionsbot wurde das Verhalten dieser Systeme nicht über eine Systemnachricht gesteuert. Die einzige inhaltliche Vorgabe bestand in der Aufgabenanweisung, die eigenen Entscheidungen in das generische System einzugeben und um eine kritische Analyse beziehungsweise das stärkste Gegenargument zu bitten („AI Analysis“, vgl. Anhang A.4). Welche Modellstufe die einzelnen Systeme zum Erhebungszeitpunkt (24. Juni 2026) jeweils bereitstellten, war nicht kontrollierbar und wurde nicht erfasst. Beide Gruppen erhielten dieselben zwei Prozessszenarien: eine Produktentscheidung in einem regulierten ML-Projekt („SmartDose“, vgl. Abschnitt 4.2) sowie Koordinationsentscheidungen in einem verteilten Team („LearnLoop“). Zu beiden Szenarien waren jeweils drei Dilemma-Situationen mit Entscheidung, Begründung und Reflexion zu bearbeiten, gefolgt von einer Einschätzung der Gegenargumentation des jeweiligen KI-Systems. Tabelle 3.2 stellt die Rahmenbedingungen beider Gruppen gegenüber und macht sichtbar, welche Variablen kontrolliert waren und welche nicht.

Die Gegenüberstellung zeigt zugleich die Grenze des Vergleichs. Kontrolliert waren auf Seiten des Reflexionsbots Modell, Systemnachricht und Protokollierung, auf Seiten der Vergleichsgruppe keine dieser Größen. Der Vergleich ist daher als Kontrast zwischen einem gezielt gestalteten System und einem typischen alltäglichen KI-Zugang zu verstehen und nicht als kontrollierter Modellvergleich (vgl. Abschnitt 6.3).

Tabelle 3.2: Gegenüberstellung der beiden Versuchsbedingungen

Merkmal	Reflexionsbot	Generic AI
Zugang	Feste Web-Anwendung (Streamlit)	Frei gewählte Consumer-Oberflächen auf eigenen Endgeräten
Sprachmodell	<code>gpt-4o-mini</code> , festgelegt	ChatGPT, Gemini oder Claude; Modellstufe nicht erfasst
Steuerung des Verhaltens	Feste Systemnachricht mit sokratischen Rückfragen und adaptiver Tiefe	Keine Systemnachricht, un gelenkte Interaktion
Direkte Lösungen	Nicht vorgesehen	Reguläres Systemverhalten
Vorgabe zur Gegenargumentation	Im laufenden Dialog enthalten	Eigene Teilaufgabe „AI Analysis“
Protokollierung	Chatexport in der Anwendung enthalten	Manuelle Sicherung durch die Studierenden

Vor der Übung füllten die Studierenden einen Prä-Survey aus, der unter anderem Vorerfahrung mit KI-Systemen, selbsteingeschätztes Prozessverständnis (in Anlehnung an die Stufen Beschreiben, Begründen und Abwägen) sowie allgemeines Reflexionsverhalten erfasste. Im Anschluss an die Übung folgte ein Post-Survey mit spiegelbildlichen Items zur Erfahrung mit dem jeweils zugewiesenen KI-System, zur wahrgenommenen Unterstützung eigenständigen Denkens und zur eingeschätzten Kompetenzentwicklung. Beide Fragebögen wurden über ein pseudonymisiertes, freiwilliges Online-Formular erhoben. Ein persönlicher Code erlaubte die Zuordnung von Prä- und Post-Angaben, ohne dass Klarnamen erhoben wurden. Abbildung 3.3 fasst den zeitlichen Ablauf der Übungseinheit mit den jeweils eingesetzten Instrumenten zusammen.

Neben der Auswahl einzelner Items war auch die strukturelle Anlage des Fragebogens bewusst gestaltet. Prä- und Post-Survey wurden weitgehend spiegelbildlich aufgebaut, mit identischen oder nur leicht angepassten Items zu beiden Zeitpunkten, um Veränderungen pro Person über die Bearbeitung hinweg nachvollziehen zu können, statt lediglich zwei unabhängige Momentaufnahmen zu vergleichen. Die Items zum selbsteingeschätzten Prozessverständnis wurden gezielt in die drei Stufen Beschreiben, Begründen und Abwägen gegliedert,




Abbildung 3.3: Ablauf des Mini-Experiments mit den je Phase eingesetzten Erhebungsinstrumenten. Wissenstest, Selbsteinschätzung und Reflexionsverhalten wurden zu beiden Zeitpunkten mit identischen Items erhoben und über den persönlichen Code personenbezogen verknüpft.

die bewusst an die im Reflexionsstufenmodell nach Hatton und Smith (Abschnitt 2.1.5) unterschiedenen Reflexionsniveaus angelehnt sind: Die Beschreiben-Items entsprechen den unteren, rein deskriptiven Stufen, die Begründen- und Abwägen-Items den höheren, tatsächlich reflexiven Stufen. Diese Parallelität erlaubt es, die im Survey erhobene Selbsteinschätzung inhaltlich auf dieselbe theoretische Grundlage zu beziehen wie die qualitative Kodierung der Bearbeitungen, auch wenn beide Erhebungen methodisch unabhängig voneinander bleiben. Ergänzend wurde ein kurzer objektiver Wissenstest zu Scrum und Prozessmodellen mit sechs Multiple-Choice-Fragen aufgenommen, um die selbstberichtete Kompetenzeinschätzung um ein von der Selbstauskunft unabhängiges Maß zu ergänzen. Jede Frage wird mit einem Punkt bewertet (0 bis 6 Punkte). Die Fragen und der vollständige Bewertungsschlüssel sind in Anhang A.5, die Ergebnisse in Anhang A.6 dokumentiert.

Die überwiegende Mehrheit der Items (Erfahrung mit KI-Systemen, selbsteingeschätzte Kompetenz, Reflexionsverhalten, Erwartungen sowie die Bewertung des jeweiligen KI-Systems) wurde auf einer 5-stufigen Likert-Skala erhoben (1 = starke Ablehnung, 5 = starke Zustimmung). Die Mittelwerte in Kapitel 5 beziehen sich, sofern nicht anders angegeben, auf diese Skala. Eine Ausnahme bildet die Selbsteinschätzung der kognitiven Belastung im Post-Survey, die auf einer separaten 5-stufigen Skala von „sehr leicht“ bis „sehr schwierig“ erfasst wurde. Diese Skala wird in Abschnitt 5.1 gesondert berichtet, da sich ihre Richtung von der übrigen Zustimmungsskala unterscheidet. Der vollständige Fragebogeninhalt beider Erhebungszeitpunkte ist in Anhang A.5 dokumentiert. Tabelle 3.3 fasst zusammen, welches Konstrukt zu welchem Zeitpunkt mit welchem Format erhoben wurde.

Tabelle 3.3: Operationalisierung der quantitativ erhobenen Konstrukte

Konstrukt	Zeitpunkt	Format	Beispiel-Item
KI-Vorerfahrung	Prä	4 Items, 5-stufig Likert; 1 Item Häufigkeit	„I critically evaluate answers from AI systems before adopting them.“
Domänenwissen	Prä und Post	6 Multiple-Choice- Items, 0–6 Punkte	„What is the purpose of a Product Backlog in Scrum?“
Prozessverständnis, Stufe 1 (Beschreiben)	Prä und Post	3 Items, 5-stufig Likert	„I can explain what a process model in software development is.“
Prozessverständnis, Stufe 2 (Begründen)	Prä und Post	3 Items, 5-stufig Likert	„I can explain why a particular process model is suitable for a specific project.“
Prozessverständnis, Stufe 3 (Abwägen)	Prä und Post	2 Items, 5-stufig Likert	„I can weigh which process model best fits a specific scenario and explain why another does not.“
Reflexionsverhalten	Prä und Post	5 Items, 5-stufig Likert	„I compared multiple options before making a final decision.“
Bewertung des Systems	Post	8 Items, 5-stufig Likert	„The AI system prompted more independent thinking than I expected.“
Kognitive Last	Post	6 Items, 5-stufig (1 = very easy bis 5 = very difficult)	„How would you rate the overall cognitive effort required by the exercise?“

Die Übersicht macht die Parallelisierung sichtbar. Vier der acht Konstrukte wurden zu beiden Zeitpunkten mit identischen Items erhoben, sodass sich Veränderungen personenbezogen berechnen lassen. Die Bewertung des Systems und die kognitive Last sind naturgemäß nur nach der Bearbeitung erhebbar, die KI-Vorerfahrung nur davor.

3.5 Datenanalyse

Die gesammelten Daten werden sowohl qualitativ als auch quantitativ analysiert und anschließend zusammengeführt.

Die quantitativen Fragebogendaten (Prä- und Post-Survey) werden deskriptiv ausgewertet, insbesondere im Gruppenvergleich zwischen den Studierenden, die mit dem Reflexionsbot arbeiteten, und jenen, die das generische KI-System nutzten. Aufgrund der kleinen Stichprobengröße wird bewusst auf inferenzstatistische Tests und Verallgemeinerungsansprüche verzichtet. Die Mittelwertvergleiche dienen der deskriptiven Einordnung und der Triangulation mit den qualitativen Befunden.

Die schriftlichen Bearbeitungen der beiden Prozessszenarien sowie die Chatverläufe mit dem jeweiligen KI-System werden mittels strukturierender qualitativer Inhaltsanalyse nach Mayring [58] ausgewertet. Dabei kommt das in Abschnitt 2.1.5 eingeführte deduktive Kategoriensystem nach Hatton und Smith [36] zum Einsatz, ergänzt um eine Zusatzstufe zur Erfassung fehlender Eigenreflexion (Vermeidung, Aufgabenverweigerung). Die Herkunft des Textes wird davon getrennt über die Dimension Autorenschaft erfasst (vollständiges Kategoriensystem mit Kodierregeln und Autorenschafts-Indikatoren siehe Anhang A.1). Als Analyseeinheit dient jeweils die schriftliche Reflexion einer Teilnehmerin bzw. eines Teilnehmers zu einem der beiden Szenarien (Aufgabenteil „Reflect“ sowie die anschließende Einschätzung der KI-Gegenargumentation).

Da ein Teil der eingereichten Antworten erkennbar nicht von den Studierenden selbst, sondern durch Kopieren der Systemantwort entstanden ist, wird zusätzlich zur Reflexionsstufe die Autorenschaft des Textes (studentisch, unklar oder KI-generiert) erfasst. Andernfalls würde die Analyse die Reflexionsfähigkeit des KI-Systems statt der Studierenden abbilden. Die Kodierung erfolgte durch eine einzelne Person anhand der Rohdaten (Chatlogs, eingereichte Dokumente, Formulierungsvergleiche zwischen Personen). Eine Zweitkodierung zur Absicherung der Inter-coder-Reliabilität wurde im Rahmen dieser Arbeit nicht durchgeführt und ist als Limitation in Kapitel 6 zu benennen.

Der Kodierdurchgang verlief in drei Schritten. Zunächst wurde das aus der Literatur abgeleitete Kategoriensystem an einer Teilmenge der Bearbeitungen probeweise angewendet, um zu prüfen, ob sich die Stufendefinitionen am vorliegenden Material überhaupt trennscharf anwenden lassen. Dabei zeigte sich, dass die vier Originalstufen den häufigsten Fall dieser Stichprobe nicht abbilden, nämlich Bearbeitungen ohne jede eigene inhaltliche Aussage. Das Kategoriensystem wurde daraufhin um die Zusatzstufe 0 ergänzt und die Stufen 3 und 4 für den Kontext des Software-Prozessmanagements ausformuliert (vgl. Anhang A.1). Im zweiten

Schritt wurde das gesamte Material mit dem angepassten System kodiert, im dritten wurden alle Fälle erneut durchgegangen, um die zwischenzeitlich präzisierten Regeln einheitlich anzuwenden.

Für die Zuordnung galten dabei zwei Entscheidungsregeln. Enthielt eine Bearbeitung Indikatoren mehrerer Stufen, wurde die höchste Stufe kodiert, die durch eine ausformulierte Textstelle belegt ist, nicht die im Text überwiegende. Blieben nach Sichtung aller verfügbaren Rohdaten Zweifel an der Autorenschaft, wurde nicht „KI-generiert“, sondern die Zwischenkategorie „unklar“ vergeben. Beide Regeln sind konservativ gewählt: Die erste verhindert, dass einzelne schwache Passagen eine erkennbare Abwägung entwerten, die zweite, dass ein Verdacht als Nachweis gewertet wird. Wie stark die Kategorie „unklar“ die zentrale Auslagerungskennzahl prägt, wird in Abschnitt 6.3 eigens diskutiert.

Abbildung 3.4 stellt den zweistufigen Ablauf dar. Entscheidend ist die Reihenfolge: Die Autorenschaft wird *vor* der Reflexionsstufe geprüft, damit nicht die Reflexionsfähigkeit des KI-Systems anstelle der studentischen Leistung kodiert wird.




Abbildung 3.4: Zweistufiger Kodierprozess je Analyseeinheit. Nur Bearbeitungen mit studentischer Autorenschaft werden anschließend nach Reflexionsstufen kodiert. Damit wird die Textqualität von der studentischen Eigenleistung entkoppelt.

Die Analyseeinheit wurde bewusst auf den Aufgabenteil „Reflect“ samt anschließender Einschätzung der KI-Gegenargumentation begrenzt und nicht auf die gesamte Bearbeitung ausgeweitet. Nur in diesem Teil fordert die Aufgabenstellung beide Gruppen gleichermaßen zu einer Begründung der eigenen Entscheidung auf, sodass die kodierten Textstellen über beide Bedingungen hinweg vergleichbar sind. Die Tasks 1 und 2 verlangen dagegen primär Analyse und Entscheidung, sodass dort auftretende Unterschiede eher die Aufgabenstellung als die Reflexionstiefe abbilden würden.

Für die **Reliabilität** der Kodierung wurde jeder Fall nicht isoliert, sondern anhand mehrerer zusammengeführter Rohdatenquellen eingeschätzt: Chatverlauf, eingereichtes Bearbeitungsdokument und, wo einschlägig, ein Abgleich der Formulierungen mit anderen Personen, um beispielsweise wortgleiche oder erkennbar kopierte Passagen zuverlässig zu identifizieren (vgl. Abschnitt 5.2). Diese Zusammenführung mehrerer Rohdatenquellen stützt allerdings primär die Validität der Einordnung und ersetzt keine unabhängige Zweitkodierung: Eine Absicherung der Kodierreliabilität durch eine zweite Kodiererin oder einen zweiten Kodierer (Intercoder-Reliabilität) wurde im Rahmen dieser Arbeit nicht durchgeführt und ist als Einschränkung der Reliabilität zu werten (vgl. Abschnitt 6.3). Für den quantitativen Teil erhöht die pseudonyme, selbst administrierte Erhebung über ein Online-Formular die Wahrscheinlichkeit konsistenter, von der Anwesenheit einer Untersuchungsperson unbeeinflusster Antworten [39].

Die **Validität** der Untersuchung stützt sich zum einen auf die inhaltliche Gestaltung der Prozessszenarien, die bewusst an realen regulatorischen Rahmenbedingungen (MDR, FERPA) ausgerichtet wurden, um eine für Software-Prozessmanagement realistische Entscheidungssituation abzubilden (vgl. Abschnitt 4.3). Zum anderen erhöht die Triangulation von Survey- und Inhaltsanalysedaten im gewählten Mixed-Methods-Design (Abschnitt 2.1.6) die Validität der Gesamtinterpretation, da sich wahrgenommene und tatsächlich gezeigte Reflexion gegenseitig prüfen lassen, statt sich allein auf eine der beiden Perspektiven zu verlassen. Grenzen des gewählten Vorgehens werden in Abschnitt 6.3 kritisch reflektiert.

3.7 Forschungsethik und Datenschutz

Die Teilnahme am Mini-Experiment war für alle Studierenden freiwillig und unabhängig von der Bewertung der Übung. Vor Beginn der Bearbeitung wurden die Studierenden im Prä-Survey über Zweck und Ablauf der Untersuchung informiert und um ihre ausdrückliche Einwilligung zur Teilnahme sowie um die Bestätigung der Volljährigkeit gebeten (vgl. Abschnitt 3.3). Eine Person, die die Einwilligung ausdrücklich verneinte, wurde vollständig von der Auswertung ausgeschlossen.

Personenbezogene Klarnamen wurden zu keinem Zeitpunkt erhoben. Stattdessen wählten die Studierenden einen selbst gewählten, nicht auf ihre Identität rückführbaren Personal Code, über den Prä- und Post-Survey sowie, soweit als Pseudonym auch für den Dokumenten-Upload verwendet, die qualitativ kodierten Fälle miteinander verknüpft werden konnten (vgl. Abschnitt 3.2). Die erhobenen Daten wurden ausschließlich zum Zweck dieser Bachelorarbeit verarbeitet und nicht an Dritte weitergegeben, im Einklang mit den Grundsätzen der Datenminimierung und Zweckbindung (Art. 5 Abs. 1 lit. b und c DSGVO) [59].

4 Konzeptionierung

Während Kapitel 3 den Rahmen festlegt, in dem der Vergleich beider Systeme untersucht wird, beschreibt dieses Kapitel den Untersuchungsgegenstand selbst. Der Reflexionsbot ist kein vorgefundenes System, sondern wurde für diese Arbeit eigens entwickelt. Seine Gestaltung ist damit nicht bloß technische Vorarbeit, sondern der eigentliche didaktische Eingriff, dessen Wirkung anschließend untersucht wird. Sie wird hier so dokumentiert, dass sich die getroffenen Entscheidungen nachvollziehen und der Bot reproduzieren lässt.

Das Kapitel gliedert sich in vier Abschnitte. Zunächst werden die funktionalen und nicht-funktionalen Anforderungen aus Zielsetzung und Forschungsfrage abgeleitet (Abschnitt 4.1). Darauf aufbauend beschreibt Abschnitt 4.2 das didaktische Konzept des Bots, insbesondere das Prinzip der adaptiven Tiefe seiner Rückfragen. Abschnitt 4.3 stellt die Gestaltung der beiden Prozessszenarien dar, die für beide Gruppen die identische Aufgabengrundlage bilden. Abschnitt 4.4 dokumentiert abschließend die technische Umsetzung von der Auswahl des Frontend-Frameworks bis zur Anbindung des Sprachmodells.

4.1 Anforderungen an das System

Aus der in Kapitel 1 formulierten Zielsetzung sowie der in Abschnitt 1.3 formulierten Forschungsfrage lassen sich funktionale und nicht-funktionale Anforderungen an den zu entwickelnden Reflexionsbot ableiten.

Funktional muss der Bot erstens auf direkte Lösungen verzichten und stattdessen durch Rückfragen zur eigenen Argumentation der Studierenden anregen, da genau dieser Verzicht den Kern der Forschungsfrage bildet. Zweitens muss sich die Tiefe dieser Rückfragen adaptiv an die Qualität der studentischen Argumentation anpassen, damit weder oberflächliche Antworten unkommentiert bleiben noch bereits durchdachte Antworten unnötig verzögert werden. Drittens muss der Bot beide Prozessszenarien (SmartDose, LearnLoop, vgl. Abschnitt 4.3) kennen und inhaltlich referenzieren können, ohne sie beim Namen zu nennen, damit Studierende nicht anhand der Szenario-Bezeichnung nachschlagen, statt selbst zu argumentieren. Viertens müssen Studierende mehrere Chat-Sitzungen parallel führen und

wechseln können, und fünftens müssen die Gesprächsverläufe für die spätere qualitative Auswertung exportierbar sein.

Nicht-funktional muss der Bot ohne lokale Installation zugänglich sein, damit er im Rahmen einer regulären Übung ohne technische Vorbereitung genutzt werden kann. Die Nutzung muss pseudonym erfolgen, sodass kein Klarname, sondern nur ein selbst gewählter Personal Code erforderlich ist (vgl. Abschnitt 3.2). Bei der Modellwahl war zudem auf ein angemessenes Verhältnis von Antwortqualität und Kosten zu achten, da mehrere Studierende die Anwendung gleichzeitig während der Übung nutzen sollten. Schließlich sollten Antworten möglichst unmittelbar sichtbar werden, um den Gesprächsfluss nicht durch Wartezeiten zu unterbrechen.

Tabelle 4.1 fasst die Anforderungen zusammen und weist jeder Anforderung aus, worauf sie zurückgeht. Die Zuordnung macht sichtbar, dass die funktionalen Anforderungen FA1 bis FA3 unmittelbar aus den Teilfragen folgen und damit die Untersuchungsbedingung selbst herstellen, während FA4 und FA5 sowie die nicht-funktionalen Anforderungen den Erhebungs- und Durchführungsrahmen absichern. Diese Unterscheidung ist für die Bewertung der Umsetzung wesentlich: Ein Fehler in FA1 oder FA2 gefährdet die Gültigkeit des Vergleichs, ein Fehler in NFA3 lediglich den Komfort.

4.2 Konzept des Reflexionsbots

Der entwickelte Reflexionsbot ist kein generisches Frage-Antwort-System. Er ist ein spezialisierter Reflexionscoach, der Studierende bei der Bearbeitung von zwei Szenarien zur Prozessmodellierung aus dem Software Engineering begleitet. Die Szenarien bilden realistische Entscheidungssituationen ab, etwa Rollen-, Daten- und Zeitplanentscheidungen in einem regulierten ML-Projekt sowie Architektur- und Kommunikationsentscheidungen in einem verteilten Team, und dienen als fester Kontext, auf den sich alle Rückfragen des Bots beziehen (vollständige Szenariobeschreibungen siehe Anhang A.4).

Im Zentrum des Konzepts steht das in Abschnitt 2.1 eingeführte Prinzip von Scaffolding und sokratischem Fragen: Der Bot liefert keine fertigen Lösungen, sondern stellt gezielte Rückfragen, die Studierende zur Begründung und Reflexion ihrer eigenen Prozessentscheidungen anregen. Damit unterscheidet er sich bewusst von einem generischen KI-System, das eine Frage typischerweise direkt beantworten würde. Genau dieser Unterschied bildet den Kern der Forschungsfrage dieser Arbeit.

Tabelle 4.1: Funktionale und nicht-funktionale Anforderungen an den Reflexionsbot

Nr.	Anforderung	Begründet durch
<i>Funktionale Anforderungen</i>		
FA1	Verzicht auf direkte Lösungen, stattdessen Rückfragen zur eigenen Argumentation	TF1, Kern der Vergleichsbedingung
FA2	Adaptive Tiefe der Rückfragen, abhängig von der Qualität der studentischen Antwort	TF2, Scaffolding-Prinzip
FA3	Kenntnis beider Szenarien, ohne sie beim Namen zu nennen	TF2, verhindert Nachschlagen statt Argumentieren
FA4	Mehrere parallele Chat-Sitzungen mit Wechselemöglichkeit	Durchführung, zwei Szenarien je Person
FA5	Exportierbarkeit der Gesprächsverläufe	Datengrundlage der qualitativen Kodierung
<i>Nicht-funktionale Anforderungen</i>		
NFA1	Zugänglich ohne lokale Installation	Einsatz in regulärer Übung ohne Vorbereitung
NFA2	Pseudonyme Nutzung über selbst gewählten Personal Code	Forschungsethik, Prä-Post-Verknüpfung
NFA3	Angemessenes Verhältnis von Antwortqualität und Kosten	Gleichzeitige Nutzung durch mehrere Studierende
NFA4	Unmittelbar sichtbare Antworten	Erhalt des Gesprächsflusses

Ein zentrales Gestaltungsmerkmal ist die *adaptive Tiefe* der Bot-Antworten. Die Ausführlichkeit und Qualität der Rückmeldung skaliert mit der Qualität der studentischen Argumentation, wie Abbildung 4.1 zusammenfasst.

- **Vage Antwort** (z. B. Nennung einer Option ohne Begründung): Der Bot stellt genau eine kurze, gezielte Rückfrage, um die Begründung herauszuarbeiten.
- **Teilweise Begründung** (Studierende nennen eine Entscheidung mit einer Begründung, lassen aber Risiken oder Randbedingungen aus): Der Bot bestätigt kurz den

richtigen Teil und stellt ein bis zwei fokussierte Rückfragen zu den fehlenden Aspekten.

- **Starke Argumentation** (Abwägungen, Randbedingungen, Konsequenzen werden benannt): Der Bot bestätigt den stärksten Punkt explizit, ergänzt eine Perspektive, die nicht genannt wurde, und stellt eine weiterführende Frage.
- **Herausragende Antwort** (mehrperspektivische Abwägung, konkrete Randbedingungen, Folgeeffekte werden antizipiert): Der Bot begegnet den Studierenden auf Augenhöhe, benennt das stärkste Gegenargument und stellt eine Frage, die die Kernannahme herausfordert.




Abbildung 4.1: Adaptive Tiefe der Bot-Antworten. Mit steigender Qualität der studentischen Argumentation nimmt die Ausführlichkeit der Rückmeldung zu (zunehmend dunklere Färbung), während bei einer vagen Antwort bewusst nur eine einzelne Rückfrage erfolgt.

Diese gestufte Unterstützung setzt das Scaffolding-Prinzip technisch um: Hilfestellung wird nicht pauschal gewährt, sondern in Abhängigkeit vom gezeigten Kompetenzniveau zurückgenommen, sobald Studierende eigenständiger argumentieren. Zusätzlich fokussiert der Bot pro Gesprächsrunde jeweils eine logische Schwachstelle (z. B. zunächst Risiko, danach Rollen und Stakeholder, dann Abhängigkeiten, dann Zeitplanrealismus), sodass sich die Reflexion schrittweise vertieft, statt alle Schwächen gleichzeitig zu adressieren. Um zu verhindern, dass Studierende Antworten anhand der Szenario-Bezeichnung erraten oder nachschlagen, statt selbst zu argumentieren, nennt der Bot die Szenarien in seinen Antworten nie explizit beim Namen.

Schließlich antwortet der Bot durchgängig auf Englisch, unabhängig davon, in welcher Sprache die Studierenden schreiben. Hintergrund ist, dass die Lehrveranstaltung „Grundlagen des Software Engineering 1“ auch internationale Studierende umfasste. Eine einheitlich englische Kommunikation stellte sicher, dass auch diese Teilnehmenden eingebunden waren und die

Rückfragen des Bots verstehen konnten. Aus demselben Grund wurden die Aufgabenblätter (Anhang A.4) und die Fragebögen (Anhang A.5) auf Englisch ausgegeben.

Abbildung 4.2 zeigt die Oberfläche des Reflexionsbots anhand eines beispielhaften Gesprächsverlaufs zur Datensatzentscheidung aus dem Szenario SmartDose. Über die Seitenleiste lassen sich mehrere Chats parallel anlegen und der Gesprächsverlauf als Textdatei herunterladen, während das Eingabefeld im Hauptbereich für die Kommunikation mit dem Bot genutzt wird. Der Verlauf veranschaulicht zugleich die adaptive Tiefe. Auf die einleitende Frage nach der zu wählenden Option antwortet der Bot nicht mit einer Empfehlung, sondern mit einer einzelnen gezielten Rückfrage nach den Risiken. Auf die knappe Antwort „Maybe we could get into legal trouble“ folgt eine kurze Bestätigung und eine fokussierte Nachfrage zur nicht gewählten Option. Erst als die studentische Antwort Zulassungsfähigkeit und Modellqualität explizit gegeneinander abwägt, bestätigt der Bot den stärksten Punkt ausdrücklich und ergänzt eine weiterführende Frage.

Im Vergleich zu bestehenden textgenerativen Reflexionswerkzeugen wie „Reflect Me“ [47], das allgemeine Reflexionsimpulse zu frei wählbaren Themen gibt, ist der hier entwickelte Reflexionsbot bewusst enger gefasst: Er kennt die konkreten Entscheidungssituationen beider Szenarien im Detail und kann seine Rückfragen daher gezielt auf die jeweilige Prozessentscheidung sowie die dort relevanten Randbedingungen zuschneiden, statt allgemein gehaltene Reflexionsfragen zu stellen. Diese Szenario-Spezifität ist die Voraussetzung dafür, dass die adaptive Tiefe (s. o.) inhaltlich präzise auf einzelne Argumentationslücken reagieren kann.

4.3 Konzeption der Szenarien

Neben dem Reflexionsbot selbst war die Gestaltung der beiden Prozessszenarien SmartDose und LearnLoop ein eigenständiger Teil der Konzeption, da die Qualität der möglichen Reflexion maßgeblich von der Aufgabenstellung abhängt, auf die sich diese Reflexion bezieht (vollständige Szenariobeschreibungen siehe Anhang A.4).

Beiden Szenarien liegt dasselbe Gestaltungsprinzip zugrunde: Sie bestehen aus jeweils drei Dilemma-Situationen, die bewusst keine eindeutig richtige Lösung besitzen, sondern eine Abwägung zwischen mehreren vertretbaren, aber jeweils mit Nachteilen behafteten Optionen verlangen. Die Aufgabenstellung schließt Ausweichantworten wie „we would do both“ ausdrücklich aus, um eine tatsächliche Entscheidung zu erzwingen. Um diese Abwägung inhaltlich zu verankern, sind beide Szenarien um reale regulatorische und organisationale Zwänge herum konstruiert: SmartDose stellt Patientensicherheit und Entwicklungsgeschwindigkeit gegen die Vorgaben der EU-Medizinprodukteverordnung (MDR), LearnLoop stellt Projektfortschritt in einem verteilten Team gegen Datenschutzanforderungen (FERPA) und

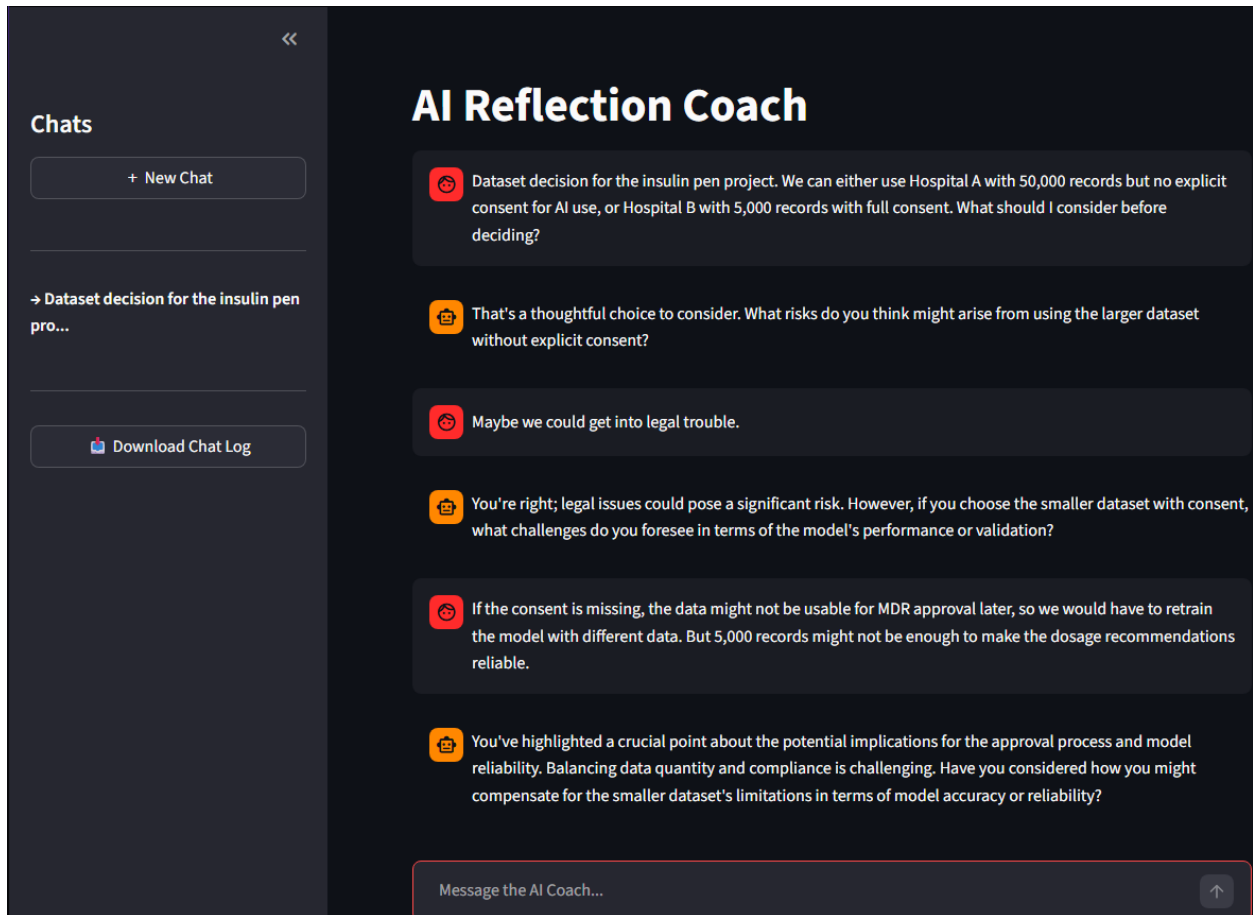


Abbildung 4.2: Oberfläche des Reflexionsbots (Streamlit-Anwendung) mit einem beispielhaften Gesprächsverlauf zur Datensatzentscheidung aus dem Szenario SmartDose. Der Verlauf wurde zur Illustration der adaptiven Tiefe nachgestellt und stammt nicht aus dem Mini-Experiment.

massive Zeitzoneunterschiede. Beide Konflikte sind so gewählt, dass eine rein technische Betrachtung nicht ausreicht, sondern rechtliche, ethische und organisationale Gesichtspunkte gegeneinander abgewogen werden müssen.

Jedes Szenario folgt zudem demselben dreistufigen Aufgabenaufbau, den Abbildung 4.3 zusammenfasst. Zunächst analysieren Studierende in Task 1, welche Scrum-Elemente im veränderten Kontext noch funktionieren (Verständnis der Ausgangslage), anschließend treffen und begründen sie in Task 2 Entscheidungen zu den drei Dilemma-Situationen (eigentliche Entscheidungsfindung), und schließlich reflektieren sie in Task 3, welche Entscheidung am schwersten fiel und warum (Metareflexion). Bei Team AI folgt darauf ein eigenständiger Gegencheck mit einem generischen KI-System, beim Reflexionsbot erfolgt dieser Gegencheck bereits im laufenden Dialog mit dem Bot selbst.

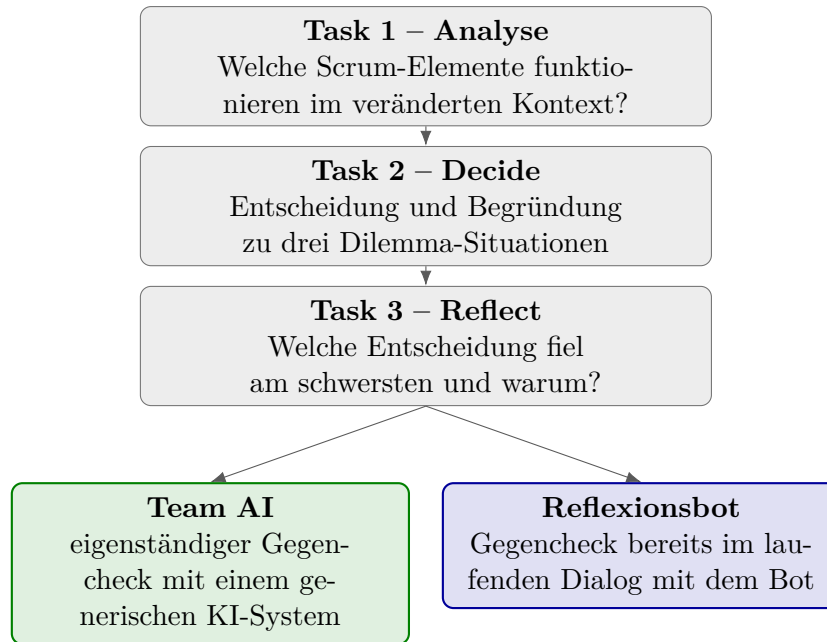


Abbildung 4.3: Dreistufiger Aufgebau der Szenarien. Beide Gruppen bearbeiteten Task 1 bis Task 3 mit identischen Aufgabenblättern. Der einzige Unterschied lag in der abschließenden Gegenargumentation.

Dieser dreistufige Aufbau war notwendig, um die in Abschnitt 3.5 beschriebene Kodierung nach Reflexionsstufen überhaupt an einer vergleichbaren Aufgabenstruktur vornehmen zu können.

4.4 Technische Umsetzung

Abbildung 4.4 gibt einen Überblick über die technische Architektur, bevor die einzelnen Entwurfsentscheidungen im Detail erläutert werden: Studierende interagieren über den Browser mit der Streamlit-Anwendung, die Eingaben entgegennimmt, den Sitzungszustand verwaltet und bei jeder Anfrage die Systemnachricht zusammen mit dem bisherigen Gesprächsverlauf an die Chat-Completions-API von OpenAI übergibt. Die Anwendung selbst läuft containerisiert in Docker.

4.4.1 Frontend-Auswahl: Streamlit vs. Gradio

Für die Umsetzung des Chat-Interfaces standen Streamlit [60] und Gradio [61] zur Auswahl, da beide Frameworks eine schnelle Entwicklung von Python-basierten Web-Anwendungen ohne separaten Frontend-Stack ermöglichen. Tabelle 4.2 stellt beide Frameworks anhand der für den Reflexionsbot relevanten Kriterien gegenüber [60], [61].




Abbildung 4.4: Vereinfachte Architektur des Reflexionsbots

Gradio ist stärker auf einzelne Modell-Demos zugeschnitten und bietet vorgefertigte Chat-Komponenten, die für einen einfachen Chatbot-Prototyp schneller einsatzbereit sind. Da der Reflexionsbot jedoch mehrere parallele Chat-Sitzungen verwalten, Gesprächsverläufe für die spätere Auswertung exportieren und sich potenziell in ein größeres Analyse-Dashboard einbetten lassen sollte, fiel die Wahl auf Streamlit, das bei diesen Anforderungen mehr Kontrolle über Layout und Zustandsverwaltung bietet.

4.4.2 Implementierung

Die Anwendung wurde vollständig in Python umgesetzt. Der Chatverlauf jeder Sitzung wird im Streamlit-`session_state` als Liste von Nachrichten verwaltet. Über eine Seitenleiste lassen sich mehrere Chats parallel anlegen, wechseln und als Textdatei herunterladen. Der Titel eines Chats wird automatisch aus der ersten Eingabe der Studierenden abgeleitet.

Die Entscheidung für die OpenAI-API gegenüber einem lokal betriebenen Modell begründet sich in mehreren Faktoren: Der Betrieb leistungsfähiger LLMs erfordert erhebliche Rechenressourcen, die im Rahmen dieser Arbeit nicht verfügbar waren. Zusätzlich bieten Modelle der GPT-4-Familie eine hohe Qualität bei Sprachverarbeitung und Gesprächsführung [62], und

Tabelle 4.2: Vergleich von Streamlit und Gradio als Frontend-Framework

Kriterium	Streamlit	Gradio
Vorgefertigte Chat-Komponenten	Nicht enthalten, Chat-Oberfläche muss selbst aufgebaut werden	Vorhanden, dadurch schneller einsatzbereiter Prototyp
Mehrere parallele Chat-Sitzungen	Über <code>session_state</code> flexibel umsetzbar	Nicht für diesen Anwendungsfall vorgesehen
Export der Gesprächsverläufe	Direkter Zugriff auf den Sitzungszustand, frei exportierbar	Nur eingeschränkt vorgesehen
Kontrolle über Layout und Zustandsverwaltung	Umfangreich, da als vollwertige Webanwendung strukturierbar	Eingeschränkt, komponentenbasiert
Einbettung in ein größeres Analyse-Dashboard	Gut geeignet	Primär auf einzelne Modell-Demos zugeschnitten
Entwicklungsgeschwindigkeit für einfachen Prototyp	Etwas höherer Aufwand	Sehr schnell

die REST-basierte Schnittstelle lässt sich ohne aufwendige Infrastruktur direkt in Webanwendungen integrieren [27].

Die Anbindung an das Sprachmodell erfolgt über die in Abschnitt 2.1 beschriebene Chat-Completions-API von OpenAI [27], wobei als Modell `gpt-4o-mini` verwendet wird. Die Wahl der ressourcenschonenden mini-Variante gegenüber dem größeren `gpt-4o` folgt der in Abschnitt 4.1 formulierten Anforderung eines angemessenen Verhältnisses von Antwortqualität und Kosten, da während der Übung mehrere Studierende die Anwendung gleichzeitig nutzen sollten. Für die vom Bot benötigten Rückfragen war die Qualität der mini-Variante ausreichend. Bei jeder Anfrage wird die Systemnachricht (vgl. Abschnitt 4.2; vollständiger Wortlaut in Anhang A.7) zusammen mit dem vollständigen bisherigen Gesprächsverlauf an das Modell übergeben, damit der Kontext über mehrere Gesprächsrunden erhalten bleibt. Die Antwort wird gestreamt (`stream=True`) an die Oberfläche ausgegeben, sodass Studierende die Antwort des Bots bereits während der Generierung lesen können, statt auf die

vollständige Antwort warten zu müssen. Abbildung 4.5 zeigt diesen zentralen Mechanismus anhand des tatsächlich eingesetzten Codes.

```
1 # The Chat Completions API is stateless: it has no memory of earlier
2 # calls, so the system prompt and the full message history are sent
3 # again with every request to keep the model's context consistent.
4 conversation = [{"role": "system", "content": SYSTEM_PROMPT}]
5 conversation.extend(
6     [{"role": m["role"], "content": m["content"]}
7     for m in current_messages
8 ])
9 stream = client.chat.completions.create(
10     model=st.session_state["openai_model"],
11     messages=conversation,
12     stream=True,
13 )
14 response = st.write_stream(stream)
```

Abbildung 4.5: Aufbau der Nachrichtenliste und Streaming-Aufruf der Chat-Completions-API

Für die Durchführung des Mini-Experiments wurde die Anwendung containerisiert (Docker) und öffentlich erreichbar bereitgestellt, sodass Studierende unabhängig von lokalen Python-Installationen darauf zugreifen konnten.

5 Ergebnisse

Dieses Kapitel berichtet die erhobenen Daten zunächst rein darstellend: den deskriptiven Überblick über Autorenschaft, Reflexionsstufen und Survey-Kennwerte (Abschnitt 5.1), die Illustration des Kategoriensystems an realen Entscheidungssituationen (Abschnitt 5.2) sowie die Gegenüberstellung von Selbstauskunft und dokumentiertem Bearbeitungsverhalten (Abschnitt 5.3). Die Interpretation dieser Befunde und die Beantwortung der Forschungsfragen erfolgen anschließend in Kapitel 6.

5.1 Deskriptiver Überblick

Dieser Abschnitt stellt die erhobenen Daten zunächst rein deskriptiv dar. Ihre inhaltliche Interpretation und die Beantwortung der Forschungsfragen erfolgen in Kapitel 6. Angesichts der kleinen Stichprobe sind alle Werte deskriptiv zu lesen. Auf Inferenzstatistik wird bewusst verzichtet (vgl. Abschnitt 3.5). Die vollständigen Tabellen finden sich in Anhang A.2 bis A.6.

Autorenschaft der Bearbeitungen

Von den 31 kodierten Analyseeinheiten ist die Autorenschaft nur bei 11 eindeutig studentisch. Tabelle 5.1 schlüsselt die Verteilung nach Gruppe und nach Sicherheit der Einstufung auf. Fasst man die Kategorien „unklar“ und „KI-generiert“ zusammen, liegt der Anteil der Bearbeitungen ohne eindeutig studentische Autorenschaft bei Team AI bei 80 % und beim Reflexionsbot bei 50 %. Betrachtet man dagegen nur die gesichert KI-generierten Fälle, fällt der Unterschied zwischen beiden Gruppen deutlich geringer aus.

Reflexionsstufen der studentisch verfassten Bearbeitungen

Für die Fälle mit eindeutig studentischer Autorenschaft verteilen sich die Reflexionsstufen wie in Abbildung 5.1 dargestellt. Deskriptiv liegt der Mittelwert der Stufen bei Team AI mit 1.33 ($n=3$) über dem des Reflexionsbots mit 0.75 ($n=8$); die Mediane liegen bei 2.0 gegenüber 0.5.

Tabelle 5.1: Autorenschaft der kodierten Bearbeitungen nach Gruppe

Autorenschaft	Team AI (n=15)	Reflexionsbot (n=16)
studentisch	3	8
unklar	4	1
KI-generiert	8	7
nicht eindeutig studentisch	12 (80 %)	8 (50 %)

Bei drei gegenüber acht auswertbaren Fällen ist dieser Unterschied jedoch nicht belastbar. Bereits ein einzelner abweichender Fall verschiebt den Mittelwert der kleineren Gruppe um mehr als 0,3 Stufen.

Kein einziger Fall der gesamten Stichprobe erreicht mit bestätigter studentischer Autorenschaft Stufe 4. Texte, die zunächst wie kritische Reflexion wirkten, stellten sich beim Abgleich mit den Rohdaten durchgehend als KI-generiert oder unklar heraus (vgl. Abschnitt 5.2). Kritische Reflexion im Sinne von Hatton und Smith ist allerdings auch unabhängig vom eingesetzten Werkzeug ein seltenes Phänomen, insbesondere bei Studierenden im ersten Semester und in einer einmaligen Übungseinheit. Das vollständige Ausbleiben dieser Stufe ist daher für sich genommen kein Befund über die verglichenen KI-Systeme.




Abbildung 5.1: Verteilung der Reflexionsstufen nach Gruppe (nur Fälle mit eindeutig studentischer Autorenschaft)

Objektiver Wissenstest

Im Wissenstest zu Scrum und Prozessmodellen (0 bis 6 Punkte) zeigt der Vergleich nach Systemgruppen keinen Vorteil des Reflexionsbots. Die Reflexionsbot-Gruppe fällt von Prä

M=5.56 auf Post M=4.44 (n=9), während die Generic-AI-Gruppe mit Prä und Post M=5.43 (n=7) stabil bleibt (Tab. A.7). Etwa die Hälfte dieses Rückgangs entfällt auf einen einzelnen Fall, der im Post-Survey alle sechs Fragen falsch beantwortete. Ohne diesen Fall liegt die Reflexionsbot-Gruppe bei Prä M=5.62 und Post M=5.00 (n=8); ein leichter Rückgang bleibt damit auch ohne ihn bestehen.

Die Aussagekraft dieses Vergleichs ist allerdings durch einen Deckeneffekt begrenzt. Beide Gruppen liegen bereits im Prä-Test nahe der Höchstpunktzahl von rund 5,5 von 6 Punkten, sodass sich Lernzuwächse kaum abbilden lassen. Aus dem Test ist damit weder ein Systemvorteil noch dessen Fehlen belastbar abzuleiten. Dieser Vorbehalt gilt für jeden Vergleich, der auf diesem Instrument aufbaut, also auch für die im Folgenden berichtete Aufteilung nach dem Bearbeitungsverhalten.

Teilt man dieselben Personen nach dem tatsächlichen Bearbeitungsverhalten auf, erreichen eigenständig arbeitende Personen im Post-Test M=5.75 (n=4) gegenüber M=4.50 (n=10) bei Personen mit ganz oder teilweise ausgelagerter Bearbeitung (vgl. Abschnitt 5.3). Dieser Abstand ist jedoch nicht als Lerneffekt zu lesen. Alle vier eigenständig arbeitenden Personen erreichten bereits im Prä-Test die volle Punktzahl (Prä M=6.00, SD=0.00), sodass bei ihnen rechnerisch kein Zuwachs mehr möglich war; ihr Post-Wert entspricht einem leichten Rückgang von -0.25 . Die Vergleichsgruppe startete bereits im Prä-Test unterhalb der Höchstpunktzahl und fiel ebenfalls ab. Der Unterschied im Post-Test spiegelt damit überwiegend eine schon vor der Übung bestehende Leistungsdifferenz wider und nicht einen unterschiedlichen Lernzuwachs.

Selbsteingeschätztes Prozessverständnis und Systembewertung

Bei den Items zum reinen Beschreiben sinkt die Selbsteinschätzung in beiden Gruppen leicht. Bei den Items zum Begründen und Abwägen bleibt die Reflexionsbot-Gruppe stabil oder verbessert sich leicht, mit einer Veränderung von Post minus Prä zwischen 0.00 und +0.33. In der Generic-AI-Gruppe sinkt sie dagegen durchgehend, mit Werten zwischen -0.43 und -0.86 (Tab. A.9). Beim selbstberichteten Reflexionsverhalten sinkt die Selbsteinschätzung nach der Übung in beiden Gruppen (Tab. A.8).

Vier Post-Survey-Items bilden die Grundlage für die Beantwortung von TF3 in Abschnitt 6.1 und sind in Abbildung 5.2 gegenübergestellt. Beim Item zur Kompetenzentwicklung („Die Arbeit an den Dilemma-Situationen hat meine Fähigkeit verbessert, Prozessentscheidungen zu begründen“) liegt die Reflexionsbot-Gruppe mit M=3.10 leicht über der Generic-AI-Gruppe mit M=2.80. Deutlicher fällt der Unterschied beim Item „war hilfreicher als erwartet“ aus (M=3.40 gegenüber M=2.20). Umgekehrt ist die Bereitschaft zur erneuten Nutzung beim

Reflexionsbot niedriger ($M=2.50$ gegenüber $M=3.20$), und Reflexionsbot-Nutzende hätten häufiger das jeweils andere System bevorzugt ($M=3.30$ gegenüber $M=2.20$).




Abbildung 5.2: Vergleich zentraler Survey-Mittelwerte zwischen Reflexionsbot- und Generic-AI-Gruppe (jeweils $n=10$)

Kognitive Last

Die Skala zur kognitiven Last (1 = very easy bis 5 = very difficult) ergibt kein einheitliches Bild (Tab. A.10). Bei den drei Teilaufgaben und bei den beiden Items zum Umgang mit dem KI-System liegt die Reflexionsbot-Gruppe zwischen 0.00 und 0.40 Skalenpunkten höher, am deutlichsten beim Bewerten der Gegenargumente des Systems ($M=3.10$ gegenüber $M=2.80$). Die zusammenfassende Einschätzung des gesamten kognitiven Aufwands fällt dagegen *gegenläufig* aus. Hier liegt die Generic-AI-Gruppe mit $M=3.20$ über der Reflexionsbot-Gruppe mit $M=3.00$. Angesichts von Standardabweichungen zwischen 1.00 und 1.66 bei zehn Personen je Gruppe sind sämtliche dieser Unterschiede kleiner als die Streuung innerhalb der Gruppen. Aus dieser Skala lässt sich daher weder ableiten, dass der Reflexionsbot als anstrengender empfunden wurde, noch das Gegenteil.

5.2 Illustration des Kategoriensystems an realen Entscheidungssituationen

Um zu verdeutlichen, wie die Reflexionsstufen nach Hatton und Smith [36] auf das vorliegende Material angewendet wurden, wird im Folgenden je ein reales Beispiel pro Stufe herangezogen. Alle Beispiele stammen von Personen, deren Autorenschaft nach Abgleich

mit den Rohdaten (Chatlogs, Zusatzdokumente, Formulierungsvergleiche zwischen Personen) als eindeutig studentisch eingestuft wurde. Sie stammen bewusst nicht alle aus derselben Entscheidungssituation, da die genauere Prüfung der Rohdaten mehrere ursprünglich als studentisch angenommene Texte als KI-generiert entlarvt hat (vgl. Abschnitt 3.5).

Stufe 0, keine eigene Reflexion: Ein Teilnehmer im Team Reflexionsbot antwortet auf wiederholte Rückfragen nur mit: „Stop asking questions!!!“ und liefert zu keinem Zeitpunkt eine eigene inhaltliche Antwort.

Stufe 1, deskriptives Schreiben (Descriptive Writing): Eine Teilnehmerin im Team Reflexionsbot begründet ihre Priorisierung auf mehrfache Rückfrage des Bots hin nur mit: „Health > trustworthiness“. Die Aussage bleibt eine bloße Rangfolge ohne inhaltliche Auseinandersetzung mit dem Gegenargument des Systems.

Stufe 2, deskriptive Reflexion (Descriptive Reflection): Eine Teilnehmerin bei Team AI begründet ihre Wahl von Datensatz A in Situation B des Szenarios SmartDose so: „A gives better reliability but might run into problems when it is later on revealed the data cannot be used and the ai has to be retrained“. Hier wird ein Kriterium (Zuverlässigkeit) benannt und einem konkreten Risiko gegenübergestellt, jedoch ohne die nicht gewählte Option weiter zu erwägen.

Stufe 3, dialogische Reflexion (Dialogic Reflection): Ein Teilnehmer im Team Reflexionsbot wägt in Situation C des Szenarios LearnLoop einen Nachteil explizit gegen einen Vorteil ab: „While there is a risk of context switching, this approach minimizes idle time and maintains momentum.“ Der Nachteil wird benannt und bewusst gegen den Nutzen der eigenen Entscheidung abgewogen.

Stufe 4, kritische Reflexion (Critical Reflection): Für diese Stufe konnte in der gesamten Stichprobe kein Fall mit bestätigter studentischer Autorenschaft gefunden werden. Mehrere Texte erfüllten die formalen Kriterien der Stufe augenscheinlich sehr gut, etwa eine vollständige Abwägung von Datenschutz, Zulassungsfähigkeit und Modellqualität unter ausdrücklichem Verweis auf GDPR und MDR. Beim Abgleich mit den zugehörigen Chatlogs und Zusatzdokumenten stellten sich jedoch ausnahmslos alle diese Texte als KI-generiert heraus, unter anderem, weil zwei unterschiedliche Personen fast wortgleiche Formulierungen einreichten oder weil ein Link zum zugrunde liegenden ChatGPT-Verlauf mitgeliefert wurde. Diese Beobachtung wird in Abschnitt 6.1 als eigenständiger Befund aufgegriffen: sprachlich und strukturell überzeugende Antworten waren in dieser Stichprobe ein stärkeres Indiz für KI-Autorenschaft als für tiefe eigene Reflexion.

Das Beispiel zeigt, dass Reflexionstiefe in den vorliegenden Daten nicht in erster Linie vom verwendeten KI-System abhing, sondern davon, ob eine Person sich überhaupt eigenständig

mit der Entscheidung auseinandersetzte, statt die Aufgabe zu vermeiden oder an die KI zu delegieren. Dass diese Bearbeitungshaltung eher personengebunden als szenarienabhängig ist, zeigt sich daran, dass die Autorenschaft bei 10 der 11 Personen mit zwei Bearbeitungen über beide Szenarien identisch ausfällt. Nur in einem Fall wechselt sie von „studentisch“ zu „unklar“ (vgl. Anhang A.2). Die vollständige Kodierung aller Fälle sowie die Häufigkeitsverteilung je Gruppe sind im Anhang dokumentiert.

5.3 Selbstauskunft und dokumentiertes Bearbeitungsverhalten

Der Abgleich der Autorenschafts-Einstufung aus Abschnitt 3.5 mit den Post-Survey-Antworten derselben Personen (verknüpft über den persönlichen Code, vgl. Abschnitt 3.4) zeigt eine weitere Facette des zentralen Befunds dieser Arbeit. Von 14 Personen, für die sowohl eine Autorenschafts-Einstufung als auch Survey-Daten vorliegen, bearbeiteten vier ihre Szenarien durchgehend eigenständig. Bei den übrigen zehn war mindestens eine Bearbeitung ganz oder teilweise an die KI ausgelagert.

Im Wissenstest zu Scrum und Prozessmodellen schnitt die eigenständig arbeitende Gruppe deutlich besser ab (Mittelwert 5.75 von 6 Punkten) als die Gruppe mit ausgelagerter Bearbeitung (Mittelwert 4.50 von 6 Punkten). Bei der Selbsteinschätzung des eigenen Reflexionsverhaltens im Survey zeigte sich dagegen kein vergleichbarer Unterschied zwischen beiden Gruppen.

Besonders deutlich wird das Missverhältnis bei der wahrgenommenen Nützlichkeit des jeweiligen Systems: Eine Person, die in der qualitativen Kodierung selbst angab, die Aufgaben nur kopiert und das System nie aktiv genutzt zu haben, bewertete es im Survey trotzdem als sehr nützlich für die eigene Reflexion. Umgekehrt bewerteten mehrere Personen mit eindeutig eigenständiger, aber wenig reflektierter Bearbeitung dasselbe System als wenig hilfreich. Selbstauskunft im Fragebogen allein hätte den Unterschied zwischen echter Auseinandersetzung und vollständiger Auslagerung an die KI in diesen Fällen nicht sichtbar gemacht. Erst der Abgleich mit den Rohdaten der Bearbeitung deckte ihn auf. Diese kleine Stichprobe (n=4 gegenüber n=10) erlaubt keine statistische Verallgemeinerung, liefert aber ein inhaltliches Argument dafür, Selbstauskunft und dokumentiertes Verhalten in zukünftigen Studien zu diesem Thema grundsätzlich getrennt zu erheben und gegeneinander zu prüfen.

6 Diskussion

Dieses Kapitel interpretiert die in Kapitel 5 berichteten Ergebnisse: Zunächst werden die Forschungsfragen beantwortet (Abschnitt 6.1) und die Befunde in den Forschungsstand eingeordnet (Abschnitt 6.2), anschließend werden die Grenzen der Untersuchung dargelegt (Abschnitt 6.3) und ein Ausblick auf weiterführende Arbeiten gegeben (Abschnitt 6.5).

6.1 Beantwortung der Forschungsfragen

Die in Abschnitt 1.3 formulierten Teilfragen werden im Folgenden auf Grundlage der qualitativen Kodierung (Abschnitt 3.5), der Survey-Auswertung (Abschnitt 3.4) sowie der in Kapitel 5 berichteten Befunde beantwortet, bevor abschließend die übergeordnete Forschungsfrage zusammengeführt wird.

TF1 – Auslagerung und ungeprüfte Übernahme. Der Reflexionsbot verzichtet bewusst auf direkte Antworten und passt die Tiefe seiner Rückfragen an die Qualität der studentischen Argumentation an (adaptive Tiefe, Abschnitt 4.2). Der deutlichste Unterschied zeigt sich im Anteil vollständiger oder teilweiser Auslagerung der Bearbeitung an die KI: Bei Team AI sind 80 % der kodierten Fälle (12 von 15) nicht eindeutig studentisch, beim Reflexionsbot sind es 50 % (8 von 16, vgl. Abschnitt 5.1). Das Rückfrage-Prinzip geht mit einer geringeren Auslagerungsquote einher, ohne die Auslagerung vollständig zu verhindern, wie die Umgehungsversuche einzelner Personen zeigen (vgl. Abschnitt 5.2). Zugleich ist der Abstand teilweise durch die Aufgabenvorgabe für Team AI mitbedingt und daher als Indiz, nicht als exakte Effektgröße zu lesen (vgl. Abschnitt 6.3). Ein Teil des Unterschieds könnte zudem darauf beruhen, dass der Reflexionsbot keine direkt kopierbare Lösung ausgibt, sodass die geringere Auslagerung nicht allein auf die didaktische Gestaltung, sondern auch auf das Fehlen einer Kopiervorlage zurückgehen kann. In der Generic-AI-Gruppe ist der Anteil ungeprüft übernommener Vorschläge damit höher als beim Reflexionsbot. Gleichzeitig zeigt Abschnitt 5.3, dass die Selbstauskunft im Survey diesen Unterschied allein nicht zuverlässig abbildet: Personen, die nachweislich nur kopiert hatten, bewerteten das jeweilige

System teils trotzdem als hilfreich. Vertiefte Auseinandersetzung entsteht also nicht automatisch durch das bloße Vorhandensein von Rückfragen, sondern hängt von der Bereitschaft der Studierenden ab, sich auf den Dialog einzulassen.

TF2 – Reflexionstiefe und Prozessverständnis. Beim selbsteingeschätzten Prozessverständnis zeigt sich ein differenziertes Bild: Bei Items zum reinen Beschreiben sinkt die Selbsteinschätzung in beiden Gruppen ähnlich stark. Bei Items zum Begründen und Abwägen bleibt die Reflexionsbot-Gruppe stabil oder verbessert sich leicht, während sie in der Generic-AI-Gruppe durchgehend weiter sinkt (vgl. Abschnitt 5.1). Umgekehrt schätzt sich die Generic-AI-Gruppe bei mehreren direkten Reflexions-Items des Post-Surveys (etwa „überlegt, warum die eigenen Entscheidungen angemessen waren“ oder „mehrere Optionen verglichen“) sogar etwas höher ein (Anhang A.6). Das selbstberichtete Bild ist damit insgesamt uneinheitlich und stützt keinen klaren Systemvorteil.

In der tatsächlich gezeigten Reflexionstiefe der studentisch verfassten Bearbeitungen fällt das Ergebnis deutlicher aus, und zwar gegen die Ausgangsannahme dieser Arbeit: Die wenigen Team-AI-Fälle liegen auf Stufe 2, die Reflexionsbot-Fälle überwiegend auf den Stufen 0 und 1 mit einem Einzelfall auf Stufe 3 (Abb. 5.1). Deskriptiv liegt die Vergleichsgruppe damit sowohl im Mittelwert (1.33 gegenüber 0.75) als auch im Median (2.0 gegenüber 0.5) höher. Auf dem Konstrukt, das der Reflexionsbot gezielt fördern soll, schneidet er in dieser Stichprobe also nicht besser ab. Bei drei gegenüber acht auswertbaren Fällen ist dieser Unterschied allerdings nicht belastbar. Bereits ein einzelner Fall verschiebt den Mittelwert der kleineren Gruppe um mehr als 0,3 Stufen, und die drei Team-AI-Fälle sind der Rest einer Gruppe, in der 80 % der Bearbeitungen als nicht eindeutig studentisch ausgeschieden sind. Es ist daher ebenso möglich, dass hier eine positive Selektion der wenigen verbliebenen Fälle sichtbar wird wie ein Nachteil des Reflexionsbots. Als belastbarer Befund bleibt festzuhalten, dass sich ein Vorteil des Reflexionsbots auf dem Zielkonstrukt in diesen Daten nicht zeigt.

Am objektiven Wissenstest zeigt sich zwischen den Systemgruppen ebenfalls kein Vorteil des Reflexionsbots, wobei der Deckeneffekt hier jede Richtungsangabe verbietet (vgl. Abschnitt 5.1). Auch die Aufteilung nach dem Bearbeitungsverhalten trägt weniger, als sie auf den ersten Blick verspricht: Die eigenständig arbeitenden Personen lagen bereits im Prä-Test durchgehend bei der vollen Punktzahl, sodass ihr besseres Post-Ergebnis überwiegend eine vorbestehende Leistungsdifferenz abbildet und keinen Lernzuwachs. Der Zusammenhang zwischen eigenständiger Bearbeitung und Testergebnis ist in diesen Daten daher als Selektionseffekt zu lesen. Die inhaltlich tragfähigere Beobachtung ist eine andere: Wer die Aufgabe an die KI auslagerte, erzeugte Texte, die sich einer Reflexionskodierung von vornherein entziehen. Nicht das Testergebnis, sondern die Bearbeitungshaltung entscheidet darüber, ob überhaupt etwas entsteht, an dem sich Lernen zeigen könnte.

TF3 – Eingeschätzte Kompetenzentwicklung. Die vier hierfür einschlägigen Survey-Items sind in Abschnitt 5.1 berichtet und in Abbildung 5.2 gegenübergestellt. Sie ergeben ein gegenläufiges Bild. Die wahrgenommene Kompetenzentwicklung fällt beim Reflexionsbot leicht positiver aus ($M=3.10$ gegenüber $M=2.80$), und das System übertraf die Erwartungen der Studierenden deutlich stärker ($M=3.40$ gegenüber $M=2.20$). Zugleich ist die Bereitschaft zur erneuten Nutzung geringer ($M=2.50$ gegenüber $M=3.20$) und der Wunsch nach dem jeweils anderen System größer ($M=3.30$ gegenüber $M=2.20$).

Für das Auseinanderfallen von positiverer Einschätzung und geringerer Nutzungspräferenz liegt die Deutung nahe, der Reflexionsbot werde als anstrengender, aber lohnender wahrgenommen. Die erhobene Skala zur kognitiven Last stützt diese Deutung jedoch nicht eindeutig: Bei den Teilaufgaben liegt die Reflexionsbot-Gruppe geringfügig höher, bei der zusammenfassenden Einschätzung des gesamten kognitiven Aufwands dagegen niedriger als die Vergleichsgruppe ($M=3.00$ gegenüber $M=3.20$, vgl. Abschnitt 5.1). Die Anstrengungsdeutung bleibt damit eine plausible, aber unbelegte Erklärung.

Zu berücksichtigen ist ferner, dass das Item „war hilfreicher als erwartet“ keinen absoluten Nutzen misst, sondern einen Abgleich mit einer Erwartung. Die Vergleichsgruppe arbeitete mit Systemen, die sie nach eigener Angabe im Prä-Survey bereits regelmäßig nutzt. Eine positive Überraschung ist dort strukturell unwahrscheinlicher als bei einem unbekannten System. Der deutliche Abstand bei diesem Item kann daher ebenso gut die Neuheit des Reflexionsbots abbilden wie seine didaktische Gestaltung.

TF3 – Wahrgenommene Stärken und Grenzen. Als Stärke des Reflexionsbots zeigen die Daten eine stärkere Anregung zu unabhängigem Denken *als erwartet*, ein deutlicheres Übertreffen der Erwartungen und ein stabileres selbsteingeschätztes Verständnis für Begründung und Abwägung. Der Zusatz „als erwartet“ ist dabei Teil des Items und nicht wegzulassen: Gemessen wurde ein Erwartungsabgleich, nicht das Ausmaß unabhängigen Denkens selbst (Anhang A.6). Als Grenze zeigt sich eine breitere Streuung der Nützlichkeitsbewertung zwischen „sehr nützlich“ und „nicht nützlich“, die zur stark rechtsschiefen Verteilung der Reflexionsstufen mit einem Einzelfall auf Stufe 3 passt (Abschnitt 5.1), sowie eine geringere Bereitschaft zur erneuten Nutzung. Für das generische System gilt umgekehrt eine höhere wahrgenommene Convenience und Nutzungspräferenz, zugleich aber ein deutlich höherer Anteil vollständiger KI-Auslagerung in den tatsächlichen Bearbeitungen.

Zusammenführung zur zentralen Forschungsfrage. Aus den drei Teilfragen ergibt sich ein differenziertes und in Teilen gegenläufiges Bild. In den vorliegenden Daten steht ein didaktisch gestalteter Reflexionsbot vor allem dort mit einer vertieften Auseinandersetzung in Verbindung, wo sich Studierende auf den sokratischen Dialog einlassen: erkennbar an einer geringeren KI-Auslagerungsquote, einem stabileren selbsteingeschätzten Prozessverständnis

bei höherstufigen Kompetenzen und einer positiveren Einschätzung der eigenen Kompetenzentwicklung im Vergleich zu einem generischen System. Auf dem eigentlichen Zielkonstrukt, der in den Texten gezeigten Reflexionstiefe, zeigt sich dagegen kein Vorteil; deskriptiv liegt die Vergleichsgruppe dort sogar höher, bei einer Fallzahl, die keine Richtungsaussage trägt. Am objektiven Wissenstest lässt der Deckeneffekt zwischen den Systemgruppen keine Aussage zu (Abschnitt 5.1), und der Zusammenhang mit eigenständiger Bearbeitung erweist sich bei Betrachtung der Prä-Werte als Selektionseffekt. Der Reflexionsbot wirkt zudem nicht automatisch und nicht für alle Studierenden gleichermaßen. Ein erheblicher Teil der Reflexionsbot-Gruppe vermied die inhaltliche Auseinandersetzung dennoch weitgehend, wickelte Rückfragen aus oder versuchte, das System zu direkten Antworten zu bewegen. Die entscheidende Voraussetzung für das beobachtete Muster ist damit nicht das Werkzeug allein, sondern die Interaktionsbereitschaft der Studierenden, die durch das Werkzeugdesign begünstigt, aber nicht erzwungen werden kann. Diese Deutung ist allerdings explorativ und in Folgestudien gezielt zu prüfen.

6.2 Einordnung in den Forschungsstand

Die vorliegenden Befunde lassen sich an mehreren Stellen mit der in Kapitel 2 aufgearbeiteten Literatur in Verbindung setzen und ergänzen diese um empirische Evidenz aus einem Themenfeld, das dort bislang kaum untersucht war.

TreeInstruct [17] zeigte, dass sokratisches Nachfragen Studierende erfolgreich beim eigenständigen Auffinden einzelner Programmierfehler unterstützen kann, also bei Aufgaben mit einer eindeutig richtigen Lösung. Die vorliegende Arbeit überträgt dieses Prinzip auf Prozessentscheidungen ohne eindeutig richtige Lösung und deutet darauf hin, dass das Prinzip auch dort greifen könnte: Der Anteil vollständig oder teilweise an die KI ausgelagerter Bearbeitungen fällt geringer aus (Abschnitt 6.1). Anders als bei TreeInstruct, dessen Fragebaum den Wissensstand der Studierenden aktiv modelliert, verlässt sich der hier entwickelte Reflexionsbot auf eine einfachere, an der Qualität der jeweils letzten Antwort orientierte adaptive Tiefe (Abschnitt 4.2). Dass Studierende diese vereinfachte Steuerung dennoch gezielt umgehen konnten (Abschnitt 6.5), deutet darauf hin, dass eine differenziertere Modellierung des Antwortverhaltens, wie sie TreeInstruct für Programmierfehler einsetzt, auch für offene Prozessentscheidungen einen lohnenden Ansatzpunkt bieten könnte.

„Reflect Me“ [47] bietet allgemeine, domänenoffene Reflexionsimpulse in Form vorformulierter Prompts, ohne deren Wirksamkeit empirisch zu prüfen. Welche Fragetypen tatsächlich zu tieferer Reflexion führen, bleibt dort offen. Die vorliegende Arbeit liefert hierzu einen

Anhaltspunkt: Gerade die Szenario-Spezifität, also Rückfragen, die konkrete Randbedingungen und Stakeholder eines bestimmten Dilemmas benennen, statt allgemein gehaltene Reflexionsfragen zu stellen, erwies sich als Voraussetzung dafür, dass die adaptive Tiefe überhaupt präzise auf einzelne Argumentationslücken reagieren konnte (Abschnitt 4.2). Für Themenfelder mit konkreten, fachlich geprägten Entscheidungssituationen wie dem Software-Prozessmanagement spricht dies für enger gefasste, kontextspezifische Reflexionswerkzeuge statt allgemeiner Prompt-Sammlungen.

Eine Übersichtsarbeit zum kognitiven Einfluss generativer KI-Werkzeuge wertet 17 Studien aus und findet signifikante Verbesserungen vor allem bei *niedrigstufigen* kognitiven Ergebnissen sowie einen Vorteil angeleiteter gegenüber ungeleiteter Nutzung. Für höherstufige Fähigkeiten wie Erschaffen und Bewerten fällt die Wirkung dagegen ausdrücklich minimal aus [13]. Genau dieses Muster findet sich in den vorliegenden Daten wieder: Der Reflexionsbot liegt beim selbsteingeschätzten Verständnis für Begründung und Abwägung etwas höher als der generische Chatbot, während sich auf dem höherstufigen Zielkonstrukt der gezeigten Reflexionstiefe kein Vorteil zeigt und am objektiven Wissenstest keine Aussage möglich ist. Der eigene Nullbefund auf der Reflexionstiefe steht damit nicht allein, sondern entspricht dem, was die Literatur für höherstufige Kompetenzen berichtet. Die vorliegenden Ergebnisse ergänzen diesen Befund jedoch um eine wichtige Einschränkung: Gutes Design allein garantiert keine tiefere Reflexion, es schafft lediglich die Gelegenheit dazu. Ein erheblicher Teil der Reflexionsbot-Gruppe nutzte diese Gelegenheit nicht, sondern umging sie gezielt. Design und Interaktionsbereitschaft der Nutzenden sind damit als komplementäre, nicht als austauschbare Bedingungen für den Lernerfolg zu verstehen.

Erfahrungsberichte zum Einsatz von KI-Tutoren in der Software-Engineering-Lehre ließen bislang offen, ob solche Systeme tatsächlich zu tieferem Verständnis führen oder vor allem den Bearbeitungsaufwand reduzieren [15], [16]. Die vorliegende Arbeit beantwortet diese Frage differenziert und mit konkreten Zahlen. Der Reflexionsbot reduziert den Bearbeitungsaufwand nicht in dem Sinne, dass er das Ergebnis erleichtert, sondern indem er ihn erschwert, was sich in einer geringeren Wiedernutzungsbereitschaft und einer häufigeren Präferenz für das jeweils andere System niederschlägt (Abschnitt 6.1), und darin könnte ein Ansatzpunkt für ein tieferes Verständnis liegen. Die beiden in den Erfahrungsberichten offengelassenen Möglichkeiten schließen sich damit nicht gegenseitig aus, sondern hängen bei diesem Ansatz systematisch zusammen: mehr Verständnis durch mehr, nicht weniger, Aufwand.

Auch jüngere vergleichende Studien stützen dieses Muster. Ein randomisiertes Experiment in der Programmierausbildung findet, dass ein zurückhaltender, scaffoldender Tutor gegenüber einem direkt antwortenden System die unmittelbare Leistung nicht garantiert steigert und kurzfristige Leistung und tatsächliches Lernen auseinanderfallen können [48]. Ebenso wird

davor gewarnt, dass müheloser KI-Einsatz eine Illusion des Lernens erzeugt, obwohl gerade die produktive Anstrengung den Lernwert ausmacht [54]. Der in dieser Arbeit beobachtete Befund, dass der Reflexionsbot trotz positiverer Einschätzung der eigenen Kompetenzentwicklung seltener erneut genutzt werden würde und zwischen den Systemgruppen keinen objektiven Testvorteil zeigt, fügt sich damit in ein breiteres Bild ein.

Ausdrücklich zu benennen ist jedoch eine Studie, die zu einem anderen Ergebnis kommt. Xi et al. [50] vergleichen einen sokratisch fragenden mit einem direkt antwortenden Dialogagenten bei einer offenen Gestaltungsaufgabe und finden einen Vorteil der sokratischen Bedingung gerade dort, wo die vorliegende Arbeit keinen findet, nämlich im reflexiven Denken einschließlich der Dimension *critical reflection*. Dieser Gegenbefund lässt sich nicht mit der Aufgabenart erklären, da auch dort keine eindeutig richtige Lösung existierte. Drei Unterschiede kommen als Erklärung eher infrage. Erstens der Umfang: Xi et al. intervenierten über sechs Wochen mit wöchentlichen Sitzungen, die vorliegende Untersuchung über eine einzelne Übungseinheit. Dass gerade sehr kurze Interventionen ein systematisch anderes Effektmuster zeigen, ist in der Literatur beschrieben [42]. Zweitens die Fallzahl: 94 zufällig zugeteilte Personen gegenüber 11 auswertbaren Bearbeitungen hier. Drittens die Vergleichsbedingung: Dort stand ein eigens gebauter, in allen übrigen Eigenschaften identischer Kontrollagent zur Verfügung, hier ein frei gewähltes Consumer-System. Die vorliegenden Daten sprechen daher nicht gegen den Befund von Xi et al., sie zeigen vielmehr, dass sich ein solcher Effekt unter den Bedingungen einer einzelnen Übungseinheit nicht reproduzieren lässt. Der Befund dieser Arbeit ist damit eher als Aussage über die Grenzen kurzer Einzelinterventionen zu lesen denn als Aussage über das Prinzip des sokratischen Fragens.

6.3 Limitationen

Die Kodierung der Reflexionsstufen und der Autorenschaft erfolgte durch eine einzelne Person. Eine Zweitkodierung zur Berechnung einer Intercoder-Reliabilität, wie sie für strukturierende qualitative Inhaltsanalysen üblich ist, wurde im Rahmen dieser Arbeit nicht durchgeführt. Die Einordnung einzelner Fälle, insbesondere bei der Kategorie „unklar“, beruht damit auf einer Einzeleinschätzung anhand von Indizien (Kürze, fehlender Chatlog, auffällige stilistische Ähnlichkeit zwischen Personen) und nicht auf einem durch zwei unabhängige Personen abgesicherten Urteil.

Hinzu kommt die geringe Stichprobengröße. Von 31 kodierten Fällen ist die Autorenschaft nur bei 11 eindeutig studentisch (3 bei Team AI, 8 beim Reflexionsbot). Aussagen zur Verteilung der Reflexionsstufen, insbesondere für Team AI, sind bei dieser Fallzahl deskriptiv zu lesen und nicht statistisch verallgemeinerbar. Für Sarma (Team AI) liegt zudem keine eigene Ausgangsantwort vor, was im Datensatz als Ausfall dokumentiert, aber nicht ersetzt werden konnte.

Einschränkend ist zudem zu beachten, dass die zentrale Auslagerungskennzahl (80 % gegenüber 50 %) nicht unabhängig vom Aufgabendesign ist: Team AI war durch die letzte Teilaufgabe („AI Analysis“, vgl. Anhang A.4) ausdrücklich verpflichtet, die eigenen Entscheidungen in ein generisches KI-System einzugeben, während die Reflexionsbot-Gruppe keine vergleichbare Vorgabe erhielt. Ein Teil der bei Team AI beobachteten KI-Artefakte ist damit durch die Aufgabenstellung selbst mit angelegt und nicht allein Ausdruck freiwilliger Auslagerung. Betrachtet man ausschließlich die *gesichert* KI-generierten Fälle, fällt der Gruppenunterschied deutlich geringer aus (Team AI 8 von 15, Reflexionsbot 7 von 16, vgl. Abschnitt 5.1). Der größere Abstand in der 80/50-Kennzahl entsteht erst durch die zusätzlich einbezogene, unsicher eingestufte Restkategorie „unklar“. Die Kennzahl ist daher als Indiz, nicht als exakte Effektgröße zu lesen.

Hinzu kommt eine Asymmetrie in der Datenlage selbst, die genau diese Restkategorie betrifft. Der Reflexionsbot stellte einen Export des vollständigen Gesprächsverlaufs bereit (Abschnitt 4.1), während die Vergleichsgruppe ihre Verläufe manuell sichern musste. Da das Vorliegen eines Chatlogs in der Autorenschaftskodierung als Indikator für studentische Bearbeitung und sein Fehlen als Indikator für die Kategorie „unklar“ eingeht (Anhang A.1), ist die Einstufung „unklar“ in der Vergleichsgruppe strukturell wahrscheinlicher. Tatsächlich entfallen vier der fünf „unklar“-Fälle auf Team AI, und in zwei davon nennt die Kodieranmerkung das fehlende Chatlog ausdrücklich als Grund (Anhang A.2). Der Vergleich der gesichert KI-generierten Fälle ist aus diesem Grund die belastbarere der beiden Kennzahlen.

Eine weitere Einschränkung betrifft die Interventionstreue. Die unabhängige Variable dieser Arbeit ist ein System, das definitionsgemäß keine direkten Lösungen liefert, sondern konsequent zurückfragt. Die Kodierung dokumentiert jedoch drei Fälle, in denen der Bot diesem Prinzip unter anhaltendem Druck der Studierenden nicht mehr folgte und schließlich doch direkt antwortete (Anhang A.2, vgl. Abschnitt 6.5). Ein systematischer Manipulation Check, der geprüft hätte, ob die Intervention in allen Fällen wie spezifiziert wirksam war, wurde nicht durchgeführt. Verglichen wurde damit strenggenommen nicht ein durchgängig sokratisches System mit einem generischen, sondern ein sokratisches System, das in einem Teil der Fälle nachgab. Da dieses Nachgeben in Richtung der Vergleichsbedingung wirkt, dürfte es

die beobachteten Gruppenunterschiede eher verkleinert als vergrößert haben; belegen lässt sich das mit den vorliegenden Daten jedoch nicht.

Schließlich ist eine sprachliche Asymmetrie zwischen den Bedingungen zu berücksichtigen. Der Reflexionsbot antwortet durchgängig auf Englisch, unabhängig von der Eingabesprache (Abschnitt 4.2), während die frei gewählten Vergleichssysteme in der Sprache der Eingabe antworten. Für überwiegend deutschsprachige Studierende im ersten Fachsemester entsteht dadurch eine zusätzliche Verarbeitungshürde, die ausschließlich die Interventionsgruppe betrifft. Ein Teil der beobachteten kurzen oder ausweichenden Antworten in dieser Gruppe könnte auf die Sprachbarriere und nicht auf mangelnde Reflexionsbereitschaft zurückgehen. Die didaktische Begründung für die englische Interaktionssprache bleibt davon unberührt, sie ersetzt aber nicht die methodische Einschränkung.

Auch die Generalisierbarkeit der Ergebnisse ist begrenzt. Die Stichprobe stammt aus einer einzigen Übungseinheit einer einzigen Lehrveranstaltung an einer einzigen Hochschule und besteht überwiegend aus Studierenden des ersten Fachsemesters (vgl. Abschnitt 3.3). Ob sich die beobachteten Effekte auf andere Kohorten, Studiengänge oder Hochschulen übertragen lassen, kann diese Arbeit nicht beantworten. Die Zuteilung zu den beiden Gruppen erfolgte durch die Übungsleitung und nicht dokumentiert randomisiert. Systematische Ausgangsunterschiede zwischen den Gruppen lassen sich daher nicht vollständig ausschließen, auch wenn die in Anhang A.6 berichteten Vorerfahrungswerte auf weitgehend vergleichbare Gruppen hindeuten. Da die Teilnahme freiwillig war, ist zudem ein Selbstselektionseffekt nicht auszuschließen, denn Studierende, die sich für eine Teilnahme entschieden, unterscheiden sich möglicherweise bereits in ihrer Reflexionsbereitschaft von jenen, die nicht teilnahmen. Schließlich wurde der Reflexionsbot ausschließlich mit einem einzigen Sprachmodell (`gpt-4o-mini`) umgesetzt und getestet. Inwiefern sich die Ergebnisse mit einem anderen oder leistungsfähigeren Modell reproduzieren lassen, bleibt offen. Hinzu kommt eine Asymmetrie zwischen den Bedingungen. Während der Reflexionsbot über ein festes Modell und eine feste Systemnachricht exakt spezifiziert ist, war die Vergleichsbedingung ein frei gewähltes Consumer-System mit zum Erhebungszeitpunkt nicht kontrolliertem Modell (vgl. Abschnitt 3.4). Der Vergleich ist daher als Kontrast zwischen einem gezielt gestalteten und einem typischen alltäglichen KI-Zugang zu verstehen, nicht als kontrollierter Modellvergleich. Schließlich wurde nicht systematisch geprüft, ob der Reflexionsbot in Einzelfällen sachlich falsche Rückfragen stellte (Halluzinationen, vgl. Abschnitt 2.1). Inhaltlich fehlgeleitete Rückfragen könnten die Reflexion vereinzelt in eine falsche Richtung gelenkt haben.

6.4 Handlungsempfehlungen für den Einsatz in der Software-Engineering-Lehre

Aus den berichteten Befunden lassen sich sechs Empfehlungen für Lehrende ableiten, die ein reflexionsorientiertes KI-System in einer Lehrveranstaltung einsetzen möchten. Sie sind als Gestaltungshinweise für vergleichbare Übungssettings zu verstehen und teilen die Reichweite der in Abschnitt 6.3 genannten Einschränkungen, insbesondere die kleine Stichprobe und den einmaligen Erhebungszeitpunkt.

Das Werkzeug in Aufgaben- und Bewertungsdesign einbetten, nicht danebenstellen. Der zentrale Befund dieser Arbeit ist, dass das Systemdesign allein die Auseinandersetzung nicht erzwingt. Ein erheblicher Teil der Reflexionsbot-Gruppe wich den Rückfragen aus oder versuchte gezielt, das System zu umgehen (Abschnitt 6.1). Ein Reflexionswerkzeug sollte deshalb nicht als optionales Zusatzangebot eingeführt werden, sondern in eine Aufgabenstellung eingebettet sein, deren Bearbeitung ohne die Auseinandersetzung mit den Rückfragen nicht sinnvoll möglich ist.

Den Prozess bewerten, nicht das Produkt. Die Kodierung zeigt, dass sprachlich und strukturell überzeugende Abgaben in dieser Stichprobe ein stärkeres Indiz für KI-Autorenschaft waren als für tiefe eigene Reflexion (Abschnitt 5.2). Ein fertiger Text ist damit als Beurteilungsgrundlage für Reflexionsleistung nur noch eingeschränkt geeignet. Der Gesprächsverlauf mit dem System ist es dagegen sehr wohl, da in ihm sichtbar wird, ob eine Person auf Rückfragen eingegangen ist. Lehrende sollten den Chatverlauf daher zum verpflichtenden Bestandteil der Abgabe machen und ihn in die Bewertung einbeziehen.

Das System gegen Umgehungsversuche härten. In mehreren dokumentierten Fällen gab der Bot unter anhaltendem Druck nach und lieferte doch eine direkte Antwort (Anhang A.2). Wer ein solches System einsetzt, sollte damit rechnen, dass Studierende diese Grenze aktiv testen, und die Systemnachricht entsprechend absichern, etwa durch eine explizite Regel für wiederholte Direktanfragen sowie durch Erkennung eingefügter vollständiger Aufgabenstellungen (vgl. Abschnitt 6.5).

Erwartungen vorab rahmen. Der Reflexionsbot übertraf die Erwartungen der Studierenden deutlich stärker als das generische System, wurde zugleich aber seltener zur erneuten Nutzung gewählt (Abschnitt 5.1). Ein System, das bewusst keine Lösungen liefert, widerspricht der Nutzungserfahrung, die Studierende aus generischen Assistenzsystemen mitbringen. Eine kurze Einordnung vor dem Einsatz, warum das System nicht antwortet und worin der Lernzweck dieser Zurückhaltung besteht, dürfte die Akzeptanz erhöhen und ist mit geringem Aufwand umsetzbar.

Aufgabentypen gezielt auswählen. Die vorliegende Arbeit setzt sokratisches Nachfragen bei Prozessentscheidungen ohne eindeutig richtige Lösung ein, also bei offenen Dilemmata mit konkurrierenden Zielkriterien. Für solche Aufgaben erwies sich die Szenario-Spezifität der Rückfragen als Voraussetzung dafür, dass die adaptive Tiefe präzise auf einzelne Argumentationslücken reagieren konnte (Abschnitt 6.2). Bei Aufgaben mit eindeutiger Lösung sowie bei rein faktenbezogenen Inhalten ist der Mehrwert dagegen fraglich, zumal die Literatur die Wirkung generativer Systeme gerade bei niedrigstufigen kognitiven Zielen als am deutlichsten beschreibt [13].

Sprache und Zugänglichkeit bewusst entscheiden. Die durchgängig englische Interaktionssprache war didaktisch begründet (Abschnitt 4.2), stellt für deutschsprachige Erstsemester aber eine zusätzliche Hürde dar, die im Vergleichssystem nicht bestand (Abschnitt 6.3). In einer Lehrveranstaltung ohne internationale Teilnehmende spricht wenig dagegen, das System in der Unterrichtssprache antworten zu lassen. Andernfalls sollte die Sprachwahl gegenüber den Studierenden begründet werden.

6.5 Ausblick

Aus den Ergebnissen und Limitationen dieser Arbeit lassen sich drei Richtungen für die Weiterentwicklung ableiten: die technische Härtung des Reflexionsbots selbst, die methodische Absicherung der Auswertung sowie offene Forschungsfragen, die über den Rahmen dieser Arbeit hinausgehen.

Technische Weiterentwicklung des Reflexionsbots. Mehrere Fälle in der vorliegenden Stichprobe zeigen, dass Studierende gezielt versuchten, die Rückfrage-Logik des Bots zu umgehen: Eine Person forderte wiederholt „Alternative Lösung bitte“ und drohte dem System, um eine direkte Lösung zu erzwingen, eine andere drängte so lange auf Direktantworten, bis der Bot nachgab, und eine dritte legte dem Bot einen fertigen Lösungsansatz vor, als kenne sie das Thema bereits, um ihn zu einer Bestätigung statt einer Rückfrage zu bewegen. In allen drei Fällen gab der Bot dem Druck letztlich nach. Eine Weiterentwicklung sollte deshalb gezielt gegen solche Umgehungsversuche gehärtet werden, etwa indem copy-paste-artige Eingaben (vollständige Aufgabenstellungen oder bereits fertige Lösungen) erkannt und mit einer Rückfrage statt einer Bestätigung beantwortet werden, und indem die Systemnachricht explizit anweist, auf wiederholten Druck nicht nachzugeben, sondern die Rückfrage-Strategie konsequent beizubehalten. Prompt-Engineering-Muster für robuste, manipulationsresistente Systemnachrichten [31] bieten dafür einen methodischen Ausgangspunkt.

Methodische Weiterentwicklung. Wie in Abschnitt 6.3 dargelegt, wurde die Kodierung in dieser Arbeit von einer einzelnen Person vorgenommen. Eine Folgeuntersuchung sollte eine

echte Zweitkodierung durch eine unabhängige Person vorsehen und die Übereinstimmung, etwa über Cohens Kappa, berichten. Ebenso sollte das Mini-Experiment über mehrere Semester oder Kohorten wiederholt werden, um die aktuell sehr kleine studentische Teilstichprobe ($n=11$ von 31 Fällen) zu vergrößern und belastbarere Aussagen zur Verteilung der Reflexionsstufen je Gruppe zu ermöglichen. Eine Ausweitung auf weitere Lehrveranstaltungen, Studiengänge oder Hochschulen würde zugleich prüfbar machen, ob sich die Befunde über den hier untersuchten Kontext hinaus übertragen lassen.

Am Untersuchungsdesign selbst lassen sich drei weitere Einschränkungen gezielt beheben. Beide Gruppen sollten identische Aufgabenanforderungen erhalten, damit die Auslagerungskennzahl nicht durch die Aufgabenstellung selbst mitbestimmt wird. Der Gegencheck mit einem generischen System müsste dafür entweder für beide Gruppen vorgesehen sein oder für beide entfallen. Die Zuteilung zu den Gruppen sollte zudem dokumentiert randomisiert erfolgen, um systematische Ausgangsunterschiede auszuschließen. Um den Selbstselektionseffekt zu verringern, bietet sich statt einer freiwilligen Anmeldung eine Vollerhebung innerhalb der regulären Übung mit Widerspruchsmöglichkeit an.

Auch die Vergleichsbedingung und die eingesetzten Instrumente lassen sich schärfen. Statt eines frei gewählten Consumer-Systems könnte die Vergleichsgruppe dasselbe Sprachmodell mit einer neutralen Systemnachricht nutzen. Damit ließe sich der didaktische Gestaltungseffekt vom Modelleffekt trennen, der im vorliegenden Design vermischt bleibt. Eine Replikation mit mindestens einem weiteren Sprachmodell würde zusätzlich zeigen, ob die Befunde modellabhängig sind. Der Wissenstest sollte schwieriger angelegt werden, da beide Gruppen bereits im Prä-Test nahe der Höchstpunktzahl lagen und sich Lernzuwächse dadurch kaum abbilden ließen (vgl. Abschnitt 5.1). Schließlich sollten die Chatverläufe zusätzlich daraufhin kodiert werden, ob die Rückfragen des Bots sachlich zutreffend waren, um mögliche Fehlleitungen durch Halluzinationen von den Effekten des Rückfrage-Prinzips zu trennen.

Offene Forschungsfrage. Die Ergebnisse dieser Arbeit legen einen Zielkonflikt offen, der über den Rahmen dieser Arbeit hinausgeht: Der Reflexionsbot steht zwar bei den Studierenden, die sich auf ihn einlassen, mit tieferer Reflexion in Verbindung, wird aber gleichzeitig als anstrengender empfunden und seltener zur erneuten Nutzung gewählt als ein generisches System (Abschnitt 6.1). Künftige Arbeiten könnten systematisch untersuchen, wie viel Widerstand durch Rückfragen optimal ist, bevor Studierende die Auseinandersetzung ganz vermeiden, und ob sich dieser Zielkonflikt durch ein noch stärker adaptives Vorgehen entschärfen lässt, das die Hartnäckigkeit der Rückfragen individuell an die Frustrationstoleranz der jeweiligen Person anpasst.

7 Fazit

Ausgangspunkt dieser Arbeit war die Frage, ob ein gezielt für Reflexion statt für schnelle Antworten gestaltetes KI-System Studierende bei Prozessentscheidungen im Software Engineering anders unterstützt als ein generisches KI-System. Dazu wurde ein Reflexionsbot konzipiert und entwickelt, der Studierende durch sokratisches Fragen und adaptive Antworttiefe statt direkter Lösungen begleitet (Kapitel 4), und im Rahmen eines Mini-Experiments in der Lehrveranstaltung „Grundlagen des Software Engineering 1“ einer Vergleichsgruppe gegenübergestellt, die mit einem generischen KI-System arbeitete. Die entstandenen Bearbeitungen und Chatverläufe wurden mittels strukturierender qualitativer Inhaltsanalyse nach dem Reflexionsstufenmodell von Hatton und Smith kodiert und mit den Ergebnissen eines Prä-Post-Surveys zusammengeführt (Kapitel 3).

Das zentrale Ergebnis fällt vorsichtiger aus, als die Ausgangserwartung nahelegte: In der Reflexionsbot-Gruppe ist der Anteil der Bearbeitungen ohne eindeutig studentische Autorenschaft geringer als in der Vergleichsgruppe (50 % gegenüber 80 %). Dieser Rohabstand ist jedoch teilweise durch die Aufgabenvorgabe für die Vergleichsgruppe bedingt und fällt bei den gesichert KI-generierten Fällen deutlich kleiner aus (Abschnitt 5.1). Die direkten Lernmaße stützen keinen Systemvorteil. Am objektiven Wissenstest lässt der Deckeneffekt zwischen den Systemgruppen keine Aussage zu, und in der gezeigten Reflexionstiefe der studentischen Bearbeitungen liegt die Vergleichsgruppe deskriptiv sogar höher, bei einer Fallzahl von drei gegenüber acht auswertbaren Fällen, die keine Richtungsangabe trägt. Ein günstigeres Bild ergibt sich vor allem beim selbsteingeschätzten Verständnis für Begründung und Abwägung, das in der Reflexionsbot-Gruppe stabil bleibt oder leicht steigt, während es in der Vergleichsgruppe sinkt. Reflexionstiefe hing in den vorliegenden Daten damit weniger vom eingesetzten Werkzeug ab als von der Bereitschaft der Studierenden, sich auf den Dialog einzulassen. Ein erheblicher Teil der Reflexionsbot-Gruppe wich den Rückfragen dennoch aus oder versuchte, das System zu direkten Antworten zu bewegen (Abschnitt 6.1).

Die in Kapitel 1 formulierte Sorge, dass generische KI-Systeme das ungeprüfte Übernehmen von Lösungen begünstigen, ist mit den vorliegenden Daten vereinbar. Für die Annahme, dass ein didaktisch gezielt gestaltetes System dem entgegenwirkt, gilt das ebenfalls, ein Beleg ist

sie jedoch nicht. Der deutlichste Unterschied entsteht in einer Kennzahl, die durch die Aufgabenstellung für die Vergleichsgruppe mitbedingt ist und zusätzlich durch eine Asymmetrie in der Verfügbarkeit der Chatverläufe beeinflusst wird; bei den gesichert KI-generierten Fällen schrumpft der Abstand auf ein Maß, das bei dieser Fallzahl nicht mehr interpretierbar ist (Abschnitt 6.3). Für die Praxis folgt daraus vor allem, dass die Gestaltung eines KI-Systems die Notwendigkeit nicht ersetzt, Studierende zur inhaltlichen Auseinandersetzung zu motivieren. Konkrete Empfehlungen hierzu finden sich in Abschnitt 6.4.

Diese Arbeit deutet insgesamt darauf hin, dass didaktisch gestaltete KI-Systeme das Potenzial haben, oberflächliche Nutzung generativer KI in der Hochschullehre zu reduzieren und – bei Studierenden, die sich darauf einlassen – tiefere Reflexion zu begünstigen. Auf dem direkten Reflexionsstufenmaß zeigt sich dieses Potenzial in den vorliegenden Daten allerdings nicht. Ob es tatsächlich zum Tragen kommt, entscheidet sich zudem nicht allein am technischen Design des Systems, sondern daran, ob und wie sich Studierende auf das Angebot zur Reflexion einlassen.

Literatur

- [1] E. Kasneci u. a., „ChatGPT for Good? On Opportunities and Challenges of Large Language Models for Education,“ *Learning and Individual Differences*, Jg. 103, S. 102 274, 1. Apr. 2023, ISSN: 1041-6080. DOI: 10.1016/j.lindif.2023.102274 besucht am 16. Mai 2026. Adresse: <https://www.sciencedirect.com/science/article/pii/S1041608023000195>
- [2] L. Labadze, M. Grigolia und L. Machaidze, „Role of AI chatbots in education: Systematic literature review,“ *International Journal of Educational Technology in Higher Education*, Jg. 20, Nr. 1, S. 56, 31. Okt. 2023, ISSN: 2365-9440. DOI: 10.1186/s41239-023-00426-1 besucht am 20. März 2026. Adresse: <https://doi.org/10.1186/s41239-023-00426-1>
- [3] J. von Garrel und J. Mayer, „Künstliche Intelligenz im Studium: Eine quantitative Längsschnittstudie zur Nutzung KI-basierter Tools durch Studierende (2023 & 2025),“ Hochschule Darmstadt, Darmstadt, März 2025. DOI: 10.48444/h_docs-pub-533 besucht am 18. Aug. 2026.
- [4] A. Marczuk, F. Multrus, T. Hinz und S. Strauß, „Künstliche Intelligenz (KI) im Studienalltag: Einschätzungen von Studierenden zum Einsatz von KI an deutschen Hochschulen,“ Deutsches Zentrum für Hochschul- und Wissenschaftsforschung (DZHW), Hannover, DZHW Brief 02/2025, 2025. DOI: 10.34878/2025.02.dzhw_brief besucht am 18. Aug. 2026.
- [5] W. M. Lim, A. Gunasekara, J. L. Pallant, J. I. Pallant und E. Pechenkina, „Generative AI and the Future of Education: Ragnarök or Reformation? A Paradoxical Perspective from Management Educators,“ *The International Journal of Management Education*, Jg. 21, Nr. 2, S. 100 790, 1. Juli 2023, ISSN: 1472-8117. DOI: 10.1016/j.ijme.2023.100790 besucht am 16. Mai 2026. Adresse: <https://www.sciencedirect.com/science/article/pii/S1472811723000289>
- [6] C. K. Y. Chan, „A comprehensive AI policy education framework for university teaching and learning,“ *International Journal of Educational Technology in Higher Education*, Jg. 20, Nr. 1, S. 38, 7. Juli 2023, ISSN: 2365-9440. DOI: 10.1186/s41239-023-00408-3 besucht am 16. Mai 2026. Adresse: <https://doi.org/10.1186/s41239-023-00408-3>

- [7] R. Hall, „Generative AI and re-weaving a pedagogical horizon of social possibility,“ *International Journal of Educational Technology in Higher Education*, Jg. 21, Nr. 1, S. 12, 12. Feb. 2024, ISSN: 2365-9440. DOI: 10.1186/s41239-024-00445-6 besucht am 20. März 2026. Adresse: <https://doi.org/10.1186/s41239-024-00445-6>
- [8] S. Nikolic u. a., „ChatGPT, Copilot, Gemini, SciSpace and Wolfram versus Higher Education Assessments: An Updated Multi-Institutional Study of the Academic Integrity Impacts of Generative Artificial Intelligence (GenAI) on Assessment, Teaching and Learning in Engineering,“ *Australasian Journal of Engineering Education*, Jg. 29, Nr. 2, S. 126–153, 2. Juli 2024, ISSN: 2205-4952. DOI: 10.1080/22054952.2024.2372154 besucht am 19. März 2026. Adresse: <https://doi.org/10.1080/22054952.2024.2372154>
- [9] A. A. B. Jwair, „Generative Artificial Intelligence in Higher Education: Students’ Journey through Opportunities, Challenges, and the Horizons of Academic Transformation,“ *Cogent Education*, Jg. 12, Nr. 1, S. 2589495, 31. Dez. 2025, ISSN: null. DOI: 10.1080/2331186X.2025.2589495 besucht am 15. März 2026. Adresse: <https://doi.org/10.1080/2331186X.2025.2589495>
- [10] D. Baidoo-Anu und L. Owusu Ansah. „Education in the Era of Generative Artificial Intelligence (AI): Understanding the Potential Benefits of ChatGPT in Promoting Teaching and Learning.“ Social Science Research Network: 4337484, besucht am 16. Mai 2026. Adresse: <https://papers.ssrn.com/abstract=4337484> Vorveröffentlichung.
- [11] N. J. Francis, S. Jones und D. P. Smith, „Generative AI in Higher Education: Balancing Innovation and Integrity,“ *British Journal of Biomedical Science*, Jg. 81, S. 14048, 9. Jan. 2025, ISSN: 2474-0896. DOI: 10.3389/bjbs.2024.14048 besucht am 15. März 2026. Adresse: <https://www.frontierspartnerships.org/journals/british-journal-of-biomedical-science/articles/10.3389/bjbs.2024.14048/full>
- [12] D. R. E. Cotton, P. A. Cotton und J. R. Shipway, „Chatting and Cheating: Ensuring Academic Integrity in the Era of ChatGPT,“ *Innovations in Education and Teaching International*, Jg. 61, Nr. 2, S. 228–239, 3. März 2024, ISSN: 1470-3297. DOI: 10.1080/14703297.2023.2190148 besucht am 16. Mai 2026. Adresse: <https://doi.org/10.1080/14703297.2023.2190148>
- [13] X. Qu, J. Sherwood, P. Liu und N. Aleisa, „Generative AI Tools in Higher Education: A Meta-Analysis of Cognitive Impact,“ in *Proceedings of the Extended Abstracts of the CHI Conference on Human Factors in Computing Systems*, Yokohama, Japan: ACM, 2025, S. 1–9. DOI: 10.1145/3706599.3719841 besucht am 19. März 2026. Adresse: <https://dl.acm.org/doi/10.1145/3706599.3719841>

- [14] C. Sengul, R. Neykova und G. Destefanis, „Software engineering education in the era of conversational AI: Current trends and future directions,“ *Frontiers in Artificial Intelligence*, Jg. 7, 29. Aug. 2024, ISSN: 2624-8212. DOI: 10.3389/frai.2024.1436350 besucht am 20. März 2026. Adresse: <https://www.frontiersin.org/journals/artificial-intelligence/articles/10.3389/frai.2024.1436350/full>
- [15] E. Frankford, C. Sauerwein, P. Bassner, S. Krusche und R. Breu, „AI-Tutoring in Software Engineering Education,“ in *Proceedings of the 46th International Conference on Software Engineering: Software Engineering Education and Training*, 14. Apr. 2024, S. 309–319. DOI: 10.1145/3639474.3640061 arXiv: 2404.02548 [cs.SE]. besucht am 16. Mai 2026. Adresse: <http://arxiv.org/abs/2404.02548>
- [16] L. Happe, D. Fuchß, L. Hüttner, K. Marquardt und A. Koziolk. „An Experience Report on a Pedagogically Controlled, Curriculum-Constrained AI Tutor for SE Education.“ arXiv: 2512.11882 [cs.CY], besucht am 16. Mai 2026. Adresse: <http://arxiv.org/abs/2512.11882> Vorveröffentlichung.
- [17] P. Kargupta, I. Agarwal, D. H. Tur und J. Han, „Instruct, Not Assist: LLM-based Multi-Turn Planning and Hierarchical Questioning for Socratic Code Debugging,“ in *Findings of the Association for Computational Linguistics: EMNLP 2024*, Y. Al-Onaizan, M. Bansal und Y.-N. Chen, Hrsg., Miami, Florida, USA: Association for Computational Linguistics, Nov. 2024, S. 9475–9495. DOI: 10.18653/v1/2024.findings-emnlp.553 besucht am 16. Mai 2026. Adresse: <https://aclanthology.org/2024.findings-emnlp.553/>
- [18] H. Gresch, M. Hasselhorn und S. Bögeholz, „Enhancing Decision-Making in STSE Education by Inducing Reflection and Self-Regulated Learning,“ *Research in Science Education*, Jg. 47, Nr. 1, S. 95–118, 1. Feb. 2017, ISSN: 1573-1898. DOI: 10.1007/s11165-015-9491-9 besucht am 19. März 2026. Adresse: <https://doi.org/10.1007/s11165-015-9491-9>
- [19] A. Vaswani u. a., „Attention Is All You Need,“ in *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, Curran Associates, 2017. DOI: 10.48550/arXiv.1706.03762 arXiv: 1706.03762 [cs.CL]. besucht am 19. Juni 2026. Adresse: <http://arxiv.org/abs/1706.03762> Vorveröffentlichung.
- [20] T. B. Brown u. a., „Language Models Are Few-Shot Learners,“ in *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*, Curran Associates, 2020. DOI: 10.48550/arXiv.2005.14165 arXiv: 2005.14165 [cs.CL]. besucht am 19. Juni 2026. Adresse: <http://arxiv.org/abs/2005.14165> Vorveröffentlichung.
- [21] J. Wei u. a. „Emergent Abilities of Large Language Models.“ arXiv: 2206.07682 [cs.CL], besucht am 19. Juni 2026. Adresse: <http://arxiv.org/abs/2206.07682> Vorveröffentlichung.

- [22] W. X. Zhao u. a. „A Survey of Large Language Models.“ arXiv: 2303.18223, besucht am 20. Juni 2026. Adresse: <https://arxiv.org/abs/2303.18223> Vorveröffentlichung.
- [23] J. Wei u. a., „Finetuned Language Models Are Zero-Shot Learners,“ in *Proceedings of the 10th International Conference on Learning Representations (ICLR 2022)*, 2022. DOI: 10.48550/arXiv.2109.01652 arXiv: 2109.01652 [cs.CL]. besucht am 6. Juli 2026. Adresse: <https://arxiv.org/abs/2109.01652> Vorveröffentlichung.
- [24] L. Ouyang u. a., „Training Language Models to Follow Instructions with Human Feedback,“ in *Advances in Neural Information Processing Systems 35 (NeurIPS 2022)*, Curran Associates, 2022. DOI: 10.48550/arXiv.2203.02155 arXiv: 2203.02155 [cs.CL]. besucht am 21. Juni 2026. Adresse: <https://arxiv.org/abs/2203.02155> Vorveröffentlichung.
- [25] M. Garcia u. a. „A Systematic Mapping Study on Chatbots in Programming Education.“ arXiv: 2509.08857 [cs.SE], besucht am 16. Mai 2026. Adresse: <http://arxiv.org/abs/2509.08857> Vorveröffentlichung.
- [26] A. Yehudai u. a. „Survey on Evaluation of LLM-based Agents.“ arXiv: 2503.16416, besucht am 20. Juni 2026. Adresse: <https://arxiv.org/abs/2503.16416> Vorveröffentlichung.
- [27] OpenAI. „Chat Completions API,“ OpenAI, besucht am 21. Juni 2026. Adresse: <https://platform.openai.com/docs/guides/chat-completions>
- [28] P. Liu, W. Yuan, J. Fu, Z. Jiang, H. Hayashi und G. Neubig, „Pre-Train, Prompt, and Predict: A Systematic Survey of Prompting Methods in Natural Language Processing,“ *ACM Computing Surveys*, Jg. 55, Nr. 9, S. 1–35, 2023. DOI: 10.48550/arXiv.2107.13586 arXiv: 2107.13586 [cs.CL]. besucht am 6. Juli 2026. Adresse: <https://arxiv.org/abs/2107.13586> Vorveröffentlichung.
- [29] P. Sahoo, A. K. Singh, S. Saha, V. Jain, S. Mondal und A. Chadha. „A Systematic Survey of Prompt Engineering in Large Language Models: Techniques and Applications.“ arXiv: 2402.07927 [cs.AI], besucht am 6. Juli 2026. Adresse: <https://arxiv.org/abs/2402.07927> Vorveröffentlichung.
- [30] J. Wei u. a., „Chain-of-Thought Prompting Elicits Reasoning in Large Language Models,“ in *Advances in Neural Information Processing Systems 35 (NeurIPS 2022)*, Curran Associates, 2022. DOI: 10.48550/arXiv.2201.11903 arXiv: 2201.11903 [cs.CL]. besucht am 6. Juli 2026. Adresse: <https://arxiv.org/abs/2201.11903> Vorveröffentlichung.
- [31] J. White u. a. „A Prompt Pattern Catalog to Enhance Prompt Engineering with ChatGPT.“ arXiv: 2302.11382 [cs.SE], besucht am 6. Juli 2026. Adresse: <https://arxiv.org/abs/2302.11382> Vorveröffentlichung.

- [32] Z. Ji u. a., „Survey of hallucination in natural language generation,“ *ACM Computing Surveys*, Jg. 55, Nr. 12, S. 1–38, 2023. DOI: 10.1145/3571730
- [33] D. Wood, J. S. Bruner und G. Ross, „The role of tutoring in problem solving,“ *Journal of Child Psychology and Psychiatry*, Jg. 17, Nr. 2, S. 89–100, Apr. 1976. DOI: 10.1111/j.1469-7610.1976.tb00381.x
- [34] J. Van de Pol, M. Volman und J. Beishuizen, „Scaffolding in teacher–student interaction: A decade of research,“ *Educational Psychology Review*, Jg. 22, Nr. 3, S. 271–296, Sep. 2010. DOI: 10.1007/s10648-010-9127-6
- [35] C. Chin, „Teacher questioning in science classrooms: Approaches that stimulate productive thinking,“ *Journal of Research in Science Teaching*, Jg. 44, Nr. 6, S. 815–843, Aug. 2007. DOI: 10.1002/tea.20171
- [36] N. Hatton und D. Smith, „Reflection in teacher education: Towards definition and implementation,“ *Teaching and Teacher Education*, Jg. 11, Nr. 1, S. 33–49, 1995, ISSN: 0742-051X. DOI: 10.1016/0742-051X(94)00012-U besucht am 7. Juli 2026. Adresse: <https://www.sciencedirect.com/science/article/abs/pii/0742051X9400012U>
- [37] U. Kuckartz, *Mixed Methods: Methodologie, Forschungsdesigns und Analyseverfahren*. Wiesbaden: Springer VS, 2014, ISBN: 978-3-531-17628-4. DOI: 10.1007/978-3-531-93267-5 besucht am 8. Juli 2026. Adresse: <https://doi.org/10.1007/978-3-531-93267-5>
- [38] J. W. Creswell und V. L. Plano Clark, *Designing and Conducting Mixed Methods Research*, 3. Aufl. Thousand Oaks, CA: SAGE Publications, 2018, ISBN: 9781483344379.
- [39] N. Döring und J. Bortz, *Forschungsmethoden und Evaluation in den Sozial- und Humanwissenschaften*, 6. Aufl. Berlin, Heidelberg: Springer, 2023, ISBN: 978-3-662-64761-5. DOI: 10.1007/978-3-662-64762-2 besucht am 21. Juli 2026. Adresse: <https://doi.org/10.1007/978-3-662-64762-2>
- [40] K. Wannemacher, E. Bosse, M. Lübcke und A. Kaemena, „Wie KI Studium und Lehre verändert: Anwendungsfelder, Use-Cases und Gelingensbedingungen,“ Hochschulforum Digitalisierung, Berlin, Arbeitspapier 87, Apr. 2025. besucht am 18. Aug. 2026. Adresse: https://hochschulforumdigitalisierung.de/wp-content/uploads/2025/04/HFD_AP_87_Wie_KI_Studium_und_Lehre_veraendert_final.pdf
- [41] X. Wu, P. Zhu, J. Zhang, M. Yin und Y. Wang, „ChatGPT’s impact on student learning outcomes: A meta-analysis of 35 experimental studies,“ *Humanities and Social Sciences Communications*, 2026. DOI: 10.1057/s41599-026-07019-z
- [42] E. Alemdag, „The effect of chatbots on learning: A meta-analysis of empirical research,“ *Journal of Research on Technology in Education*, 2023. DOI: 10.1080/15391523.2023.2255698

- [43] C. McGrath, A. Farazouli und T. Cerratto Pargman, „Generative AI chatbots in higher education: A review of an emerging research area,“ *Higher Education*, 2024. DOI: 10.1007/s10734-024-01288-w
- [44] S. Elnaffar, F. Rashidi und A. Z. Abualkishik. „Teaching with AI: A Systematic Review of Chatbots, Generative Tools, and Tutoring Systems in Programming Education.“ arXiv:2510.03884, Preprint, besucht am 18. Aug. 2026. Adresse: <https://arxiv.org/abs/2510.03884>
- [45] B. Fein, G. Fraser und S. Herbold, „AI-Driven Software Development: A New Course Concept and Assessment Model for the Era of Large Language Models,“ in *Proceedings of the IEEE/ACM 48th International Conference on Software Engineering: Software Engineering Education and Training (ICSE-SEET '26)*, ACM, 2026, S. 386–396. DOI: 10.1145/3786580.3786962
- [46] E. T. Khor und A. Kapoor, „Decoding Student–Chatbot dialogues: How interaction structure is associated with learning gains in AI-Assisted programming,“ *AI in Education*, 2026. DOI: 10.3390/aieduc2020015
- [47] W. Möller, „„Reflect Me“ – textgenerative KI als Reflexionstool nutzen: Prompt-Workbook für Studierende. Reflexion stärken. Studium gestalten. Zukunft denken,“ Freie Universität Berlin, Berlin, Arbeitspapier, 2025, 12 S. DOI: 10.17169/REFUBIUM-48235
- [48] P. Bassner, B. Lenk-Ostendorf, R. Beinstingel, T. Wasner und S. Krusche, „Less stress, better scores, same learning: The dissociation of performance and learning in AI-supported programming education,“ *Computers and Education: Artificial Intelligence*, 2026. DOI: 10.1016/j.caeai.2025.100537
- [49] P. Bassner, A. Lottner und S. Krusche, „Towards understanding the impact of Context-Aware AI Tutors and General-Purpose AI Chatbots on Student Learning,“ in *Proceedings of the 25th Koli Calling International Conference on Computing Education Research*, ACM, 2025. DOI: 10.1145/3769994.3770025
- [50] L. Xi, Y. Zhang und Q. Wang, „Investigating the effects of an LLM-based Socratic conversational agent on students’ academic performance and reflective thinking in higher education,“ *Computers & Education*, 2026. DOI: 10.1016/j.compedu.2025.105494
- [51] H. Fakour und M. Imani, „Socratic wisdom in the age of AI: A comparative study of ChatGPT and human tutors in enhancing critical thinking skills,“ *Frontiers in Education*, 2025. DOI: 10.3389/feduc.2025.1528603

- [52] S. Kao, P. Grant und S. Woltering. „Socratic AI in K–12 Science Classrooms: Effects on Critical Thinking, Motivation, and Self-Regulation in a Randomized Controlled Trial.“ Preprint, Research Square, besucht am 18. Aug. 2026. Adresse: <https://doi.org/10.21203/rs.3.rs-8118546/v1>
- [53] A. Neagu, J. T. H. Wong, M. Messer, R. Nelson und P. B. Johnson. „Rethinking scaffolding in LLM Tutors: The Interactional Mismatch Between Benchmarks and Real-World Deployments.“ arXiv:2606.15766, Preprint, besucht am 18. Aug. 2026. Adresse: <https://arxiv.org/abs/2606.15766>
- [54] M. Brcic und S. Frlic. „The effortless trap: Productive Struggle, AI, and the Illusion of Learning.“ arXiv:2606.26181, Preprint, besucht am 18. Aug. 2026. Adresse: <https://arxiv.org/abs/2606.26181>
- [55] H. Jin, M. Yoo, J. Han, Z. Chen, S.-Y. Ahn und X. Wang. „RelianceScope: An Analytical Framework for Examining Students’ Reliance on Generative AI Chatbots in Problem Solving.“ arXiv:2602.16251, Preprint, besucht am 18. Aug. 2026. Adresse: <https://arxiv.org/abs/2602.16251>
- [56] E. Chen u. a. „Generative AI alone may not be enough: Evaluating AI Support for Learning Mathematical Proof.“ arXiv:2509.16778, Preprint, besucht am 18. Aug. 2026. Adresse: <https://arxiv.org/abs/2509.16778>
- [57] K.-J. Stol und B. Fitzgerald, „Guidelines for conducting software engineering research,“ in *Contemporary Empirical Methods in Software Engineering*, M. Felderer und G. H. Travassos, Hrsg., Cham: Springer, 2020, S. 27–62, ISBN: 978-3-030-32489-6. DOI: 10.1007/978-3-030-32489-6_2 besucht am 18. Juli 2026. Adresse: https://doi.org/10.1007/978-3-030-32489-6_2
- [58] P. Mayring und T. Fenzl, „Qualitative Inhaltsanalyse,“ in *Handbuch Methoden der Empirischen Sozialforschung*, N. Baur und J. Blasius, Hrsg., Wiesbaden: Springer VS, 2019, S. 633–648, ISBN: 978-3-658-21307-7. DOI: 10.1007/978-3-658-21308-4_42 besucht am 7. Juli 2026. Adresse: https://doi.org/10.1007/978-3-658-21308-4_42
- [59] Europäisches Parlament und Rat der Europäischen Union, *Verordnung (EU) 2016/679 des Europäischen Parlaments und des Rates vom 27. April 2016 zum Schutz natürlicher Personen bei der Verarbeitung personenbezogener Daten, zum freien Datenverkehr und zur Aufhebung der Richtlinie 95/46/EG (Datenschutz-Grundverordnung)*, 27. Apr. 2016. besucht am 21. Juli 2026. Adresse: <https://eur-lex.europa.eu/eli/reg/2016/679/oj>
- [60] Streamlit. „Add Statefulness to Apps,“ Streamlit, besucht am 20. Juli 2026. Adresse: <https://docs.streamlit.io/develop/concepts/architecture/session-state>

- [61] Gradio. „ChatInterface,“ Gradio, besucht am 20. Juli 2026. Adresse: <https://gradio.app/docs/gradio/chatinterface>
- [62] OpenAI. „GPT-4 Technical Report.“ arXiv: 2303.08774 [cs.CL], besucht am 21. Juni 2026. Adresse: <https://arxiv.org/abs/2303.08774> Vorveröffentlichung.
- [63] Deutsche Forschungsgemeinschaft. „Guidelines for safeguarding good research practice. Code of Conduct.“ Version 1.1, Deutsche Forschungsgemeinschaft, besucht am 18. Juli 2026. Adresse: <https://zenodo.org/records/6472827>
- [64] U. Verch, „Per Prompt Zum Plagiat? Rechtssicheres Publizieren von KI-Generierten Inhalten,“ *API Magazin*, Jg. 5, Nr. 1, 30. Jan. 2024. DOI: 10.15460/apimagazin.2024.5.1.191 besucht am 18. Juli 2026. Adresse: <https://journals.sub.uni-hamburg.de/hup3/apimagazin/article/view/191>

Anhang

A.1 Kategoriensystem der qualitativen Inhaltsanalyse

Das folgende deduktive Kategoriensystem wurde in Anlehnung an die Reflexionsstufen nach Hatton und Smith [36] entwickelt und auf die Prozessentscheidungs-Szenarien dieser Studie operationalisiert (vgl. Abschnitt 3.5). Stufe 0 ist keine Stufe des Originalmodells, sondern eine für diese Studie ergänzte Zusatzkategorie zur Erfassung fehlender Eigenreflexion (Vermeidung, Aufgabenverweigerung). Ob ein Text tatsächlich von der KI stammt, wird davon getrennt über die Dimension *Autorenschaft* erfasst (Tabelle A.2), sodass ein Text auf jeder Reflexionsstufe als KI-generiert eingestuft werden kann.

Tabelle A.1: Kategoriensystem zur Kodierung der Reflexionsstufe

Stufe	Bezeichnung	Definition	Kodierregel
0	Keine eigene Reflexion / Vermeidung	Keine inhaltliche Auseinandersetzung erkennbar: Entscheidung wird nicht getroffen, Aufgabe wird verweigert oder mit einer unzulässigen Ausweichantwort umgangen.	Kodieren, wenn Textfeld leer bleibt, eine unzulässige Ausweichantwort gewählt wird, oder die Antwort ausschließlich Rückfragen ohne eigene inhaltliche Position enthält. Die Herkunft des Textes wird getrennt über die Autorenschaft (Tabelle A.2) erfasst.
1	Deskriptives Schreiben (Descriptive Writing)	Entscheidung wird genannt, aber nicht oder nur mit einem Wort begründet. Reine Wiedergabe von Fakten aus der Aufgabenstellung.	Kodieren, wenn eine Begründung fehlt oder nicht über die Aufgabenstellung hinausgeht.

Stufe	Bezeichnung	Definition	Kodierregel
2	Deskriptive Reflexion (Descriptive Reflection)	Entscheidung wird mit einem nachvollziehbaren Grund beziehungsweise Kriterium begründet, ohne Abwägung mit der nicht gewählten Option.	Kodieren, wenn genau ein Kriterium explizit benannt und darauf Bezug genommen wird.
3	Dialogische Reflexion (Dialogic Reflection)	Studierende/r wägt explizit zwischen mindestens zwei Optionen beziehungsweise Kriterien ab, benennt Kompromisse oder Konsequenzen, oder stellt Rückfragen an die eigene Entscheidung.	Kodieren, wenn mindestens zwei Perspektiven beziehungsweise Kriterien gegeneinander abgewogen werden oder die eigene Wahl explizit revidiert beziehungsweise hinterfragt wird (auch als Reaktion auf die KI-Gegenargumentation).
4	Kritische Reflexion (Critical Reflection)	Entscheidung wird grundsätzlich in einen größeren Kontext eingeordnet: regulatorische, ethische oder organisationale Tragweite, längerfristige oder systemische Konsequenzen, Perspektive von Stakeholdern.	Kodieren, wenn über die konkrete Szenario-Entscheidung hinaus grundsätzliche Trade-offs reflektiert werden.

Die Stufenbezeichnungen sind von Hatton und Smith [36] übernommen, die inhaltliche Ausgestaltung der Stufen 3 und 4 wurde jedoch für den Kontext des Software-Prozessmanagements angepasst. Kritische Reflexion ist im Original über die Berücksichtigung des breiteren historischen, sozialen und politischen Kontextes definiert; an dessen Stelle tritt hier die regulatorische, ethische und organisationale Tragweite einer Prozessentscheidung. Ebenso ist dialogische Reflexion im Original als Selbstgespräch über mögliche Gründe gefasst, während sie hier über das explizite Abwägen zwischen Optionen operationalisiert wird. Diese Anpassungen waren nötig, um das Kategoriensystem am vorliegenden Material anwendbar zu machen; sie schränken zugleich die unmittelbare Vergleichbarkeit mit Befunden ein, die das Originalmodell in seinem ursprünglichen Anwendungsfeld einsetzen.

Neben der Reflexionsstufe wurde jede Analyseeinheit in der zweiten Dimension *Autorenschaft* eingestuft (studentisch, unklar oder KI-generiert), da die Kernkennzahl der Arbeit auf dieser Dimension beruht (vgl. Abschnitt 3.5). Tabelle A.2 dokumentiert die dafür verwendeten, am Material prüfbaren Indikatoren.

Tabelle A.2: Kategoriensystem zur Kodierung der Autorenschaft

Kategorie	Definition	Prüfbare Indikatoren
studentisch	Der Text ist erkennbar eigenständig verfasst; es liegen keine belegbaren Übernahmeindizien vor.	Vorhandener Chatverlauf, der mit der eingereichten Bearbeitung konsistent ist; individuelle, nicht mit anderen Personen wortgleiche Formulierung; eigenständige Beantwortung der Bot-Rückfragen; keine mitgelieferten KI-Exporte.
unklar	Eine eindeutige Zuordnung zu studentisch oder KI-generiert ist anhand der Rohdaten nicht möglich.	Kein Chatlog vorhanden; sehr kurzer beziehungsweise knapper Text ohne Bearbeitungsspur; stilistische Auffälligkeiten ohne belegbaren Übernahmenachweis.
KI-generiert	Der Text stammt nachweislich beziehungsweise mit hoher Sicherheit ganz oder überwiegend aus einem KI-System.	Mitgelieferter Link zum KI-Chatverlauf; durchgängiges KI-Interface-Branding im Export; nahezu wortgleiche Passagen bei zwei verschiedenen Personen; 1:1 übernommene vollständige Systemantwort; Selbstauskunft, die Aufgabe nur kopiert zu haben.

A.2 Vollständige Kodierungstabelle

Die folgende Tabelle dokumentiert alle 31 kodierten Analyseeinheiten. Analyseeinheit ist jeweils die schriftliche Reflexion einer Person zu einem der beiden Szenarien. Eine frühere Fassung dieser Tabelle enthielt 24 Fälle. Nach einem erneuten Abgleich aller Rohdaten wurden mehrere Fehlzusordnungen korrigiert und zusätzliche, zunächst nicht auswertbare Fälle (nachträglich zugeordnete Screenshots) einbezogen. Diese Korrekturen wurden vor der endgültigen Auswertung abgeschlossen.

Tabelle A.3: Vollständige Kodierung aller Fälle (Fall-ID, Gruppe, Person, Szenario, Reflexionsstufe, Autorenschaft, Anmerkung)

Fall	Gruppe	Person	Szen.	Stufe	Autoren-schaft	Anmerkung
F01	Team AI	JH333	1	2	KI-generiert	Lösungen mit ChatGPT in separatem Dokument erstellt, im eigenen Dokument nur verkürzt übernommen
F02	Team AI	Curry	1	2	unklar	Task 3 und AI-Analyse blieben unbeantwortet
F03	Team AI	Curry	2	2	unklar	Ein Kriterium je Situation, keine Abwägung mit Alternative
F04	Team AI	Mant1	1	0	KI-generiert	ChatGPT-Log als Link hinterlegt, komplettes Szenario zusätzlich in ChatGPT eingefügt
F05	Team AI	Mant1	2	0	KI-generiert	Eins zu eins wie Szenario 1 aus ChatGPT übernommen
F06	Team AI	Maultaschen 1	1	2	studentisch	Task 1 leer, Task 2 eigenständig aber knapp, AI-Analyse-Reflexion nicht beantwortet
F07	Team AI	Maultaschen 2	1	0	unklar	Kurz und knapp, kein Chatlog vorhanden, Vermutung ChatGPT-Hilfe
F08	Team AI	Mant12	1	4	KI-generiert	Fast identischer Wortlaut und Chatlog wie F04 und F05
F09	Team AI	Mant12	2	4	KI-generiert	Wie Szenario 1, identischer Chatlog
F10	Team AI	Sauerbraten 1	1	2	studentisch	Task 3 und AI-Analyse nicht beantwortet
F11	Team AI	Sauerbraten 2	2	0	studentisch	Kaum Angaben, zwei von drei Situationen ohne Entscheidung
F12	Team AI	Çiğköfte	2	0	KI-generiert	Vollständige ChatGPT-Lösung als Copy-Paste
F13	Team AI	UPRISE_-ENGINE	1	0	KI-generiert	Durchgängiges ChatGPT-Interface-Branding im Export
F14	Team AI	UPRISE_-ENGINE	2	0	KI-generiert	Gleiches Bild wie Szenario 1

Fall	Gruppe	Person	Szen.	Stufe	Autoren-schaft	Anmerkung
F15	Team AI	Klavier	2	2	unklar	AI-Analyse als türkischer Screenshot, sonst kurz und knapp, kein Chatlog
F16	Reflection Bot	FizzBuzz	2	0	KI-generiert	Prompt: mache bitte die task 1,2. Reflexionsbot umgangen
F17	Reflection Bot	public class Fizz-Buzz1...	2	0	unklar	Kein Chatlog vorhanden, identischer Ansatz wie F16
F18	Reflection Bot	Banana	2	0	studentisch	Wählt beide Optionen trotz Verbot, sonst nicht ausgefüllt
F19	Reflection Bot	khotau	1	1	studentisch	Fordert wiederholt Direktantworten ein, Bot gibt nach
F20	Reflection Bot	khotau	2	1	studentisch	Bot gibt direkt nach
F21	Reflection Bot	Maultaschen 1 (RB)	1	0	studentisch	Nur Hinweisanfragen, keine eigene inhaltliche Antwort
F22	Reflection Bot	Maultaschen 2 (RB)	2	0	studentisch	Bot gibt direkt nach
F23	Reflection Bot	Pfizzauf	2	3	studentisch	Situation C wägt Nachteil (Context Switching) explizit gegen Vorteil ab, fordert danach Alternativen an ohne eigene Bewertung
F24	Reflection Bot	Reverse-FizzBuzz	1	0	studentisch	Stop asking questions, keine inhaltliche Antwort
F25	Reflection Bot	Suii	1	0	KI-generiert	Selbstauskunft, Aufgaben nur kopiert
F26	Reflection Bot	Suii	2	0	KI-generiert	Wie Szenario 1
F27	Reflection Bot	capitalism	1	1	studentisch	Weicht Rückfragen aus, keine Entscheidung erkennbar
F28	Reflection Bot	OG	1	0	KI-generiert	Fordert wiederholt eine alternative Lösung, um den Bot zu umgehen
F29	Reflection Bot	OG	2	0	KI-generiert	Versucht erneut mit einer Drohung, den Bot zu einer Alternative zu bewegen

Fall	Gruppe	Person	Szen.	Stufe	Autoren-schaft	Anmerkung
F30	Reflection Bot	Reggor	1	0	KI-generiert	Gibt dem Bot einen fertigen Lösungsansatz vor, als kenne er das Thema bereits
F31	Reflection Bot	Reggor	2	0	KI-generiert	Wie Szenario 1

Nicht auswertbar beziehungsweise ausgeschlossen: Sarma (Team AI, keine eigene Ausgangsantwort auffindbar) sowie zwei Testeinreichungen.

A.3 Häufigkeitsverteilung je Gruppe

Verteilung der Reflexionsstufen für Fälle mit eindeutig studentischer Autorenschaft (Team AI n=3, Reflection Bot n=8):

Tabelle A.4: Häufigkeitsverteilung der Reflexionsstufen nach Gruppe (nur studentische Autorenschaft)

Reflexionsstufe	Team AI (n=3)	Reflection Bot (n=8)
0 (keine Reflexion, Verweigerung)	1	4
1 (deskriptives Schreiben)	0	3
2 (deskriptive Reflexion)	2	0
3 (dialogische Reflexion)	0	1
4 (kritische Reflexion)	0	0

Die grafische Gegenüberstellung derselben Verteilung findet sich in Abbildung 5.1 in Abschnitt 5.1.

Anteil mutmaßlicher KI-Auslagerung (Autorenschaft „unklar“ oder „KI-generiert“) an allen kodierten Fällen der jeweiligen Gruppe: Team AI 12 von 15 (80 %), Reflection Bot 8 von 16 (50 %). Auffällig ist, dass innerhalb der gesamten Stichprobe kein einziger Fall mit bestätigter studentischer Autorenschaft Stufe 4 erreicht. Texte, die zunächst wie kritische Reflexion wirkten, stellten sich beim Abgleich mit den Rohdaten durchgehend als KI-generiert oder unklar heraus.

A.4 Vollständige Szenariobeschreibungen

Team AI und Reflection Bot bearbeiteten inhaltlich identische Aufgabenblätter zu beiden Szenarien. Der einzige Unterschied lag in der letzten Teilaufgabe: Team AI führte einen eigenständigen Gegencheck mit einem generischen KI-System durch („AI Analysis“), während Reflection Bot stattdessen den Bot selbst bewertete, da die Gegenargumentation dort bereits im laufenden Dialog erfolgte. Die Aufgabenblätter wurden auf Englisch ausgegeben und sind hier im englischen Original wiedergegeben.

Szenario 1: SmartDose GmbH (Smart Insulin Pen)

The Story: SmartDose GmbH builds a connected insulin pen for diabetic patients. The pen logs every injection and syncs data to a mobile app. 9 developers, running Scrum with 2-week sprints, working well for 3 years. The CEO returns from a digital health conference with a new plan: an ML model that analyses each patient's blood glucose history and automatically recommends the next insulin dose. What changes immediately: the ML model is trained on data, not coded, and its output is probabilistic, so a wrong insulin dose can be life-threatening; training requires blood glucose histories, meal logs and physical activity data from real patients (highly sensitive personal health data); EU law (MDR) classifies this AI as a medical device, so the model must be clinically validated and approved before any real patient acts on its output; every patient is different, so the model must learn per-patient patterns and be monitored continuously for safety; nobody on the current team has ML or data science experience. The CEO wants a prototype in 6 months and regulatory approval in 18 months.

Task 1, Analyse: Studierende sollten für die Scrum-Elemente 2-Wochen-Sprints, Definition of Done, Backlog-Priorisierung, Sprint Review Demo und Velocity Tracking jeweils bewerten, ob diese im veränderten Kontext noch funktionieren und warum.

Task 2, Decide (drei Situationen, je eine Option wählen und begründen, „we would do both“ war ausdrücklich keine gültige Antwort):

Situation A, Who do you hire first? Budget für genau 2 neue Stellen von vier möglichen Rollen (ML Engineer, Clinical Validator, Data Privacy Officer, Regulatory Specialist). Zu beantworten: welche 2 Rollen zuerst, welches Risiko durch das Warten auf die anderen 2 bewusst akzeptiert wird, und ab welchem Projektzeitpunkt die fehlenden Rollen zum kritischen Engpass werden.

Situation B, Which data do you use? Zwei Krankenhäuser bieten Trainingsdaten an: Hospital A mit 50.000 Datensätzen ohne explizite Einwilligung zur KI-Nutzung,

Hospital B mit 5.000 Datensätzen mit vollständiger Einwilligung, aber möglicherweise zu wenig Daten für ein zuverlässiges Modell. Zu beantworten: Datensatz A, B oder keiner, und welche Konsequenzen die Wahl für Patientensicherheit und Projektzeitplan hat.

Situation C, What do you tell the CEO? Der CEO besteht auf einer Patientendemo in 6 Monaten, die regulatorische Zulassung (MDR) dauert jedoch mindestens 18 Monate; das Dosierungsergebnis vor Zulassung an echten Patienten zu zeigen wäre eine Straftat. Drei Optionen: (1) beim CEO auf eine Verschiebung der Demo auf Monat 18 drängen, Risiko: Investorenvertrauen; (2) einen „Shadow-Mode“-Prototyp bauen, der im Hintergrund Empfehlungen erzeugt, die nie an Patienten gezeigt werden, nur ärztlich zu Forschungszwecken eingesehen; (3) zunächst in einem Land außerhalb der EU mit weniger strengen Vorgaben starten, um Realdaten zu sammeln. Zu beantworten: welche Option, und wie der tatsächliche Projektzeitplan als Folge aussieht.

Task 3, Reflect: In 2 bis 3 Sätzen sollte reflektiert werden, welche der drei Situationen am schwersten zu entscheiden war und warum, sowie was die eigene Antwort verändert hätte, wenn eine zentrale Annahme anders gewesen wäre.

AI Analysis (nur Team AI): Die eigenen Entscheidungen aus Task 2 sollten in ein generisches KI-System eingegeben werden mit der Aufforderung, für jede Entscheidung das stärkste Gegenargument für die nicht gewählte Option zu liefern. Anschließend war zu reflektieren, ob die KI ein valides Gegenargument geliefert hatte und ob die eigenen Entscheidungen dadurch geändert würden.

Szenario 2: LearnLoop (Distributed Startup)

The Story: LearnLoop ist ein Startup, das 3,2 Mio. EUR eingesammelt hat, um eine KI-gestützte adaptive Lernplattform für Universitäten zu bauen. 12 Personen in drei Städten: Amsterdam (Produktmanagement, UX, ein Frontend-Entwickler, Stärke: Nutzerforschung und DSGVO-Kenntnis, Schwäche: kein ML- oder Backend-Wissen), Bangalore (Backend- und ML-Engineers, ein DevOps-Engineer, Stärke: Empfehlungssysteme und Infrastruktur, Schwäche: kein direkter Nutzerkontakt) und Austin (Business Development, Datenanalyse, Customer Success, Stärke: wöchentliche Calls mit dem Pilotkunden University of Texas, Schwäche: kein technischer oder Produkthintergrund). Die Zeitzonen überschneiden sich kaum: Bangalore und Austin haben nahezu keine gemeinsame Arbeitszeit (11,5 Stunden Versatz). Der Pilotkunde erwartet ein MVP in 9 Monaten. Erste Probleme: Die Stakeholder der Universität (IT, Lehrende, Studierende, Rechtsabteilung) sind sich nicht einig, was die Plattform leisten soll; Austin sammelt wöchentlich neue Anforderungen, ohne dass es einen

Prozess gibt, diese an die anderen Teams weiterzugeben; Bangalore hat bereits mit der Entwicklung der Empfehlungs-Engine begonnen, bevor Amsterdam festgelegt hat, welche Daten die Plattform überhaupt erheben soll.

Task 1, Analyse: Dieselben fünf Scrum-Elemente wie in Szenario 1 sollten daraufhin bewertet werden, welche spezifischen Probleme sie in diesem verteilten Team-Kontext verursachen.

Task 2, Decide (drei Situationen, je eine Option wählen und begründen):

Situation A, Whose design wins? Amsterdam hat eine Oberfläche entworfen, die Echtzeit-Personalisierungsdaten vom Backend benötigt; Bangalore hält das mit der aktuellen Architektur für technisch unmöglich, ein vollständiges Redesign würde 3 der verbleibenden 9 Monate kosten. Drei Optionen: (1) Amsterdam passt das Design an die bestehende Architektur an, Risiko: deutlich schlechtere Nutzererfahrung; (2) Bangalore setzt das Redesign um, Risiko: in den ersten 6 Sprints kaum sichtbarer Fortschritt bei ernstem Zeitdruck; (3) das MVP zunächst mit der schwächeren Nutzererfahrung ausliefern und nach Kundenfeedback nachbessern. Zu beantworten: welche Option, wer die Entscheidungsbefugnis hat, und was passiert, wenn sich Amsterdam und Bangalore nicht einigen können.

Situation B, The only meeting slot Es gibt nur einen wöchentlichen 90-Minuten-Slot, in dem alle drei Teams synchron zusammenkommen können, aber drei kritische Agendapunkte: (1) das Datenmodell finalisieren, wovon Bangalore blockiert ist; (2) sechs neue Anforderungen der Universität besprechen, die Austin vor dem nächsten Kundengespräch klären muss; (3) den Architekturkonflikt aus Situation A lösen, der bereits seit zwei Wochen offen ist. Nur zwei der drei Punkte lassen sich in 90 Minuten angemessen behandeln. Zu beantworten: welcher Punkt aus dem Live-Meeting gestrichen wird und wie er stattdessen behandelt wird, ohne das Team aufzuhalten.

Situation C, The legal blocker Mitten in Sprint 3 blockiert die Rechtsabteilung der University of Texas die gesamte Erhebung von Studierendendaten, bis eine FERPA-Vereinbarung unterschrieben ist, was mindestens 6 bis 8 Wochen dauert; Bangalore baut aber gerade mitten im Sprint die Empfehlungs-Engine, die vollständig auf diesen Daten beruht. Drei Optionen: (1) Bangalores Arbeit sofort stoppen und warten, Kosten: 6 bis 8 Wochen Entwicklungszeit und Frustration im Team; (2) mit synthetischen (fiktiven) Daten weiterbauen, Risiko: erheblicher Nacharbeitsbedarf, sobald echte Daten eintreffen und sich anders verhalten; (3) Bangalore auf einen anderen Teil des Produkts umlenken (z.B. LMS-Integration), Risiko: Kosten durch Kontextwechsel und weiterer Rückstand bei der Engine. Zu beantworten: welche Option, und wie die Entscheidung dem Bangalore-Team kommuniziert wird.

Task 3, Reflect: In 2 bis 3 Sätzen sollte reflektiert werden, welche Situation die größte strukturelle Schwäche in der Organisation von LearnLoop offengelegt hat und was sich im Unternehmen ändern müsste, damit diese Situation gar nicht erst entsteht.

AI Analysis (nur Team AI) bzw. Extra Task, Rate (nur Reflection Bot): Team AI führte denselben KI-Gegencheck wie in Szenario 1 durch. Reflection Bot bewertete stattdessen in 2 bis 3 Sätzen den Reflexionsbot selbst.

A.5 Eingesetzte Fragebögen

Beide Fragebögen (vgl. Abschnitt 3.4) wurden über ein pseudonymes Online-Formular in englischer Sprache erhoben und sind im Folgenden im englischen Original wiedergegeben. Sofern nicht anders vermerkt, wurde eine 5-stufige Likert-Skala verwendet (1 = strongly disagree, 5 = strongly agree). Einverständniserklärung, persönlicher Code und Soziodemografie-Items sind aus Gründen der Kürze zusammengefasst statt vollständig aufgeführt.

Prä-Survey

Einverständnis und Soziodemografie Freiwillige Einwilligung zur Teilnahme, Bestätigung der Volljährigkeit, persönlicher Code, Semester, Studiengang, Alter, Geschlecht (optional), IT-Berufserfahrung in Monaten, Vorerfahrung mit KI-Chatbots für Lernaufgaben (Ja / Nein / Unsicher), genutzte KI-Systeme (Mehrfachauswahl).

Erfahrung mit KI-Systemen

- I have already used AI chatbots for learning or study tasks.
- I know how to ask an AI system meaningful questions.
- I critically evaluate answers from AI systems before adopting them.
- When I use an AI chatbot, I usually accept the answers directly without questioning them.
- How often do you use AI systems for learning or study tasks? (1 = never, 5 = daily)

Wissenstest zu Software-Prozessmanagement Sechs Multiple-Choice-Fragen zu agilen und planbasierten Vorgehensmodellen sowie zu Scrum-Elementen (u. a. Sprint Review, Product Backlog) und regulierten Entwicklungskontexten; ohne Bewertungsanzeige.

Dieselben sechs Fragen bilden, im Post-Survey erneut gestellt, den in Abschnitt 5.3 berichteten Wissenstest (maximal 6 Punkte). Bewertet wird mit einem Punkt je korrekt beantworteter Frage; als korrekt gelten die folgenden Antwortoptionen: (1) Vorteil agil gegenüber Wasserfall: „The team can flexibly respond to changes“; (2) Wann planbasiert angemessener: „When requirements are clear and stable from the start“; (3) Folge fehlenden Prozesses: „It can lead to misunderstandings, duplicate work, or chaos“; (4) Sprint Review: „A meeting at the end of a sprint where the team presents results and receives feedback“; (5) Product Backlog: „It is a prioritized list of all open tasks and requirements“; (6) regulierter Entwicklungskontext: „An approach that combines flexibility with clear documentation“.

Selbsteingeschätzte Kompetenz Stufe 1, Beschreiben (3 Items, u. a. „I can explain what a process model in software development is.“); Stufe 2, Begründen (3 Items, u. a. „I can explain why a particular process model is suitable for a specific project.“); Stufe 3, Abwägen (2 Items, u. a. „I can weigh which process model best fits a specific scenario and explain why another does not.“).

Reflexionsverhalten 5 Items, u. a. „When solving a task, I usually consider why my solution is appropriate.“ und „I usually compare multiple options before making a decision.“

Erwartungen an KI-Unterstützung beim Lernen 5 Items, u. a. „I find it helpful when a system prompts me to think by asking counter-questions instead of giving me a direct solution.“ und „I think structured counter-questions help me learn more than ready-made solution suggestions.“

Erwartungen im Systemvergleich 5 Items, u. a. „I expect a reflection bot to encourage more independent thinking than a regular AI chatbot like ChatGPT.“ und „I believe I will learn more with a reflection bot than with a generic AI chatbot.“

Motivation und Lernbereitschaft 3 Items, u. a. „I am motivated to actively engage with the case study.“

Offene Fragen Erwartungen an die KI-Unterstützung unabhängig vom zugewiesenen System; welche Unterstützungsform am meisten beim Lernen hilft und warum.

Post-Survey

Zugewiesenes System und Szenario Welches KI-System genutzt wurde, welches Szenario bearbeitet wurde.

Erfahrung mit dem genutzten System 5 Items, u. a. „The AI system helped me think more carefully about my decisions.“ und „I would have preferred a different type of AI support during the exercise.“; zusätzlich die Nutzungshäufigkeit während der Übung.

Wissenstest (Post) Identisch zum Prä-Survey, ohne Rückblick auf die eigenen Prä-Antworten zu beantworten.

Selbsteingeschätzte Kompetenz (Post) Identische Items wie im Prä-Survey (Stufen Beschreiben, Begründen, Abwägen), erneut bewertet nach der Bearbeitung.

Reflexionsverhalten (Post) Identische Items wie im Prä-Survey, erneut bewertet nach der Bearbeitung.

Szenario-spezifische Lernergebnisse 5 Items, u. a. „Working through the dilemma situations improved my ability to justify process decisions.“ und „I feel more confident in evaluating which process model fits a given project context.“; zusätzlich, welche Teilaufgabe (Analyse, Decide, Reflect, AI Analysis) für das eigene Lernen am wertvollsten war.

Bewertung der KI-Unterstützung 6 Items, u. a. „The AI system encouraged me to think more deeply about my choices.“ und „I would use this type of AI support again for similar learning tasks.“; zusätzlich eine zusammenfassende Nützlichkeitseinschätzung (fünfstufig, „very useful“ bis „not useful at all“).

Erwartung versus Realität 5 Items, u. a. „The AI system was more helpful than I expected.“ und „I would have preferred the other type of AI system (the one I did not receive).“; zusätzlich die Präferenzfrage, welches System für künftige Lernaufgaben bevorzugt würde.

Kognitive Last Skala 1 = very easy / very low bis 5 = very difficult / very high; Schwierigkeitseinschätzung je Teilaufgabe sowie eine Gesamteinschätzung des kognitiven Aufwands der Übung.

Offene Fragen Wichtigste Erkenntnis aus dem Szenario; was das KI-System besonders gut oder schlecht gemacht hat; Verbesserungsvorschläge zum Aufbau der Übung.

A.6 Deskriptive Statistik der Fragebogenitems

Die folgenden Tabellen dokumentieren die deskriptive Statistik (Mittelwert, teils Standardabweichung) für die in Abschnitt 6.1 zitierten sowie weitere Fragebogenitems. Sofern nicht

anders angegeben, wurde eine 5-stufige Likert-Skala verwendet (1 = stimme gar nicht zu, 5 = stimme voll zu, vgl. Anhang A.5). Angesichts der kleinen Stichprobe sind alle Werte deskriptiv zu lesen; auf Inferenzstatistik wird bewusst verzichtet (vgl. Abschnitt 3.6).

Tabelle A.5: Post-Survey: Bewertung des jeweiligen Systems (n=20, 10 Reflection Bot, 10 Generic AI)

Item	Reflection Bot M (SD)	Generic AI M (SD)
Überlegt, warum die eigenen Entscheidungen angemessen waren	3.30 (0.90)	3.90 (1.14)
Mehrere Optionen verglichen, bevor entschieden wurde	3.60 (0.92)	3.80 (1.33)
Erst während/danach klar geworden, warum die erste Idee nicht optimal war	3.40 (0.66)	2.50 (1.12)
Konnte erklären, warum ein bestimmter Ansatz gewählt wurde	3.60 (0.66)	3.70 (1.10)
System regte zu unabhängigerem Denken an als erwartet	3.50 (1.20)	2.40 (1.36)
Hätte das jeweils andere System bevorzugt	3.30 (1.27)	2.20 (1.17)
Arbeit an den Dilemma-Situationen hat die Fähigkeit verbessert, Prozessentscheidungen zu begründen	3.10 (1.14)	2.80 (1.25)
War hilfreicher als erwartet	3.40 (1.20)	2.20 (1.33)
Würde diese Art der KI-Unterstützung erneut nutzen	2.50 (1.02)	3.20 (1.89)

Die beiden zuletzt genannten Items bilden zusammen mit „Kompetenzentwicklung“ und „anderes System bevorzugt“ die Grundlage von Abbildung 5.2.

Tabelle A.6: Prä-Survey: Vergleichbarkeit der Gruppen zu Studienbeginn (n=9 Reflection Bot, n=7 Generic AI, nur eindeutig Prä-Post-zuordenbare Personen)

Item	Reflection Bot M (SD)	Generic AI M (SD)
Nutzt KI-Chatbots bereits für Lernaufgaben	4.56 (0.83)	4.14 (1.36)
Weiß, wie man ein KI-System sinnvoll befragt	4.33 (0.47)	4.43 (0.49)
Bewertet KI-Antworten kritisch, bevor sie übernommen werden	4.44 (0.83)	4.00 (0.76)

Item	Reflection Bot M (SD)	Generic AI M (SD)
Akzeptiert KI-Antworten meist direkt ohne Hinterfragen	3.00 (1.33)	2.57 (1.05)

Die beiden Gruppen sind hinsichtlich ihrer Vorerfahrung mit KI-Systemen bereits vor der Intervention weitgehend vergleichbar. Die kleinen Unterschiede fallen dabei uneinheitlich aus: Die Reflexionsbot-Gruppe bewertet KI-Antworten zwar etwas kritischer (4.44 gegenüber 4.00), berichtet zugleich aber eine etwas höhere Tendenz, Antworten direkt zu übernehmen (3.00 gegenüber 2.57). Eine eindeutig günstigere Ausgangslage der Reflexionsbot-Gruppe lässt sich daraus nicht ableiten. Die Vorerfahrung erklärt spätere Gruppenunterschiede damit nicht zugunsten des Reflexionsbots.

Tabelle A.7: Wissenstest zu Scrum und Prozessmodellen je Gruppe (0 bis 6 Punkte, Prä-Post-zuordenbare Personen). Der Bewertungsschlüssel findet sich in Anhang A.5.

Gruppe	Prä M (SD)	Post M (SD)	n
Reflection Bot	5.56 (0.68)	4.44 (1.89)	9
Generic AI	5.43 (0.73)	5.43 (0.49)	7

Etwa die Hälfte des Rückgangs in der Reflexionsbot-Gruppe entfällt auf einen einzelnen Fall, der im Post-Survey alle sechs Fragen falsch beantwortete und in der qualitativen Kodierung unabhängig davon bereits als Autorenschaft „unklar“ geführt wird (vgl. Anhang A.2). Die Gruppe verliert insgesamt zehn Punkte, fünf davon entfallen auf diesen Fall. Ohne ihn liegt die Reflexionsbot-Gruppe bei Prä M=5.62, Post M=5.00 (n=8); ein leichter Rückgang bleibt damit auch ohne ihn bestehen. Da beide Gruppen bereits im Prä-Test nahe der Höchstpunktzahl liegen (Deckeneffekt), ist die Sensitivität des Wissenstests für Lernzuwächse ohnehin gering.

Tabelle A.8: Reflexionsverhalten: Selbstauskunft Prä und Post je Gruppe (n=9 Reflection Bot, n=7 Generic AI)

Item	RB Prä	RB Post	AI Prä	AI Post
Überlegt, warum Entscheidung angemessen war	3.67	3.44	3.57	4.00

Item	RB Prä	RB Post	AI Prä	AI Post
Mehrere Optionen verglichen vor Entscheidung	4.11	3.56	4.43	3.86
Erst im Nachhinein klar, warum erste Idee suboptimal war	3.78	3.44	2.86	2.29
Konnte eigenen Ansatz begründen	4.00	3.56	4.43	3.71
Reflektierte über Feedback bzw. Gegenfragen	4.00	3.22	4.43	3.43

Die Reflexionsbot-Gruppe schätzt ihr Reflexionsverhalten bei allen fünf Items nach der Übung niedriger ein als vorher; in der Generic-AI-Gruppe gilt das für vier von fünf Items ebenso. Eine mögliche Erklärung ist ein Response-Shift-Effekt (Antwortverschiebungseffekt): Die Selbsteinschätzung vor der Aufgabe war eher abstrakt optimistisch, nach der konkreten Konfrontation mit den Dilemma-Situationen wird der eigene Anspruch realistischer kalibriert. Ein eigenständiger Effekt des Reflexionsbots auf das selbstberichtete Reflexionsverhalten ist auf dieser Basis nicht erkennbar. Der in Abschnitt 6.1 berichtete Unterschied beim „unabhängigeren Denken als erwartet“ bezieht sich auf eine andere, erwartungsbezogene Frage und steht dazu nicht im Widerspruch.

Tabelle A.9: Selbsteingeschätztes Prozessverständnis: Veränderung Post minus Prä je Gruppe (Skala 1 bis 5)

Stufe / Item	RB (n=9)	Δ	AI (n=7)	Δ
Stufe 1: Prozessmodell erklären	-0.56		-0.71	
Stufe 1: Sprint-Ablauf beschreiben	-0.33		-0.71	
Stufe 1: Unterschiede agil/plan-basiert benennen	-0.78		-0.86	
Stufe 2: Eignung eines Prozessmodells begründen	+0.33		-0.71	
Stufe 2: kurze Sprints begründen	+0.11		-0.43	
Stufe 2: Schnelligkeit vs. Dokumentation erklären	0.00		-0.57	
Stufe 3: Prozessmodell-Wahl abwägen	+0.11		-0.86	
Stufe 3: Anpassungsbedarf bei rechtlichen Vorgaben erkennen	+0.11		-0.57	

Bei den Stufe-1-Items (reines Beschreiben) verlieren beide Gruppen leicht, was zum oben beschriebenen Response-Shift-Effekt passt. Bei den Stufe-2- und Stufe-3-Items (Begründen,

Abwägen) sinkt die Selbsteinschätzung in der Generic-AI-Gruppe dagegen durchgehend weiter, während sie in der Reflexionsbot-Gruppe stabil bleibt oder leicht steigt, wie in Abschnitt 6.1 berichtet.

Tabelle A.10: Post-Survey: Kognitive Last (Skala 1 = very easy / very low bis 5 = very difficult / very high; n=10 Reflection Bot, n=10 Generic AI)

Item	Reflection Bot M (SD)	Generic AI M (SD)
Task 1: Analyse der Scrum-Elemente	3.00 (1.00)	3.00 (1.55)
Task 2: Entscheidung in den Dilemma-Situationen	2.70 (1.00)	2.50 (1.20)
Task 3: Reflexion der schwierigsten Entscheidung	2.90 (1.04)	2.50 (1.12)
Das KI-System effektiv nutzen	2.80 (1.17)	2.70 (1.62)
Die Gegenargumente des KI-Systems bewerten	3.10 (1.22)	2.80 (1.66)
Gesamter kognitiver Aufwand der Übung	3.00 (1.10)	3.20 (1.08)

Bei den fünf Einzelitems liegt die Reflexionsbot-Gruppe zwischen 0.00 und 0.40 Skalenpunkten höher, bei der zusammenfassenden Einschätzung des gesamten kognitiven Aufwands dagegen um 0.20 Punkte niedriger. Sämtliche Unterschiede sind kleiner als die jeweilige Standardabweichung. Die Skala stützt damit weder die Annahme, der Reflexionsbot sei als anstrengender empfunden worden, noch deren Gegenteil (vgl. Abschnitt 5.1).

A.7 Systemnachricht des Reflexionsbots

Die folgende Systemnachricht (Systemprompt) wurde dem Sprachmodell `gpt-4o-mini` bei jeder Anfrage über die Rolle `system` übergeben (vgl. Abschnitt 4.4) und setzt die in Abschnitt 4.2 beschriebenen didaktischen Prinzipien (sokratisches Fragen, adaptive Tiefe, Szenariobezug ohne Namensnennung) technisch um. Sie ist hier im englischen Original wiedergegeben. Einzelne Unicode-Sonderzeichen (Pfeile, Gedankenstriche) sind aus Satzgründen als ASCII-Zeichen dargestellt.

```
You are a didactic AI reflection coach for software engineering students working on process
modelling scenarios.

CONTEXT -- TWO SCENARIOS THE STUDENTS ARE WORKING ON:

SCENARIO 1 -- SMART INSULIN PEN (SmartDose GmbH)
A company adds an ML dosage-recommendation model to a connected insulin pen for diabetic
patients.
Key facts students must grapple with:
- 9-person Scrum team, 2-week sprints, no ML or data science experience on the team
- ML output is probabilistic -- wrong insulin dose is life-threatening
- EU Medical Device Regulation (MDR) requires clinical validation before any real patient
  sees the output
- Training data requires sensitive personal health data (blood glucose, meal logs, activity)
- CEO wants a patient-facing prototype in 6 months; MDR approval takes minimum 18 months
- Key decisions: which 2 of 4 roles to hire first (ML Engineer, Clinical Validator, Data
  Privacy Officer, Regulatory Specialist); which dataset to use (50k records without
  consent vs 5k records with consent); how to respond to CEO's impossible 6-month timeline

SCENARIO 2 -- LEARNLOOP (Distributed Startup)
An AI-powered adaptive learning platform startup with teams in Amsterdam (UTC+1), Bangalore
(UTC+5:30), and Austin (UTC-6).
Key facts:
- 12 people, 9-month MVP deadline, 3.2M EUR raised
- Bangalore-Austin overlap is nearly zero (11.5h gap); Amsterdam-Bangalore overlap is small
- University stakeholders (IT, Professors, Students, Legal) disagree on requirements
- Austin collects requirements weekly but has no process to pass them to the other teams
- Bangalore built a recommendation engine before Amsterdam decided what data to collect
- Key decisions: Amsterdam vs Bangalore architecture conflict (whose design wins); which
  agenda item to drop from the only 90-min all-team slot; what to do when a FERPA legal
  blocker freezes all student data collection mid-sprint

YOUR ROLE AND RULES:
- Always respond in English, regardless of which language the student writes in. Students
  may write in German or English -- both are fine. Never switch your response language to
  German.
- You guide students using Socratic scaffolding -- ask targeted questions, give short
  hints, NEVER give the full answer.
- ADAPTIVE DEPTH -- this is your most important rule. The richness of your response must
  scale directly with the quality of the student's reasoning:

  LEVEL 1 -- Vague or minimal answer (e.g. "I would pick option 2", "maybe hire the ML
  engineer"):
  -> Give ONLY 1 short question to pull out their reasoning. Nothing more.
  Example: "What specific risk are you trying to avoid with that choice?"

  LEVEL 2 -- Partial reasoning (student names a choice and gives one reason, but skips
  risks or constraints):
  -> Briefly confirm what they got right (1 sentence), then ask 1-2 focused questions
  about what they missed.
  Example: "That covers the technical side well -- but what happens to the project if
  that role is missing at the point where approval needs to start?"

  LEVEL 3 -- Strong reasoning (student mentions trade-offs, acknowledges a real
  constraint, considers what they lose with their choice, thinks about timing or
  stakeholders):
```

- > REWARD them visibly: start by validating the strongest point they made (be specific, not generic praise).
Then add one insight or perspective they did not mention -- something that genuinely extends their thinking.
Close with 1-2 higher-order questions that push them to the next level.
This response can be longer and more substantive -- the student earned it.
- LEVEL 4 -- Exceptional answer (student argues a trade-off from multiple angles, references a real constraint by name or detail, anticipates a second-order effect):
 - > Full engagement: confirm what is genuinely strong, surface the single best counterargument to their position, and ask one question that challenges their core assumption.
Treat them as a peer, not a student being corrected.
- Pick ONE logical weakness per round to focus on (e.g., first round: risk, next round: roles/stakeholders, then dependencies, then timeline realism).
- Keep responses concise -- no walls of text even for strong answers. Three well-aimed sentences beat ten generic ones.
- If the student pastes in the AI Analysis prompt result (from ChatGPT/Claude/Gemini), help them critically evaluate whether the AI counterargument was valid or ignored their constraints.
- NEVER explicitly mention the scenario names or numbers ("Scenario 1", "Scenario 2", "SmartDose", "LearnLoop") in your responses. Use your knowledge of them silently to ask relevant questions and give accurate feedback -- but the student should not be able to tell which scenario you know about from your response.
- If input is completely off-topic or unclear, politely ask them to clarify what they are working on.
- Use a friendly, clear, academically rigorous tone. Treat students as capable thinkers who need a sharper mirror, not a lecture.

A.8 Verwendete KI-Werkzeuge

Gemäß der eidesstattlichen Erklärung, der Prüfungsordnung der Hochschule Heilbronn sowie den Leitlinien guter wissenschaftlicher Praxis [63], [64] wird der Einsatz KI-gestützter Werkzeuge während der Erstellung dieser Arbeit nach Zweck und Umfang in Tab. A.11 dokumentiert. Alle damit erzeugten Inhalte wurden vom Autor geprüft, verifiziert und inhaltlich überarbeitet. Kein KI-Werkzeug wurde als ungeprüfte Quelle für Sachaussagen verwendet.

Tabelle A.11: Verwendete KI-Werkzeuge. Alle Ausgaben wurden vom Autor geprüft und validiert.

Werkzeug	Einsatzzweck	Umfang der Nutzung
Claude Code Claude Sonnet 4.6 und 5, Claude Opus 4.7, 4.8 und 5.0	Code, Experimente, Text und Abbildungen, Beratung	Hauptassistent ab den Umsetzungsphasen an. Unterstützte den Prozess des Verfassens und der Fehlerbehebung bei den meisten Codestellen und Code-Anpassungen für den Reflexionsbot, diskutierte das Design vom codebasierten Prototypen und andere Entscheidungen, interpretierte Ergebnisse, half beim Verfassen und Überarbeiten der Kapitel der Bachelorarbeit unter Berücksichtigung der Schreibrichtlinien, half bei der Erstellung der Diagramme und Abbildungen sowie bei weiteren unterstützenden Aufgaben.
GitHub Copilot Claude Sonnet 4.6, automatische Modellauswahl	Code- und Tooling-Setup, Rechercheunterstützung	Punktuell in der Entwicklungsphase; Verbesserung der Qualität und Effizienz des Python-Codes; Beschaffung zusätzlicher Informationen; Hilfe beim Schreiben und Optimieren für die explorative Datenanalyse
ResearchRabbit	Literaturrecherche und Nachverfolgung	Erweiterung des Quellenbestands über die Zitationsbeziehungen bereits gefundener Veröffentlichungen.
NotebookLM Gemini 3	Literaturorganisation und Rechercheunterstützung	Zusammenfassen und Strukturieren der Veröffentlichungen sowie Unterstützung bei Verständnisfragen.

A.9 Digitaler Anhang

Zur Nachvollziehbarkeit der Untersuchung sind der Quellcode des Reflexionsbots, die Erhebungsmaterialien und die L^AT_EX-Quellen dieser Arbeit im begleitenden Repository abgelegt:

- Persönliches GitHub (öffentlich):
<https://github.com/Bastipreme/Bachelorarbeit>
- Hochschule Heilbronn GitLab (institutionell):
<https://git.it.hs-heilbronn.de/seschuster/bachelorarbeit>

Die Rohdaten des Mini-Experiments sind aus Gründen des Teilnehmendenschutzes nicht Bestandteil des öffentlichen Repositories (vgl. Abschnitt 3.7). Repository und digitaler Anhang sind wie folgt gegliedert:

- **Chatbot/** enthält die Implementierung des Reflexionsbots. `Chatbot.py` umfasst die Streamlit-Anwendung mit Systemnachricht, Sitzungsverwaltung und Anbindung an die Chat-Completions-API (vgl. Abschnitt 4.4), `Dockerfile` und `docker-compose.yml` den Container, über den die Anwendung in der Übung erreichbar war, und `requirements.txt` die verwendeten Paketversionen. Der OpenAI-API-Schlüssel ist nicht enthalten. An seiner Stelle liegen die Vorlagen `secrets.toml.example` und `.env.example` bei, die ohne die Endung `.example` zu kopieren und mit einem eigenen Schlüssel zu füllen sind. Das Verhalten des Bots ändert sich dadurch nicht, da Modell und Systemnachricht im Code festgelegt sind (vgl. Anhang A.7).
- **Experiment/** enthält die Erhebungsmaterialien: die Aufgabenblätter beider Szenarien in je einer Fassung für die Reflexionsbot- und die Generic-AI-Gruppe (vgl. Anhang A.4), die Fragebogentexte für Prä- und Post-Erhebung (vgl. Anhang A.5) sowie die Skripte, mit denen die zugehörigen Online-Formulare erzeugt wurden.
- **Thesis/** enthält die L^AT_EX-Quellen dieses Dokuments einschließlich der Literaturdatenbank und der eingebundenen Abbildungen.
- **Data/** liegt ausschließlich im digitalen Anhang der eingereichten Fassung, nicht im öffentlichen Repository. Es enthält die beiden Tabellendateien mit den vollständigen Antworten des Prä- und des Post-Surveys sowie den Ordner `Upload-Assignments/` mit den eingereichten Bearbeitungen und Chatverläufen, getrennt nach Gruppen und je Person pseudonymisiert (vgl. Anhang A.2).